

Biostatistiques Appliquées & Modélisation du Vivant

Chapitre 0 : Généralités sur les Statistiques, Probabilités & Démarche Expérimentale

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie
Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Plan Détaillé du Chapitre 0

La Démarche Biostatistique & la Variabilité du Vivant

Typologie des Variables & Échelles de Mesure

Statistique Descriptive : Position & Dispersion

Fondements des Probabilités en Biologie

Les Grandes Lois de Probabilité en Biologie

Inférence Statistique & Intervalles de Confiance

Logique des Tests d'Hypothèses & Prise de Décision

Conditions d'Application & Arbre Décisionnel

Organisation & Feuille de Route du Module

Pourquoi le Biochimiste a-t-il un Besoin Vital des Statistiques ?

Définition / Concept Clé : La Nature Intrinsèque du Vivant

En physique ou chimie minérale, les conditions identiques mènent à des résultats quasi déterministes.

En **Biochimie et Biologie** :

- ▶ Deux souris de même lignée consanguine réagissent différemment à un xénobiotique.
- ▶ Deux cultures cellulaires clonales présentent une hétérogénéité d'expression enzymatique.
- ▶ Le métabolisme cellulaire oscille en permanence (rythmes circadiens, homéostasie).

Cas Pratique Biochimie : Le Rôle Central de la Statistique

La biostatistique n'est pas un calcul abstrait ; c'est **l'outil décisionnel** indispensable pour :

1. **Quantifier l'incertitude** inhérente aux mesures expérimentales de laboratoire.
2. **Extraire le signal biologique réel** du bruit de fond aléatoire.
3. **Prendre une décision objective** : valider ou réfuter l'effet d'une molécule d'intérêt avec un risque d'erreur strictement contrôlé.

Décomposition de la Variabilité Expérimentale

📖 Définition / Concept Clé : L'Équation Fondamentale du Laboratoire

Toute mesure brute Y (absorbance spectrophotométrique, intensité de fluorescence, fluorescence qPCR) s'écrit :

$$\text{Mesure Observée} = \text{Signal Vrai} + \text{Biais Biologique} + \text{Erreur Technique}$$

🦋 Variabilité Biologique (Inhérente)

- ▶ Diversité génétique, statut épigénétique, âge, poids, sexe, statut nutritionnel.
- ▶ $\Rightarrow$ **C'est le cœur même de la recherche !** On ne peut pas l'annuler, on doit en estimer la distribution.

🔧 Variabilité Technique (Artefactuelle)

- ▶ Imprécision de pipetage, fluctuations thermiques du bain-marie, dérive de la lampe UV.
- ▶ $\Rightarrow$ **Bruit parasite** à minimiser par de rigoureuses Bonnes Pratiques de Laboratoire (BPL).

Réplicats Biologiques vs. Réplicats Techniques

Définition / Concept Clé : Réplicats Biologiques (N)

Échantillons prélevés sur des **organismes ou systèmes biologiques totalement indépendants** (ex: 6 souris différentes, 3 extractions tissulaires distinctes).

⇒ **Seuls les réplicats biologiques** permettent d'extrapoler les conclusions à une population générale !

Piège Fréquent en Biologie : Réplicats Techniques (k)

Mesures répétées sur le **même échantillon biologique** (ex : doser 3 fois le même tube de sérum dans 3 puits d'une microplaque ELISA).

⇒ Réduit l'imprécision instrumentale, mais **ne donne aucune information** sur la variabilité biologique inter-individuelle.

Message Clé à Retenir : La Pseudo-Réplication : Faute Méthodologique Majeure

Compter 3 mesures techniques sur 1 seule souris comme $N = 3$ est une tromperie statistique. Le vrai N biologique est 1 ! En analyse statistique, on fait la moyenne des réplicats techniques pour n'avoir qu'un seul point par unité biologique.

De la Population Cible à l'Échantillon Expérimental

Définition / Concept Clé : La Population Parente (Ω)

- ▶ Ensemble total des unités d'intérêt (ex : tous les patients diabétiques d'Algérie, toutes les cellules HeLa du monde).
- ▶ Caractérisée par des **paramètres vrais mais inconnus** :
 - ▶ Moyenne vraie : μ
 - ▶ Variance vraie : σ^2
 - ▶ Écart-type vrai : σ

Cas Pratique Biochimie : L'Échantillon Réel (n)

- ▶ Sous-ensemble fini accessible au laboratoire (ex : $n = 25$ rats, $n = 12$ biopsies).
- ▶ Caractérisé par des **statistiques calculées** :
 - ▶ Moyenne observée : $\bar{X}$
 - ▶ Variance d'échantillon : s^2
 - ▶ Écart-type d'échantillon : s (ou SD)

Message Clé à Retenir : L'Inférence Statistique : Le Pont entre Échantillon et Population

L'inférence statistique consiste à utiliser les statistiques connues calculées sur l'échantillon ($\bar{X}, s$) pour estimer avec une marge d'erreur quantifiée les paramètres inconnus de la population (μ, σ).

Les 4 Natures de Données Rencontrées au Laboratoire

Type de Variable	Définition & Échelle	Exemples Précis en Biochimie & Biologie
Quantitative continue	Valeurs numériques réelles sur une échelle continue mesurable.	Absorbance (A_{595}), Concentration protéique ($\mu\text{g/mL}$), Activité enzymatique ($\mu\text{mol/min/mg}$), pH, Glycémie.
Quantitative discrète	Nombres entiers résultant d'un comptage strict.	Nombre de colonies bactériennes (UFC), comptage de leucocytes sur cellule de Malassez, nombre de métastases.
Qualitative nominale	Catégories disjointes sans hiérarchie ni relation d'ordre.	Génotype (Sauvage WT vs Muté KO), Sexe (M/F), Type d'organe (Foie, Rein, Rate), Statut sérologique (+ / -).
Qualitative ordinale	Modalités qualitatives possédant un ordre naturel ou gravité.	Stade de fibrose hépatique (F0, F1, F2, F3, F4), intensité de bande Western blot (–, +, ++, +++).

 Piège Fréquent en Biologie : Attention au Choix des Tests !

Structuration Rigoureuse d'un Tableau de Données (*Tidy Data*)

Définition / Concept Clé : Les 3 Règles d'Or du Format Tidy

Pour être analysable sous Python/R sans erreur :

1. Chaque **ligne** représente un individu biologique unique (N).
2. Chaque **colonne** représente une seule variable biologique ou expérimentale.
3. Chaque **cellule** contient une valeur unique (pas de texte mélangé aux chiffres, ex: « 12.4 » et non « 12.4 mg »).

Piège Fréquent en Biologie : Les Pièges Fréquents sous Excel

- ▶ Cellules fusionnées empêchant la lecture automatique.
- ▶ Données réparties en multiples tableaux côte à côte.
- ▶ Virgule décimale française (,) au lieu du point (.) international.
- ▶ Valeurs manquantes codées par « ND » ou « 0 » au lieu d'un blanc (NaN).

Paramètres de Tendence Centrale : Moyenne, Médiane, Mode

📄 Définition / Concept Clé : 1. La Moyenne ($\bar{X}$)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Avantage : Utilise 100% de l'information numérique.

Faiblesse : Très sensible aux valeurs extrêmes (outliers).

🧪 Cas Pratique Biochimie : 2. La Médiane (Med)

Valeur qui sépare l'échantillon ordonné en deux moitiés égales (50% au-dessus, 50% au-dessous).

Avantage : Statistique **robuste**, insensible aux valeurs aberrantes de pipetage.

📄 Définition / Concept Clé : 3. Le Mode (Mo)

Valeur la plus fréquemment observée dans l'échantillon.

Usage : Particulièrement utile pour les variables discrètes ou catégorielles (ex: pic de prévalence).

💡 Message Clé à Retenir : Moyenne vs Médiane

Lorsque la distribution est parfaitement symétrique (loi normale), Moyenne = Médiane = Mode.

Dès que la distribution est asymétrique, la moyenne est « tirée » vers la queue de distribution,

alors que la médiane reste stable.

Moyenne vs. Médiane face aux Asymétries Biologiques

Cas Pratique Biochimie : Cas Réel : Dosage d'Interleukine-6 (IL-6)

Chez 10 patients atteints d'un choc septique, les taux sériques d'IL-6 (pg/mL) mesurés sont :

12, 14, 15, 18, 20, 22, 25, 28, 35, **1250**

► **Moyenne** : $\bar{X} = 142.9$ pg/mL

► **Médiane** : $Med = 21.0$ pg/mL

⇒ La moyenne (142.9) ne reflète la réalité d'aucun patient ! 90% des patients ont un taux < 35 . La médiane (21.0) traduit fidèlement le niveau central du groupe.

Définition / Concept Clé : Règle de Décision Pédagogique



Quand utiliser la Moyenne ?

- Distribution symétrique (Gaussienne).
- Tests paramétriques (ANOVA, Student).

Quand utiliser la Médiane ?

- Distribution asymétrique (cytokines, qPCR $2^{-\Delta\Delta C_t}$, expression génique).
- Présence d'outliers non rejetables.
- Tests non paramétriques (Mann-Whitney).

Illustration Graphique : Tendence Centrale & Asymétrie



💡 Message Clé à Retenir : Impact Visuel

Sur la distribution asymétrique positive (à droite), observez comment le mode (2.0), la médiane (2.0) et la moyenne (2.65) se dissocient nettement.

Paramètres de Dispersion : Variance & Écart-Type

📄 Définition / Concept Clé : Variance d'Échantillon (s^2)

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

Pourquoi diviser par $n - 1$? (Bessel)

- ▶ La moyenne vraie μ est inconnue ; on utilise $\bar{X}$ estimée sur l'échantillon.
- ▶ $\sum (X_i - \bar{X})^2$ est mathématiquement plus petite que $\sum (X_i - \mu)^2$.
- ▶ Diviser par $n - 1$ compense exactement cette sous-estimation : s^2 devient un **estimateur sans biais** de σ^2 .

📄 Définition / Concept Clé : Écart-Type d'Échantillon (SD)

$$SD = s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}}$$

Signification biologique :

- ▶ S'exprime dans la **même unité** que la variable biologique mesurée (mg/mL, μ M, absorbance).
- ▶ Quantifie l'étendue réelle de dispersion des individus biologiques autour de la moyenne.
- ▶ **Ne diminue pas** lorsque n augmente !

Écart-Type (SD) vs. Erreur Standard (SEM) : Quelle Différence ?

📄 Définition / Concept Clé : 1. L'Écart-Type (SD)

$$SD = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n - 1}}$$

Rôle : Décrit la **dispersion biologique** des individus.

- ▶ Répond à : « À quel point les animaux ou échantillons sont-ils différents entre eux ? »
- ▶ Reste stable quand la taille n augmente.
- ▶ Indispensable pour caractériser une population.



📄 Définition / Concept Clé : 2. L'Erreur Standard (SEM)

$$SEM = \frac{SD}{\sqrt{n}}$$

Rôle : Mesure la **précision de l'estimation** de la moyenne.

- ▶ Répond à : « Quelle est l'incertitude sur la position de la moyenne vraie μ ? »
- ▶ **Diminue** proportionnellement à $1/\sqrt{n}$.
- ▶ Sert à construire les intervalles de confiance et à comparer deux groupes.

Illustration Graphique : SD vs. SEM



💡 Message Clé à Retenir : Règle Internationale de Publication

► **Rapporter un groupe biologique** : Indiquer $\bar{X} \pm SD$ (ex : rats témoins : 41.2 ± 3.1 g/L).

► **Comparer l'effet de deux traitements** : Indiquer $\bar{X} \pm SEM$ ou mieux, l'Intervalle de

Indicateurs Complémentaires : Quartiles, IQR & Coefficient de Variation

📄 Définition / Concept Clé : Quartiles & Écart Interquartile (*IQR*)

- ▶ Q_1 (25%) : 25% des données sont inférieures.
- ▶ Q_2 (50%) : La médiane.
- ▶ Q_3 (75%) : 75% des données sont inférieures.
- ▶ **Écart Interquartile :**

$$IQR = Q_3 - Q_1$$

- ▶ Englobe les **50% centraux** de l'échantillon. Insensible aux valeurs aberrantes !



🧪 Cas Pratique Biochimie : Coefficient de Variation (*CV%*)

$$CV = \frac{SD}{\bar{X}} \times 100\%$$

Contrôle Qualité & Répétabilité Analytique :

- ▶ Mesure la dispersion relative sans dimension.
- ▶ Permet de comparer la précision de deux techniques n'ayant pas la même unité.
- ▶ **Norme laboratoire :**
 - ▶ $CV < 5\%$: Excellente répétabilité (ELISA intra-essai, spectrophotométrie)

Visualisation Graphique : Anatomie du Boxplot de Tukey



Définition / Concept Clé : La Règle de Tukey pour les Valeurs Aberrantes (*Outliers*)

Une valeur X est considérée comme suspecte si elle dépasse les limites des moustaches :

Qu'est-ce qu'une Probabilité en Sciences du Vivant ?

Définition / Concept Clé : Définition & Axiomes Fondamentaux

Pour une expérience biologique aléatoire (prélèvement, réaction enzymatique, génotypage) dans l'univers Ω :

1. Une probabilité est comprise entre 0 et 1 :

$$0 \leq P(A) \leq 1$$

2. La probabilité de l'événement certain vaut 1 : $P(\Omega) = 1$.
3. Si deux événements A et B sont disjoints (incompatibles) :

$$P(A \cup B) = P(A) + P(B)$$

Cas Pratique Biochimie : Interprétation Fréquentiste

En biologie expérimentale, $P(A)$ représente la **fréquence relative limite** d'apparition de l'événement A si l'on répétait l'expérience un très grand nombre de fois dans des conditions identiques :

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

Exemple : La probabilité qu'un souriceau issu d'un croisement hétérozygote $Aa \times Aa$ soit albinos (aa) est $P = 0.25$ (loi mendélienne).

Probabilités Conditionnelles & Événements Indépendants

📄 Définition / Concept Clé : Probabilité Conditionnelle $P(A|B)$

Probabilité que l'événement A se produise **sachant que l'événement B est déjà réalisé** :

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (\text{avec } P(B) > 0)$$

$\Rightarrow$ Modifie l'univers des possibles en se restreignant à B .

$$\Rightarrow P(A \cap B) = P(B) \times P(A|B)$$

🧪 Cas Pratique Biochimie : Indépendance Biologique

Deux événements A et B sont dits **statistiquement indépendants** si la réalisation de B n'apporte aucune information sur A :

$$P(A|B) = P(A) \iff P(A \cap B) = P(A) \times P(B)$$

Cas biologique : La ségrégation de deux gènes portés par deux chromosomes différents (absence de liaison génétique / *linkage*).

⚠️ Piège Fréquent en Biologie : Attention au Piège du Conditionnement

Le Théorème de Bayes au Cœur du Diagnostic Biologique

📖 Définition / Concept Clé : Théorème de Bayes

Permet de réviser la probabilité d'une maladie (M) après avoir obtenu le résultat d'un test biologique (T) :

$$P(M^+|T^+) = \frac{P(T^+|M^+) \cdot P(M^+)}{P(T^+)} = \frac{P(T^+|M^+) \cdot P(M^+)}{P(T^+|M^+)P(M^+) + P(T^+|M^-)P(M^-)}$$

🧪 Cas Pratique Biochimie : Paramètres Intrinsèques du Test

- **Sensibilité (Se)** : Probabilité que le test soit positif si le sujet est malade.

$$Se = P(T^+|M^+) \quad (\text{Vrais Positifs})$$

- **Spécificité (Sp)** : Probabilité que le

🧪 Cas Pratique Biochimie : Valeurs Prédictives Cliniques

- **Valeur Prédictive Positive (VPP)** : Probabilité d'être réellement malade si le test est positif.

$$VPP = P(M^+|T^+)$$

- **Valeur Prédictive Négative (VPN)**

Le Paradoxe des Tests Rares en Épidémiologie & Dépistage

Cas Pratique Biochimie : Exemple Chiffré Frappant

On teste un biomarqueur précoce du cancer du pancréas :

- ▶ Sensibilité du test : $Se = 99\%$
- ▶ Spécificité du test : $Sp = 99\%$
- ▶ Prévalence de la maladie dans la population : $P(M^+) = 0.1\%$ (1 individu sur 1000).

Un patient reçoit un test **POSITIF**. Quelle est la probabilité réelle qu'il ait ce cancer ?

Application de Bayes sur 100 000 personnes :

- ▶ 100 malades $\Rightarrow$ 99 tests positifs ($Se = 99\%$).
- ▶ 99 900 personnes saines $\Rightarrow 1\% \times 99\,900 = 999$ **faux positifs** !
- ▶ Total des tests positifs : $99 + 999 = 1098$.

$$VPP = \frac{99}{1098} \approx 9.0\%$$

Message Clé à Retenir : Leçon Biologique

Même avec un test excellent (99% de précision), **plus de 90% des tests positifs sont des faux positifs** car la maladie est rare !

$\Rightarrow$ Ne jamais interpréter un résultat de laboratoire sans connaître la **préva-**

Variables Aléatoires Discrètes vs. Continues

📄 Définition / Concept Clé : 1. Variable Aléatoire Discrète

Ne prend que des valeurs entières isolées ($k \in \mathbb{N}$).

- ▶ Caractérisée par sa **fonction de probabilité** :

$$P(X = k) \quad \text{avec} \quad \sum_k P(X = k) = 1$$

- ▶ **Espérance** : $\mathbb{E}(X) = \sum k \cdot P(X = k)$
- ▶ **Lois clés** : Binomiale, Poisson.

📄 Définition / Concept Clé : 2. Variable Aléatoire Continue

Prend une infinité non dénombrable de valeurs réelles ($x \in \mathbb{R}$).

- ▶ Caractérisée par sa **densité de probabilité** $f(x)$:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

- ▶ **Attention** : La probabilité d'une valeur exacte est nulle :
 $P(X = a) = 0$.
- ▶ **Lois clés** : Normale, Student, Fisher.

La Loi Binomiale $\mathcal{B}(n, p)$: Les Processus Oui / Non

Définition / Concept Clé : Définition & Formule

Modélise le nombre de succès k parmi n essais biologiques indépendants, où chaque essai a une probabilité constante de succès p :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1 - p)^{n-k}$$

Espérance : $\mathbb{E}(X) = n \cdot p$ **Variance :** $\text{Var}(X) = n \cdot p \cdot (1 - p)$

Cas Pratique Biochimie : Applications Fréquentes en Biologie

- ▶ Nombre de souris survivantes après injection létale ($n = 10, p = 0.3$).
- ▶ Nombre d'embryons porteurs d'un allèle récessif ($p = 0.25$).

Message Clé à Retenir : Propriété Remarquable

Lorsque le nombre d'essais n est grand et p n'est ni trop proche de 0 ni de 1 ($np \geq 5$ et $n(1 - p) \geq 5$), la loi binomiale s'approche parfaitement d'une **loi normale** :

La Loi de Poisson $\mathcal{P}(\lambda)$: La Loi des Événements Rares

📄 Définition / Concept Clé : Définition & Formule

Modélise le nombre d'événements k survenant dans un intervalle de temps, d'espace ou de volume continu, lorsque les événements sont indépendants et ont un taux moyen constant λ :

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad (k = 0, 1, 2, \dots)$$

Propriété Signature Unique : L'espérance est strictement égale à la variance !

$$\mathbb{E}(X) = \text{Var}(X) = \lambda$$

🧪 Cas Pratique Biochimie : Applications Clés de Laboratoire

- ▶ Comptage d'UFC bactériennes par boîte de Petri à forte dilution.

- ▶ Nombre de mutations spontanées par

⚠️ Piège Fréquent en Biologie : Le Test de Poisson

Si dans un comptage expérimental, la variance observée s^2 est nettement supérieure à la moyenne $\bar{X}$ ($s^2 \gg \bar{X}$), il y a **sur-dispersion** (overdispersion). Les bactéries

La Loi Normale de Gauss $\mathcal{N}(\mu, \sigma^2)$: La Reine des Distributions

☰ Définition / Concept Clé : Densité de Probabilité Gaussienne

La célèbre courbe en cloche, parfaitement symétrique autour de sa moyenne μ :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (x \in \mathbb{R})$$

☰ Définition / Concept Clé : Standardisation (Centrage-Réduction)

Toute variable normale $X \sim \mathcal{N}(\mu, \sigma^2)$ se transforme en **Loi Normale Centrée Réduite** $Z \sim \mathcal{N}(0, 1)$ par :

$$Z = \frac{X - \mu}{\sigma}$$

Permet d'utiliser une seule table universelle

🧪 Cas Pratique Biochimie : Pourquoi est-elle Partout en Biologie ?

De nombreux paramètres biologiques (taille, poids, glycémie, pression artérielle) résultent de l'addition d'une multitude de facteurs génétiques et environnementaux indépendants de faible intensité.

La Règle Empirique des 68% – 95% – 99.7%

Définition / Concept Clé : Les 3 Intervalles Fondamentaux

Pour toute distribution normale $\mathcal{N}(\mu, \sigma^2)$:

- ▶ **68.3%** des individus se trouvent dans l'intervalle :

$$[\mu - 1\sigma, \mu + 1\sigma]$$

- ▶ **95.4%** ($\approx 95\%$) des individus dans :

$$[\mu - 1.96\sigma, \mu + 1.96\sigma] \approx [\mu - 2\sigma, \mu + 2\sigma]$$

- ▶ **99.7%** des individus dans :

$$[\mu - 3\sigma, \mu + 3\sigma]$$

Cas Pratique Biochimie : Application aux Valeurs Usuelles de Référence

En biologie médicale, les « normes de laboratoire » remises aux patients sont définies par l'intervalle :

$$\text{Normes} = [\bar{X} - 2SD, \bar{X} + 2SD]$$

⇒ Par définition mathématique, **5% des personnes parfaitement saines** ont un résultat « hors normes » (2.5% trop bas, 2.5% trop haut) !

Le Théorème Central Limite (TCL) : Le Miracle Statistique

📄 Définition / Concept Clé : Énoncé Fondamental du TCL

Soit une population quelconque, possédant une moyenne μ et une variance σ^2 , **quelle que soit sa distribution de départ** (asymétrique, exponentielle, bimodale, uniforme) :

La distribution de la moyenne $\bar{X}_n$ d'un échantillon aléatoire de taille n tend vers une **loi normale** lorsque n grandit :

$$\bar{X}_n \xrightarrow{n \rightarrow \infty} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{soit} \quad Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \rightarrow \mathcal{N}(0, 1)$$


🧪 Cas Pratique Biochimie : Conséquence Pratique Immense

En pratique, dès que $n \geq 30$, la moyenne d'échantillon se comporte comme une variable normale, même si les mesures biologiques individuelles ne sont pas normales

💡 Message Clé à Retenir : Justification des Tests Classiques

Le TCL est la raison exacte pour laquelle les tests statistiques basés sur la moyenne (Student, ANOVA) sont robustes et largement applicables en biologie.

Illustration Graphique : Le Théorème Central Limite en Action



💡 Message Clé à Retenir : Visualisation de la Convergence

À gauche : population d'origine fortement asymétrique (durée de survie cellulaire exponentielle).
Au milieu ($n = 5$) : l'asymétrie s'atténue. À droite ($n = 30$) : la distribution des moyennes d'échantillon épouse parfaitement la courbe de Gauss normale !

Les Lois Dérivées d'Échantillonnage : χ^2 , Student t , Fisher F

📖 Définition / Concept Clé : 1. Loi du χ^2 (Chi-deux)

Somme des carrés de k variables normales centrées réduites :

$$\chi^2 = \sum_{i=1}^k Z_i^2$$

Usage : Tests d'indépendance de tableaux de contingence, conformité mendélienne.

📖 Définition / Concept Clé : 2. Loi de Student (t)

Quotient d'une variable normale par la racine d'un chi-deux :

$$t = \frac{Z}{\sqrt{\chi^2/ddl}}$$

Usage : Comparaison de deux moyennes lorsque la variance vraie σ^2 est inconnue et estimée par s^2 .

📖 Définition / Concept Clé : 3. Loi de Fisher (F)

Rapport de deux variances indépendantes :

$$F = \frac{s_1^2}{s_2^2} = \frac{\chi_1^2/ddl_1}{\chi_2^2/ddl_2}$$

Usage : L'épine dorsale de l'**ANOVA** (comparaison de variances) et des régressions !

Le Principe Fondamental de l'Estimation Statistique

Définition / Concept Clé : Estimation Ponctuelle

Consiste à attribuer à un paramètre inconnu de la population (μ, σ^2) une valeur unique calculée sur l'échantillon :

- ▶ μ est estimé par la moyenne d'échantillon $\bar{X}$.
- ▶ σ^2 est estimé par la variance corrigée s^2 .

Inconvénient majeur : Ne fournit aucune indication sur l'incertitude et la marge d'erreur liée à l'échantillonnage !

Cas Pratique Biochimie : Estimation par Intervalle de Confiance

Fournit une plage de valeurs crédibles $[L_{inf}, L_{sup}]$ susceptible de contenir le paramètre vrai inconnu avec un niveau de confiance choisi à l'avance (habituellement 95%) :

$$P(\mu \in [L_{inf}, L_{sup}]) = 1 - \alpha = 0.95$$

⇒ Combine la meilleure estimation et l'imprécision expérimentale en un seul chiffre.

Construction Interprétation de l'Intervalle de Confiance à 95%

☰ Définition / Concept Clé : Formule Générale de l'IC à 95% de la Moyenne

Lorsque la variance de la population est inconnue (cas de 100% des études biologiques) :

$$IC_{95\%}(\mu) = \left[\bar{X} - t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}} \right] = \bar{X} \pm t_{\alpha/2, n-1} \cdot SEM$$

Où $t_{\alpha/2, n-1}$ est la valeur critique de la loi de Student à $n - 1$ degrés de liberté (pour $n \geq 30$, $t \approx 1.96 \approx 2$).

⚠ Piège Fréquent en Biologie : Ce que signifie « 95% de confiance »

Si vous répétiez cette expérience 100 fois en prélevant 100 échantillons indépendants et en calculant 100 intervalles : **95 d'entre eux contiendraient la vraie moyenne** μ ,

💡 Message Clé à Retenir : Ce que cela NE signifie PAS !

« Il y a 95% de chances que μ soit dans cet intervalle ».

⇒ **FAUX !** La moyenne vraie μ est une constante fixe (non aléatoire). C'est l'intervalle qui est aléatoire et qui fluctue

Règle d'Or : Intervalles de Confiance & Prise de Décision

Cas Pratique Biochimie : L'IC de la Différence entre 2 Groupes

Soit $\Delta = \mu_A - \mu_B$ la différence d'efficacité entre un groupe Traité et un Témoin :

$$IC_{95\%}(\mu_A - \mu_B) = (\bar{X}_A - \bar{X}_B) \pm t \cdot SEM_{diff}$$

Règle Décisionnelle Équivalente au Test t :

- ▶ Si l'IC à 95% **inclut la valeur 0** (ex : $[-1.2, +3.4]$) : La différence **n'est pas significative** ($p > 0.05$).
- ▶ Si l'IC à 95% **exclut 0** (ex : $[+2.1, +6.8]$) : L'effet est **statistiquement significatif** ($p < 0.05$).

Message Clé à Retenir : Le Piège du Chevauchement des Barres

- ▶ Si deux barres d'erreur en SEM se chevauchent : on ne peut rien conclure sans calcul formel.
- ▶ Si deux Intervalles de Confiance à 95% ne se chevauchent absolument pas : la différence est **garantie significative** à $p < 0.01$!

Le Raisonnement par l'Absurde du Test Statistique

Définition / Concept Clé : 1. Formulation des Deux Hypothèses

En démarche scientifique, on ne peut jamais prouver directement qu'un traitement est actif. On démontre que **l'hypothèse d'inactivité est hautement improbable** :

- ▶ H_0 (**Hypothèse Nulle**) : « Aucun effet du traitement »
($\mu_{\text{Traité}} = \mu_{\text{Témoin}}$). Toute différence observée n'est due qu'au hasard d'échantillonnage.
- ▶ H_1 (**Alternative**) : « Il existe un effet réel » ($\mu_{\text{Traité}} \neq \mu_{\text{Témoin}}$).


Cas Pratique Biochimie : Cas Concret en Enzymologie

On étudie l'inhibition d'une protéase tumorale par une molécule X à $10 \mu\text{M}$:

$$H_0 : \text{Activité}_{\text{Inhibiteur}} = \text{Activité}_{\text{Contrôle}}$$

Si la baisse d'activité mesurée au spectrophotomètre est tellement spectaculaire qu'elle a moins de 5% de chances d'être le fruit du hasard pur, **on rejette** H_0 et on affirme que la molécule est inhibitrice !

Les Deux Risques d'Erreur : α , β et Puissance Statistique



Décision du Chercheur	Réalité : H_0 est Vraie (Pas d'effet)	Réalité : H_0 est Fausse (Effet réel)
Rejet de H_0 (Effet affirmé)	Erreur de Type I (α , Faux Positif)	Décision Correcte (Puissance $1 - \beta$)
Non-rejet de H_0 (Pas d'effet)	Décision Correcte ($1 - \alpha$)	Erreur de Type II (β , Faux Négatif)

Démystification Rigoureuse de la p -value

📖 Définition / Concept Clé : Définition Formelle Exacte

La **p -value** est la probabilité d'observer un résultat au moins aussi extrême que celui obtenu expérimentalement, **sous l'hypothèse où le traitement n'a absolument aucun effet (H_0 vraie)**.

$p \leq \alpha (0.05) \implies$ Événement rarissime sous $H_0 \implies$ Rejet de H_0 (Différence significative).

⚠️ Piège Fréquent en Biologie : Les 3 Idées Fausses des Biologistes

1. « $p = 0.02$ signifie qu'il y a 98% de chances que mon traitement fonctionne » $\implies$ **FAUX !**
(Confusion avec le théorème bayésien).
2. « $p > 0.05$ prouve que les deux groupes sont identiques » $\implies$ **FAUX !**
(Absence de preuve n'est pas

💡 Message Clé à Retenir : Seuil $\alpha = 0.05$: Une Convention Historique

Fixé par Ronald Fisher en 1925 : « 1 chance sur 20 de se tromper ». Ce n'est pas une loi physique de la nature ! Une p -value de 0.049 et de 0.051 décrivent quasiment la même réalité biologique.

Significativité Statistique vs. Pertinence Biologique

📄 Définition / Concept Clé : Le Rôle de la Taille d'Échantillon (n)

La statistique de test dépend de la taille de l'effet et de $\sqrt{n}$:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s/\sqrt{n}}$$

- ▶ Avec $n = 10\,000$ souris, une baisse de glycémie infinitésimale de 0.02 g/L sera statistiquement ultra-significative ($p < 0.0001$). Mais cliniquement inutile !
- ▶ Avec $n = 3$, une baisse majeure de 50% peut ne pas être significative

🧪 Cas Pratique Biochimie : La Taille de l'Effet (*Effect Size*)

Toujours rapporter le d **de Cohen** :

$$d = \frac{\bar{X}_1 - \bar{X}_2}{s_{\text{pool}}}$$

- ▶ $d = 0.2$: Effet faible.
- ▶ $d = 0.5$: Effet modéré.
- ▶ $d \geq 0.8$: Effet biologique majeur !

⇒ La p -value dit si l'effet existe ; la taille de l'effet dit s'il a de l'importance biologique.

Les 3 Postulats Obligatoires des Tests Paramétriques

☰ Définition / Concept Clé : 1. Indépendance

Les observations proviennent d'unités biologiques indépendantes.

- ▶ Pas de pseudo-réplication.
- ▶ Respect du protocole expérimental et randomisation des cages et puits.

☰ Définition / Concept Clé : 2. Normalité

Les données (ou les résidus du modèle) suivent une loi normale.

- ▶ **Test de Shapiro-Wilk**
($p > 0.05 \Rightarrow$ Normalité acceptée).
- ▶ **Graphe Q-Q plot** : points alignés sur la diagonale.

☰ Définition / Concept Clé : 3. Homoscédasticité

Les variances des différents groupes sont égales ($\sigma_1^2 = \sigma_2^2 = \dots$).

- ▶ **Test de Levene** ou de **Bartlett**
($p > 0.05 \Rightarrow$ Variances homogènes).

⚠ Piège Fréquent en Biologie : Que faire si les postulats ne sont pas respectés ?

Deux solutions : 1) Transformer les données (log, racine carrée) pour normaliser, ou 2) Utiliser les tests non paramétriques.

Stratégies de Transformation & Tests Non Paramétriques

Cas Pratique Biochimie : 1. Transformations de Variables

- ▶ **Transformation Logarithmique**
 $\log_{10}(X)$: Idéale pour les données asymétriques positives, concentrations d'anticorps, qPCR ($2^{-\Delta\Delta Ct}$). Rétablit la normalité et stabilise la variance !
- ▶ **Transformation Racine Carrée** $\sqrt{X}$
: Indiquée pour les données de comptage (Poisson, colonies UFC, cellules).

Définition / Concept Clé : 2. Tests Non Paramétriques (Sur Rangs)

Ne supposent aucune loi de distribution sous-jacente :

- ▶ **Mann-Whitney / Wilcoxon** :
Remplace le test t de Student pour 2 groupes indépendants.
- ▶ **Kruskal-Wallis** : Remplace l'ANOVA à un facteur pour ≥ 3 groupes.
- ▶ **Corrélation de Spearman** :
Remplace Pearson pour des relations non linéaires.

Arbre Décisionnel Universel : Choisir le Bon Test Statistique

Question Biologique	Conditions Paramétriques Réunies	Postulats Non Respectés / Petit n
Comparer 2 groupes indépendants (ex: Témoin vs Traité)	Test t de Student pour échantillons indépendants	Test U de Mann-Whitney (Wilcoxon rank-sum)
Comparer 2 mesures sur même individu (Avant / Après)	Test t de Student apparié	Test des rangs signés de Wilcoxon
Comparer ≥ 3 groupes avec 1 seul facteur (ex: 3 doses)	ANOVA à 1 facteur (One-way ANOVA)	Test de Kruskal-Wallis (+ post-hoc Dunn)
Comparer avec 2 facteurs croisés (ex: Traitement $\times$ Sexe)	ANOVA croisée à 2 facteurs (Two-way)	Modèles mixtes ou transformations
Liaison entre 2 variables quantitatives (ex: Ab	Corrélation de Pearson & Régression linéaire	Corrélation de Spearman (r_s)

Feuille de Route du Module de Biostatistiques (Master 2)

Partie I : Modélisation Linéaire Avancée

- ▶ **Chapitre I** : ANOVA croisée à 2 facteurs (effets principaux, interactions, synergie / antagonisme).
- ▶ **Chapitre II** : ANOVA hiérarchisée / *Nested* (séparation de la variabilité biologique et technique, contrôle qualité).
- ▶ **Chapitre III** : Régression linéaire & étalonnages analytiques (gammes BSA, limites LOD et LOQ).

Partie II : Modélisation Non Linéaire

- ▶ **Chapitre IV** : Cinétiques enzymatiques directes (Michaelis-Menten non linéaire vs Lineweaver-Burk, Hill, 4PL).

Partie III : Analyse de Données Multivariées

- ▶ **Chapitre V** : Analyse en Composantes Principales (ACP) sur profils métabolomiques et protéomiques.
- ▶ **Chapitre VI** : Classification Ascendante Hiérarchique (CAH) & Dendrogrammes / Heatmaps omiques.

Partie IV : Pratique & Travaux Dirigés

- ▶ **Chapitre VII** : Plan d'expérience, intégrité scientifique et communication des résultats.
- ▶ **Travaux Dirigés TP Python** : Exercices corrigés et notebooks interactifs Jupyter.

Fin du Chapitre 0

Généralités, Statistique Descriptive & Probabilités

Vous disposez désormais de tous les socles théoriques et décisionnels indispensables.

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie
Université M'Hamed Bougara de Boumerdès (UMBB)