

Biostatistiques Appliquées

Chapitre V : Analyse en Composantes Principales (ACP) & Profilage Multivarié

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Plan Détaillé du Chapitre V

L'Ère des Données Omiques & Multivariées

Axes Principaux & Inertie Expliquée

Interprétation Conjointe des Graphiques

Le Défi de la Haute Dimensionnalité

Définition / Concept Clé : La Matrice Biologique ($n \times p$)

En biochimie médicale et biotechnologie moderne :

- ▶ n échantillons ou patients (lignes).
- ▶ p biomarqueurs dosés simultanément (colonnes).

Un spectromètre de masse quantifie 40 à 200 métabolites par goutte de sérum. Impossible de regarder 40 graphiques un par un !

Cas Pratique Biochimie : Mission de l'ACP

Réduction non supervisée de dimension :

- ▶ Projeter le nuage de points de $\mathbb{R}^p$ vers un plan à 2 dimensions ($\mathbb{R}^2$).
- ▶ Conserver le **maximum de la variance biologique totale** (inertie).
- ▶ Identifier des signatures métaboliques caractéristiques d'états pathologiques.

L'Étape Obligatoire : Centrage et Réduction

⚠ Piège Fréquent en Biologie : L'Hétérogénéité des Unités de Mesure

Si l'on analyse dans un même tube :

- ▶ Cholestérol total (~ 2.1 g/L).
- ▶ ALAT (~ 45 UI/L).
- ▶ BCAA (~ 450 μ M).

Les acides aminés BCAA écraseraient numériquement les autres variables sans raison biologique valable !

💡 Message Clé à Retenir : La Transformation Standardisée (Z)

Chaque valeur est centrée et réduite :

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}$$

$\implies$ Chaque biomarqueur a désormais une moyenne égale à 0 et une variance égale à 1. Toutes les variables ont le **même poids de départ** dans l'ACP. On diagonalise la **matrice des corrélations**.

Valeurs Propres (λ_k) & Choix du Nombre d'Axes



📄 Définition / Concept Clé : Propriétés Mathématiques Clés

- ▶ Les composantes principales sont orthogonales (non corrélées entre elles).
- ▶ Chaque axe capte une quantité de variance appelée **valeur propre** λ_k .
- ▶ Inertie totale = nombre de variables p .
- ▶ Pourcentage de variance expliquée par l'axe k : $\frac{\lambda_k}{p} \times 100$.

Critère de Kaiser : Conserver uniquement les axes ayant $\lambda_k \geq 1$ (c'est-à-dire les axes qui expliquent plus de variance qu'une variable unitaire isolée).

Règle du Coude (Scree plot) : Identifier le point d'inflexion où la chute d'inertie se stabilise (le « coude » géologique).

Cercle des Corrélations & Plan des Patients



À gauche (Cercle des Corrélations) : Flèches proches

Dr. Sarra BENMOUMOU (Ph.D.)

≡ variables fortement corrélées (Glucose & Lactate).

Biostatistiques — M2 Biochimie (UMBB)

À droite (Plan des Patients) : Séparation parfaite des

Temoins (vert), Diabétiques (bleu sur l'Axe 1) et des

6 / 8

Règles d'Or de Lecture du Cercle des Corrélations

Configuration Géométrique	Lien Statistique	Interprétation Biologique Concrète
Angle aigu ($< 90^\circ$)	$r > 0$ (Forte corrélation positive)	Biomarqueurs régulés de concert par la même voie métabolique (ex: Glucose et Triglycérides).
Angle droit ($\approx 90^\circ$)	$r \approx 0$ (Indépendance)	Mécanismes physiopathologiques totalement distincts (ex: Transaminases ALAT et Glycémie à jeun).
Angle plat ($\approx 180^\circ$)	$r < 0$ (Forte corrélation négative)	Relation d'antagonisme ou compensation métabolique (ex: Baisse du HDL protecteur quand le glucose s'envole).
Longueur de flèche ($\cos^2 \rightarrow 1$)	Qualité de représentation maximale	La variable est parfaitement interprétable sur ce plan factoriel.

Fin du Chapitre V

Prochaine étape : Classification Hiérarchique Ascendante (CAH)

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie

Université M'Hamed Bougara de Boumerdès (UMBB)