

Biostatistiques Appliquées

Chapitre VI : Classification Hiérarchique Ascendante (CAH) & Dendrogrammes

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Plan Détaillé du Chapitre VI

Objectifs de la CAH en Biologie

Distances & Critères d'Agrégation

Le Dendrogramme & Les Heatmaps

La Classification Non Supervisée

Définition / Concept Clé : Définition & Philosophie

Contrairement aux modèles prédictifs guidés :

- ▶ Les groupes d'individus ou de biomolécules ne sont **pas connus à l'avance**.
- ▶ L'algorithme cherche à regrouper les entités les plus ressemblantes de manière ascendante (du bas vers le haut).
- ▶ Fournit une représentation sous forme d'arbre : le **Dendrogramme**.

Cas Pratique Biochimie : Applications Clés en Biochimie

- ▶ **Microbiologie** : Sous-typage de souches bactériennes d'après leurs profils enzymatiques et antibiogrammes.
- ▶ **Oncologie Moléculaire** : Identification de nouveaux sous-types de cancers à partir de biomarqueurs protéiques.
- ▶ **Génomique** : Regroupement de gènes co-exprimés ou co-régulés.

1. Mesures de Dissimilarité Biologique

📖 Définition / Concept Clé : Distance Euclidienne

$$d(x, y) = \sqrt{\sum_{k=1}^p (x_k - y_k)^2}$$

- ▶ Mesure géométrique classique.
- ▶ Très sensible aux unités absolues (exige des données **préalablement centrées-réduites**).

📖 Définition / Concept Clé : Distance de Corrélation


$$d_{\text{cor}}(x, y) = 1 - r(x, y)$$

- ▶ Regroupe les protéines ou gènes ayant la **même cinétique temporelle**, même si l'amplitude basale est très différente.
- ▶ Essentielle pour l'analyse d'expression génique.

2. Critères d'Agrégation (Méthodes de Liaison)

Méthode	Principe Mathématique de Fusion	Comportement Biologique
Lien Simple	Distance minimale entre deux éléments des groupes	Tendance fâcheuse au « chaînage » (regroupe les points isolés en filaments).
Lien Complet	Distance maximale entre deux éléments	Forme des groupes très compacts et sphériques.
Lien Moyen (UPGMA)	Moyenne arithmétique de toutes les distances croisées	Standard historique de la phylogénie moléculaire.
Méthode de Ward	Fusionne les deux groupes qui minimisent la perte d'inertie intra-groupe (ΔI_{intra})	Recommandée en biochimie pour obtenir des groupes homogènes et équilibrés.

Lecture du Dendrogramme & Seuil de Coupure



Hauteur des branches : Représente le niveau de dissemblance entre sous-groupes fusionnés. Plus la branche verticale est longue, plus la séparation biologique est franche.

Ligne de coupure horizontale : Choisie au niveau du saut d'inertie le plus grand. Ici, le trait rouge délimite parfaitement **3 clusters cliniques distincts** ($k=3$).

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Définition / Concept Clé : Le Double Clustering Simultané

La Heatmap moderne croise deux CAH indépendantes :

1. **En colonnes** : Classification des biomarqueurs ou gènes (identifie les réseaux métaboliques co-activés).
2. **En lignes** : Classification des échantillons ou patients (isole les phénotypes pathologiques).

Cas Pratique Biochimie : Cas Réel : Résistance aux Antibiotiques

Chez 15 souches de *Pseudomonas aeruginosa* testées sur 12 molécules :

La heatmap regroupe visuellement les souches multi-résistantes exprimant simultanément une β -lactamase à spectre étendu (BLSE) et des pompes d'efflux.

Fin du Chapitre VI

Prochaine étape : Interprétation d'une Analyse Expérimentale

Dr. Sarra BENMOUMOU (Ph.D.)

Faculté des Sciences — Département de Biologie
Université M'Hamed Bougara de Boumerdès (UMBB)