

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : **Biostatistiques Appliquées & Plans d'Expériences**

color BioNavy

Année 2024 – 2025

 Dr. S. BENMOUMOU

Enseignante Responsable

**SÉRIE
D'EXERCICES****Travaux Dirigés : Série 07****Interprétation d'une Analyse Expérimentale, DoE & Bonnes Pratiques** **Exercice 1 : Calcul de Puissance Statistique ($1 - \beta$) & Détermination d'Effectif (N)**

Une équipe de biochimie souhaite tester l'effet hépatoprotecteur d'une nouvelle molécule antioxydante chez le rat. D'après les données de la littérature :

- Le taux moyen de MDA hépatique chez les animaux témoins est $\mu_1 = 8.5 \mu\text{mol/g}$, avec un écart-type $s = 2.0 \mu\text{mol/g}$.
- L'équipe considère qu'une baisse du MDA à $\mu_2 = 6.5 \mu\text{mol/g}$ ($\Delta = 2.0 \mu\text{mol/g}$) représente une amélioration biologique cliniquement pertinente.
- Le risque d'erreur de première espèce est fixé à $\alpha = 0.05$ (test bilatéral, $Z_{\alpha/2} = 1.960$).
- La puissance statistique souhaitée est de $1 - \beta = 80\%$ ($Z_\beta = 0.842$).

Questions :

- Calculez la taille d'effet standardisée (d de Cohen) : $d = \frac{|\mu_1 - \mu_2|}{s}$. S'agit-il d'un effet faible (0.2), modéré (0.5) ou fort (0.8) ?
- Calculez le nombre d'animaux requis par groupe (n) selon la formule standard :

$$n = \frac{2 \cdot (Z_{\alpha/2} + Z_\beta)^2}{d^2}$$

- Si l'expérimentateur décide arbitrairement de n'utiliser que $n = 3$ rats par groupe (pour économiser des animaux), quelle sera approximativement la puissance statistique de son étude ($< 25\%$) ?
- Expliquez le concept de la « malédiction du vainqueur » (*winner's curse*) : pourquoi les rares études sous-dimensionnées qui franchissent par hasard le seuil $p < 0.05$ surestiment-elles dramatiquement l'efficacité réelle du traitement ?

 Exercice 2 : Détection des Pratiques Douteuses (p -hacking, HARKing, Arrêt Précoce)

Dans un laboratoire de recherche, un jeune chercheur teste l'effet d'une cytokine sur 20 paramètres métaboliques chez 8 souris traitées et 8 souris témoins. **Questions :**

- a. Si les 20 paramètres sont testés indépendamment par des tests t au seuil $\alpha = 0.05$, quelle est la probabilité d'obtenir au moins un résultat « significatif » par pur hasard sous H_0 : $\alpha_{\text{global}} = 1 - (1 - 0.05)^{20}$?
- b. Le chercheur constate que seule la variable n°14 a un $p = 0.038$. Il décide d'écrire son article en faisant comme si cette variable était son unique hypothèse de départ. Quel nom donne-t-on à cette pratique trompeuse (HARKing) et quel est son danger ?
- c. Un autre chercheur analyse ses données après 4 souris : $p = 0.08$. Il ajoute 2 souris : $p = 0.06$. Il ajoute 2 souris : $p = 0.045$, et s'arrête immédiatement en publiant. Quel est le biais d'« arrêt précoce » (*data peeking*) ?
- d. Quelle correction classique (Bonferroni ou Benjamini-Hochberg FDR) doit être appliquée lorsqu'on analyse simultanément de multiples métabolites ?

Exercice 3 : Transparence Graphique & Remplacement des Barplots « Dynamite »

Pendant des décennies, la littérature biologique a représenté les données quantitatives sous forme d'histogrammes en barres pleines surmontées d'une barre d'erreur (« dynamite plots »).

Questions :

- a. Pour quelles raisons scientifiques majeures les revues internationales de premier rang (*Nature*, *Cell*, *PLOS Biology*) interdisent-elles désormais les barplots pour les échantillons continus de petite taille ($n < 30$) ?
- b. Montrez qu'une barre pleine avec $\bar{x} = 25$ et $SD = 5$ peut dissimuler deux distributions biologiques radicalement différentes :
 - Cas 1 : Distribution normale symétrique homogène.
 - Cas 2 : Distribution bimodale (deux sous-populations distinctes : non-répondeurs à 15 et hyper-répondeurs à 35).
- c. Quels sont les éléments anatomiques clés d'un **Boxplot** de Tukey (ligne médiane, boîte interquartile, moustaches, points aberrants) ?
- d. Pourquoi la superposition de tous les points réels (*Scatter / Jitter plot*) par-dessus le boxplot est-elle le standard absolu de transparence ?

Exercice 4 : Audit de Conformité aux Directives SAMPL & ARRIVE 2.0

On vous soumet pour relecture critique le paragraphe suivant extrait d'un manuscrit soumis à une revue de biochimie :

« Les souris ont été divisées en lots. L'activité enzymatique a été mesurée. Les résultats montrent une augmentation significative sous traitement ($p < 0.05$). Les données ont été analysées avec le logiciel GraphPad. »

Questions :

- a. Selon le guide **SAMPL** (Statistiques dans la littérature biomédicale), relevez au moins 4 manquements graves dans ce paragraphe.
- b. Selon les directives **ARRIVE 2.0** (expérimentation animale *in vivo*), quelles informations obligatoires sur la randomisation, la mise en aveugle et la taille des groupes font

défaut ?

- c. Pourquoi l'expression « $p < 0.05$ » doit-elle être bannie au profit de la valeur numérique exacte (ex: $p = 0.023$) et assortie de la taille d'effet et de l'intervalle de confiance à 95% ?

Exercice 5 : Rédaction d'un Paragraphe « Analyses Statistiques » pour Mémoire

Vous finalisez votre mémoire de Master 2 portant sur l'évaluation d'un antioxydant naturel dans un modèle de stéatose hépatique chez le rat. Votre travail combine :

- Dosage des protéines par la méthode de Bradford (gamme étalon linéaire).
- Mesure du stress oxydatif (MDA) par ANOVA à deux facteurs croisés (Statut $\times$ Traitement, $n = 6$) suivie du test de Tukey HSD.
- Analyse non supervisée du profil de 8 métabolites sériques par ACP normée.
- Vérification de la normalité (Shapiro-Wilk) et de l'homogénéité des variances (Levene).

Questions :

- a. Rédigez un paragraphe complet (15 à 20 lignes), rigoureux, clair et publiable pour la section « Matériels & Méthodes » de votre mémoire.
- b. Précisez la manière exacte dont les données seront présentées dans les tableaux et figures (ex: Moyenne $\pm$ SD ou Médiane [IQR]).
- c. Mentionnez les outils logiciels utilisés pour le traitement des données (Python, bibliothèques scientifiques).