

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : **Biostatistiques Appliquées & Plans d'Expériences**

color BioNavy

Année 2024 – 2025

 Dr. S. BENMOUMOU

Enseignante Responsable

**SÉRIE
D'EXERCICES**

Travaux Dirigés : Série 06

Classification Ascendante Hiérarchique (CAH)

Exercice 1 : Métriques de Distance & Matrice de Dissimilarité (RT-qPCR)

Le niveau d'expression relative ($\Delta\Delta Ct$, en unité arbitraire) de 2 gènes de résistance (G_1 : efflux, G_2 : β -lactamase) est mesuré chez 4 isolats bactériens hospitaliers (S_1, S_2, S_3, S_4) :

Isolat Bactérien	S_1	S_2	S_3	S_4
Gène G_1 (Efflux)	1.0	2.0	5.0	6.0
Gène G_2 (β -lactamase)	2.0	1.0	5.0	4.0

Questions :

- Rappelez les formules de la distance euclidienne $d_E(A, B) = \sqrt{\sum (x_{Ai} - x_{Bi})^2}$ et de la distance de Manhattan $d_M(A, B) = \sum |x_{Ai} - x_{Bi}|$.
- Calculez les distances euclidiennes entre toutes les paires d'isolats : $d(S_1, S_2)$, $d(S_1, S_3)$, $d(S_1, S_4)$, $d(S_2, S_3)$, $d(S_2, S_4)$ et $d(S_3, S_4)$.
- Dressez la matrice de dissimilarité triangulaire inférieure D_0 (4×4).
- Quels sont les deux premiers isolats qui vont fusionner lors de la première étape de l'algorithme de CAH ?

Exercice 2 : Stratégies de Liaison (Linkage Methods) & Critère de Ward

Soient deux sous-groupes d'échantillons déjà formés : $C_1 = \{S_1, S_2\}$ et $C_2 = \{S_3, S_4\}$. **Questions :**

- Définissez les quatre méthodes d'agrégation usuelles pour calculer la distance entre deux groupes $D(C_1, C_2)$:
 - Saut minimum (*Single Linkage*) : $D_{\min} = \min d(x_i, y_j)$.
 - Saut maximum (*Complete Linkage*) : $D_{\max} = \max d(x_i, y_j)$.
 - Lien moyen (*Average Linkage* / UPGMA) : $D_{\text{avg}} = \frac{1}{|C_1||C_2|} \sum d(x_i, y_j)$.
 - Critère de Ward (*Minimum Variance Method*).
- À partir des distances calculées à l'Exercice 1, calculez la distance $D(C_1, C_2)$ selon le Single Linkage, le Complete Linkage et l'Average Linkage.
- Quel est le défaut majeur du Single Linkage en biologie (phénomène de « chaînage » / *chaining effect*) ?

- d. Pourquoi la méthode de Ward est-elle la référence absolue en biochimie et médecine ? Que minimise-t-elle exactement ?



Exercice 3 : Fusion Pas-à-Pas & Construction du Dendrogramme

On applique le critère de Ward sur les données des 4 isolats (S_1, S_2, S_3, S_4). L'augmentation d'inertie intra-classe lors de la fusion de deux clusters A et B d'effectifs n_A et n_B et de centres de gravité g_A et g_B est donnée par :

$$\Delta I(A, B) = \frac{n_A \cdot n_B}{n_A + n_B} d_E^2(g_A, g_B)$$

Questions :

- Étape 1 :** Calculez $\Delta I(S_1, S_2)$ sachant que $d_E^2(S_1, S_2) = (2 - 1)^2 + (1 - 2)^2 = 2.0$.
- Étape 2 :** Calculez $\Delta I(S_3, S_4)$ sachant que $d_E^2(S_3, S_4) = (6 - 5)^2 + (4 - 5)^2 = 2.0$. Les deux premiers clusters formés sont donc $C_1 = \{S_1, S_2\}$ et $C_2 = \{S_3, S_4\}$.
- Calculez les barycentres g_1 du groupe C_1 et g_2 du groupe C_2 .
- Étape 3 :** Calculez le saut d'inertie $\Delta I(C_1, C_2)$ lors de la fusion finale des deux groupes.
- Dessinez schématiquement le dendrogramme obtenu en graduant l'axe vertical des ordonnées avec les valeurs d'indice de dissimilarité / inertie (ΔI).



Exercice 4 : Détermination du Seuil de Coupure & Profilage des Classes

À partir du dendrogramme construit à l'Exercice 3 : **Questions :**

- Où doit-on positionner la ligne de coupure horizontale pour obtenir la partition la plus stable et pertinente biologiquement ?
- Quel est le nombre optimal de clusters (k) suggéré par le saut d'inertie majeur ?
- Calculez le profil biologique moyen de chaque classe (moyennes des gènes G_1 et G_2 dans le Groupe 1 et dans le Groupe 2).
- Caractérisez cliniquement les deux groupes d'isolats : lequel correspond à des souches bactériennes sensibles et lequel correspond à des souches super-résistantes hospitalières ?



Exercice 5 : Lecture & Interprétation d'une Clustermap (Heatmap Bi-Clusterisée)

Dans une étude métabolomique sur 30 sérums de patients testés sur 20 acides aminés et lipides, l'équipe génère une Clustermap via le package `seaborn.clustermap`. **Questions :**

- Pourquoi une Clustermap comporte-t-elle **deux dendrogrammes distincts** (l'un au-dessus des colonnes, l'autre à gauche des lignes) ?
- Que permet d'identifier le dendrogramme horizontal situé en colonnes ?
- Que permet d'identifier le dendrogramme vertical situé en lignes ?
- Si l'on observe un bloc compact rouge vif (surexpression) à l'intersection du cluster de

patients 2 et d'un cluster d'enzymes hépatiques (ALAT, ASAT, PAL), quelle conclusion physiopathologique immédiate le biochimiste peut-il en déduire ?