

Biostatistiques Appliquées & Modélisation du Vivant

Chapitre 0 : Généralités sur les Statistiques, Probabilités & Démarche Expérimentale

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

September 23, 2026

Plan Pédagogique du Chapitre 0

📖 Définition / Concept Clé : Fondements Biostatistiques pour le Master 2

Ce chapitre établit les bases mathématiques et conceptuelles indispensables :

- ▶ **Section 1** : La Démarche Biostatistique & la Variabilité Intrinsèque du Vivant
- ▶ **Section 2** : Typologie des Données du Laboratoire & Formatage *Tidy Data*
- ▶ **Section 3** : Statistique Descriptive (Moyenne, Médiane, SD, SEM, IQR, Boxplot de Tukey)
- ▶ **Section 4** : Fondements des Probabilités & Théorème de Bayes dans le Diagnostic
- ▶ **Section 5** : Grandes Lois de Probabilité (Binomiale, Poisson, Normale) & TCL
- ▶ **Section 6** : Inférence Statistique & Intervalles de Confiance à 95%
- ▶ **Section 7** : Logique des Tests d'Hypothèses, Risques α/β & p -value
- ▶ **Section 8** : Conditions d'Application des Tests & Arbre Décisionnel

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

La Nature Intrinsèque du Vivant : Pourquoi les Statistiques ?

Définition / Concept Clé : Déterminisme Chimique versus Stochastique Biologique

En chimie minérale, des réactifs identiques donnent des résultats déterministes. En biologie :

Mêmes conditions expérimentales $\nRightarrow$ Résultats strictement identiques

Deux souris de même portée (C57BL/6) recevant la même molécule présenteront des réponses physiologiques distinctes (rythmes nycthéméraux, statut épigénétique).

Cas Pratique Biochimie : Rôle Vital de la Biostatistique pour le Biochimiste

La statistique fournit le cadre objectif pour :

- ▶ **Quantifier l'incertitude biologique** sans la masquer par de simples moyennes.
- ▶ **Isoler le signal thérapeutique réel** du bruit de fond aléatoire.
- ▶ **Prendre une décision rigoureuse** sur l'efficacité d'un traitement avec risque contrôlé.

L'Équation Fondamentale de la Mesure Expérimentale

Définition / Concept Clé : Décomposition Universelle de Toute Mesure de Laboratoire

Toute valeur numérique Y_i mesurée au laboratoire (spectrophotométrie, ELISA, qPCR) s'écrit :

$$Y_i = \underbrace{\mu}_{\text{Signal Vrai Inconnu}} + \underbrace{b}_{\text{Biais Systématique}} + \underbrace{\varepsilon_i}_{\text{Fluctuation Aléatoire (Bruit)}}$$

Cas Pratique Biochimie : Application au Dosage du Glucose Sérique (Glucose Oxydase)

- ▶ $\mu = 1.00 \text{ g/L}$: La glycémie physiologique réelle de l'animal.
 - ▶ $b = +0.08 \text{ g/L}$: Biais instrumental (spectrophotomètre mal mis à zéro).
 - ▶ $\varepsilon_i = \pm 0.02 \text{ g/L}$: Imprécisions de micropipetage et fluctuations thermiques.
- ⇒ La démarche expérimentale élimine le biais b (BPL) et modélise la variance de ε_i .

Variabilité Biologique (Inhérente) vs. Variabilité Technique (Artefact)

Définition / Concept Clé : Deux Sources d'Incertitude de Natures Distinctes

L'expérimentateur doit impérativement distinguer la biologie de l'artefact instrumental :

Critère	Variabilité Biologique (Inhérente)	Variabilité Technique (Artefact)
Origine	Génome, épigénétique, âge, statut hormonal.	Imprécision pipette, dérive optique, réactifs.
Statut	L'objet de la découverte scientifique !	Bruit parasite indésirable.
Action	On estime sa distribution dans l'espèce.	À éliminer par les Bonnes Pratiques (BPL).

Message Clé à Retenir : Règle d'Or

Répéter 10 fois le pipetage réduit l'erreur technique, mais n'informe pas sur la diversité biologique !

Réplicats Biologiques (N) versus Réplicats Techniques (k)

📖 Définition / Concept Clé : La Définition Exacte de l'Effectif de l'Échantillon (N)

La statistique inférentielle exige des unités expérimentales **strictement indépendantes** :

- ▶ **✓ Réplicats Biologiques (N)** : Animaux distincts, donneurs indépendants, extractions cellulaires séparées. $\Rightarrow$ **Seule base valide de calcul de N .**
- ▶ **✗ Réplicats Techniques (k)** : Mesures répétées sur le même échantillon (ex : triplicat ELISA du sérum du rat n°1, $k = 3$).

⚠ Piège Fréquent en Biologie : Le Piège de la Pseudoréplication

Doser 2 souris dans 5 puits chacune donne un effectif biologique de $N = 2$, et non $N = 10$!
Traiter les 10 mesures comme indépendantes dans un test t constitue une faute grave qui gonfle artificiellement les degrés de liberté et génère des faux positifs massifs.

De la Population Cible à l'Échantillon Expérimental

Définition / Concept Clé : Le Principe Fondamental de l'Inférence Statistique

On étudie un échantillon aléatoire pour extrapoler les conclusions à une population cible :



Cas Pratique Biochimie : Conditions Impératives de Validité

- ▶ **Représentativité** : Les animaux inclus doivent être représentatifs de l'espèce cible.
- ▶ **Randomisation** : Attribution aléatoire des lots pour neutraliser les facteurs de confusion.
- ▶ **Indépendance** : La mesure d'un animal n'influence en rien celle d'un autre.

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Les Données Quantitatives Continues

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **quantitative continue** si elle peut prendre théoriquement toute valeur réelle sur un intervalle de $\mathbb{R}$. Elle possède une unité physique mesurable.

Cas Pratique Biochimie : Exemples Clés au Laboratoire de Biochimie

- ▶ Absorbance spectrophotométrique à 595 nm (gamme Bradford) : 0.452, 0.458 DO.
- ▶ Concentration sérique d'albumine : 41.25 g/L.
- ▶ Vitesse initiale d'une enzyme : $v_0 = 12.4 \mu\text{mol} \cdot \text{min}^{-1} \cdot \text{mg}^{-1}$.
- ▶ Expression relative par RT-qPCR : $2^{-\Delta\Delta C_t} = 3.42$.

⇒ Analysées par statistiques paramétriques (Moyenne, *SD*, *SEM*, Test *t*, ANOVA).

Les Données Quantitatives Discrètes

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **quantitative discrète** lorsqu'elle ne prend que des **valeurs entières dénombrables** ($\mathbb{N}$), résultant d'un processus de comptage d'occurrences.

Cas Pratique Biochimie : Exemples Clés en Microbiologie & Toxicologie

- ▶ Nombre de colonies bactériennes (UFC) dénombrées sur boîte de gélose ($k = 0, 1, 2, \dots$).
- ▶ Nombre de métastases pulmonaires après induction tumorale ($k = 7$ nodules).
- ▶ Nombre de cellules sanguines comptées sur cellule de Malassez.
- ▶ Nombre d'épisodes d'hypoglycémie enregistrés par an.

⇒ Modélisées par la loi de Poisson $\mathcal{P}(\lambda)$ ou loi Binomiale Négative.

Les Données Qualitatives Nominales

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **qualitative nominale** lorsque ses modalités correspondent à des **catégories sans relation d'ordre** ni hiérarchie numérique.

Cas Pratique Biochimie : Exemples Biologiques Réels

- ▶ **Génotype d'un modèle murin** : Sauvage (WT), Hétérozygote (+/-), Knock-Out (KO).
- ▶ **Sexe biologique des animaux** : Mâle vs Femelle.
- ▶ **Localisation cellulaire** : Nucléaire, Cytosolique, Mitochondriale, Membranaire.
- ▶ **Groupe sanguin érythrocytaire** : A, B, AB, O.

⇒ Analysées par tableaux de contingence, test du χ^2 et test exact de Fisher.

Les Données Qualitatives Ordinales

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **qualitative ordinale** lorsque ses catégories possèdent un **ordre intrinsèque**, mais dont la distance numérique entre échelons n'est pas mesurable.

Cas Pratique Biochimie : Exemples Médicaux & Histologiques

- ▶ **Score de fibrose hépatique (Métavir)** : F0 (absence), F1, F2, F3, F4 (cirrhose).
- ▶ **Intensité de coloration immunohistochimique** : Nulle (0), Faible (+), Forte (+++).
- ▶ **Échelle de douleur ou tolérance** : Mineure, Modérée, Sévère.

Règle clé : Interdiction de calculer une moyenne ! Utiliser la **médiane** et les tests non paramétriques de rangs (Mann-Whitney, Kruskal-Wallis).

Structuration Professionnelle des Données : Le Format *Tidy Data*

Définition / Concept Clé : Les 3 Principes de Wickham pour l'Analyse Informatique

Pour être exploitable sans erreur sous Python/Pandas ou GraphPad : **1.** Chaque ligne = 1 individu unique. **2.** Chaque colonne = 1 variable. **3.** Chaque cellule = 1 valeur.

ID_Animal	Genotype	Traitement	Dose_mgkg	MDA_nmol_g	GPx_U_mg
RAT_01	Wild-Type	Curcumine	50	5.82	142.5
RAT_02	Wild-Type	Curcumine	50	6.14	138.2
RAT_03	db/db	Curcumine	200	8.45	95.4
RAT_04	db/db	Véhicule	0	14.20	62.1

Message Clé à Retenir : À Bannir

Éviter absolument les cellules fusionnées dans Excel et les blocs de données juxtaposés.

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Paramètres de Tendances Centrales : La Moyenne Arithmétique

Définition / Concept Clé : Définition & Formule Mathématique

La moyenne empirique $\bar{x}$ représente le barycentre gravitationnel de l'échantillon de taille n :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Piège Fréquent en Biologie : Vulnérabilité Majeure : Sensibilité Extrême aux Outliers

Soit la protéinémie de 5 tubes (en g/L) : 40, 42, 39, 41, 43 $\Rightarrow \bar{x} = 41.0$ g/L.

Si une bulle optique produit un artefact sur le 5^e tube (40, 42, 39, 41, **120**), la moyenne devient :

$$\bar{x} = 56.4 \text{ g/L}$$

La moyenne ne décrit plus aucun des animaux réels : elle a été déportée par l'aberrant !

Paramètres de Tendence Centrale : La Médiane

Définition / Concept Clé : Définition & Propriété de Robustesse

La médiane (Med) sépare l'échantillon ordonné en deux moitiés égales (50% au-dessus, 50% au-dessous) :

$$\text{Pour } n \text{ impair : Med} = x_{(\frac{n+1}{2})}, \quad \text{Pour } n \text{ pair : Med} = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

Cas Pratique Biochimie : L'Insensibilité Totale aux Valeurs Aberrantes

Sur notre série avec artefact : 39, 40, **41**, 42, **120**.

La médiane reste imperturbablement égale à **41.0 g/L** !

Que la dernière valeur soit 43 ou 1200 g/L, la médiane ne change pas. C'est l'indicateur de choix pour toutes les distributions asymétriques au laboratoire.

Paramètres de Tendence Centrale : Le Mode & Distributions Plurimodales

Définition / Concept Clé : Définition & Signification Biologique

Le **Mode** correspond à la valeur présentant la plus forte fréquence d'observation (sommet de la densité).


Cas Pratique Biochimie : Alerte Majeure : Les Distributions Bimodales

Si un biomarqueur tumoral présente **deux modes distincts**, cela révèle que l'échantillon n'est pas homogène, mais composé de **deux sous-populations distinctes** :

- ▶ **Mode 1** : Sous-clone sensible à la chimiothérapie (85% de mortalité cellulaire).
- ▶ **Mode 2** : Sous-clone résistant porteur d'une mutation de transporteur (10% de mortalité).

Calculer une moyenne globale masquerait complètement la résistance thérapeutique !

Visualisation HD : Moyenne vs. Médiane vs. Mode selon l'Asymétrie



💡 Message Clé à Retenir : Interprétation Clé

Normale (Gauche) : Symétrie parfaite $\implies$ Moyenne = Médiane = Mode.

Asymétrique (Droite, ex: IL-6) : Mode < Médiane < Moyenne. La moyenne est tirée vers la droite. Publiez impérativement la **Médiane** !

Paramètres de Dispersion : La Variance de Bessel (s^2)

Définition / Concept Clé : Formule Mathématique & Correction de Bessel ($n - 1$)

La variance quantifie la dispersion des observations individuelles autour de leur moyenne :

$$s^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Cas Pratique Biochimie : Pourquoi Divise-t-on par $n - 1$ et non par n ?

Dans l'échantillon, la vraie moyenne μ est inconnue et remplacée par $\bar{x}$. Or, les points x_i sont naturellement plus proches de $\bar{x}$ que de la vraie moyenne μ .

Diviser par n sous-estimerait la variance réelle de la population.

La division par $n - 1$ compense exactement cette perte d'un **degré de liberté** consommé par le calcul de $\bar{x}$.

Paramètres de Dispersion : L'Écart-Type (SD)

Définition / Concept Clé : Définition & Retour à l'Unité Physique d'Origine

L'écart-type est la racine carrée positive de la variance :

$$SD = s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Cas Pratique Biochimie : Signification Biologique Concrète

- ▶ Il exprime la **dispersion biologique intrinsèque** des individus au sein du groupe.
- ▶ Il possède la **même unité physique** que la variable brute ($\bar{x} \pm SD = 41.2 \pm 3.1 \text{ g/L}$).
- ▶ **Propriété clé** : L'écart-type SD **ne tend pas vers zéro** lorsque la taille de l'échantillon n augmente ! Il converge vers l'écart-type réel σ de la population.

Paramètre de Précision : L'Erreur Standard de la Moyenne (SEM)

📖 Définition / Concept Clé : Définition & Précision de l'Estimation


L'erreur standard quantifie **l'incertitude sur l'estimation de la moyenne $\bar{x}$** :

$$SEM = \frac{SD}{\sqrt{n}} = \frac{s}{\sqrt{n}}$$

⚠️ Piège Fréquent en Biologie : Mise en Garde Pédagogique

- ▶ Comme $SEM = SD/\sqrt{n}$, plus l'effectif n grandit, plus le SEM rétrécit vers zéro !
- ▶ Beaucoup d'auteurs publient le SEM pour avoir de petites barres d'erreur et masquer la variabilité.
- ▶ **Règle internationale** : Pour décrire la variabilité biologique, publiez le SD . Réservez le SEM pour la comparaison inférentielle de moyennes.

Visualisation HD : Écart-Type (SD) versus Erreur Standard (SEM)



💡 Message Clé à Retenir : Différence Visuelle

Gauche (SD) : Dispersion biologique individuelle ($\pm 1SD$ couvre 68%, $\pm 2SD$ couvre 95%).

Droite (SEM) : La distribution de la moyenne rétrécit drastiquement lorsque n grandit ($\propto 1/\sqrt{n}$).

Indicateurs Robustes : Quartiles & Écart Interquartile (*IQR*)

Définition / Concept Clé : Définition des Quartiles & Zone Centrale des 50% d'Individus

Les quartiles divisent la distribution ordonnée en 4 quarts : Q_1 (25%), Q_2 (Médiane, 50%), Q_3 (75%).

$$\mathbf{IQR} = Q_3 - Q_1 \quad (\text{Écart Interquartile : contient les 50\% d'individus centraux})$$

Cas Pratique Biochimie : Application au Laboratoire

Comme la médiane, l'*IQR* est **insensible aux valeurs aberrantes**. C'est l'indicateur obligatoire pour résumer des données non normales : Médiane [Q_1 ; Q_3].

Répétabilité Analytique : Le Coefficient de Variation ($CV\%$)

Définition / Concept Clé : Formule Relative de Dispersion


Le coefficient de variation exprime l'écart-type en pourcentage de la moyenne :

$$CV\% = \frac{SD}{\bar{x}} \times 100\% = \frac{s}{\bar{x}} \times 100\%$$

Cas Pratique Biochimie : Critères d'Acceptation selon les Bonnes Pratiques de Laboratoire (BPL)

- ▶ $CV < 5\%$: Dosage spectrophotométrique ou colorimétrique d'excellente répétabilité.
- ▶ $CV < 10\%$: Dosage immunologique ELISA validé.
- ▶ $CV > 15\%$: Imprécision analytique inacceptable : problème de pipetage ou d'étalonnage.

Visualisation HD : Anatomie Complète du Boxplot de Tukey



💡 Message Clé à Retenir : Règle de Détection Mathématique des Outliers de Tukey

Moustaches : Borne Basse = $Q_1 - 1.5 \times IQR$, Borne Haute = $Q_3 + 1.5 \times IQR$.
Tout point biologique au-delà des moustaches est un **outlier** potentiel devant être investigué.

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Qu'est-ce qu'une Probabilité en Sciences du Vivant ?

Définition / Concept Clé : L'Approche Fréquentiste de Kolmogorov

La probabilité $P(A)$ d'un événement biologique représente la fréquence relative limite d'apparition de cet événement lorsque l'expérience est répétée un grand nombre de fois :

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}, \quad 0 \leq P(A) \leq 1, \quad P(\Omega) = 1$$

Cas Pratique Biochimie : Application : Efficacité d'un Vecteur Viral de Transfection

Sur 1000 cellules exposées à un lentivirus GFP, 720 émettent une fluorescence verte :

$$P(\text{Transfection Réussie}) = \frac{720}{1000} = 0.72 \quad (72\%)$$

Probabilités Conditionnelles & Indépendance Génétique

Définition / Concept Clé : Définition Mathématique du Conditionnement

La probabilité conditionnelle $P(A \mid B)$ est la probabilité que A se produise sachant que B est déjà réalisé :

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \quad \Longleftrightarrow \quad P(A \cap B) = P(A \mid B) \cdot P(B)$$

Cas Pratique Biochimie : L'Indépendance Mendélienne en Génétique

Deux événements A et B sont **indépendants** si la réalisation de B n'influence pas A :

$$P(A \mid B) = P(A) \quad \Longleftrightarrow \quad P(A \cap B) = P(A) \times P(B)$$

Exemple : Transmission de 2 gènes sur 2 chromosomes distincts (3^e loi de Mendel).

Le Théorème de Bayes au Cœur du Diagnostic Biologique

Définition / Concept Clé : L'Inversion Probabiliste Fondamentale


Le clinicien veut savoir : quelle est la probabilité d'être malade sachant que le test ELISA est positif ?

$$P(M \mid +) = \frac{P(+ \mid M) \cdot P(M)}{P(+)} = \frac{\text{Sensibilité} \times \text{Prévalence}}{\text{Sensibilité} \times \text{Prévalence} + (1 - \text{Spécificité}) \times (1 - \text{Prévalence})}$$

Cas Pratique Biochimie : Indicateurs Clés de Performance Analytique

- ▶ **Sensibilité (Se)** : $P(+ \mid M) \implies$ capacité à détecter les vrais malades.
- ▶ **Spécificité (Sp)** : $P(- \mid \bar{M}) \implies$ capacité à déclarer négatifs les sujets sains.
- ▶ **VPP** : $P(M \mid +) \implies$ Valeur Prédictive Positive (probabilité d'être malade si testé positif).

Visualisation HD : Arbre du Test ELISA & Calcul de la VPP



💡 Message Clé à Retenir : Analyse de la Catastrophe des Faux Positifs

Sur 10 000 individus testés pour une maladie rare (1%) avec $Se = 99\%$ et $Sp = 95\%$:
Vrais Positifs = 99, mais Faux Positifs = 495 personnes saines déclarées positives !
 $\Rightarrow VPP = 99 / (99 + 495) = 16.7\%$ seulement ! Plus de 5 tests positifs sur 6 sont faux.

Le Paradoxe des Maladies Rares en Dépistage Clinique

Définition / Concept Clé : Pourquoi un Test à 99% Échoue-t-il sur une Maladie Rare ?

Lorsque la prévalence est très faible ($P(M) < 1\%$), l'immense majorité de la population est saine ($> 99\%$).

Même avec 1% de faux positifs, ce taux s'applique à un réservoir géant d'individus sains !

Le nombre absolu de faux positifs submerge alors complètement les quelques vrais malades.

Cas Pratique Biochimie : Conséquence Pédagogique Immédiate

Ne jamais dépister en masse sans sélection préalable des sujets à risque (symptômes évocateurs augmentant la prévalence pré-test).

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

La Loi Binomiale $\mathcal{B}(n, p)$: Les Processus de Bernoulli

Définition / Concept Clé : Modélisation des Événements Discrets Binaires (Succès / Échec)

Lorsqu'une expérience binaire de probabilité p est répétée n fois de façon indépendante :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad \mathbb{E}(X) = n \cdot p, \quad \mathbb{V}(X) = n \cdot p \cdot (1 - p)$$

Cas Pratique Biochimie : Exemples Clés au Laboratoire

- ▶ Nombre de puits positifs sur une plaque PCR à dilution limite ($n = 96, p = 0.25$).
- ▶ Taux de survie d'une culture cellulaire après 48h d'exposition à un cytotoxique.
- ▶ Transmission mendélienne d'un allèle récessif létal ($p = 0.25$).

La Loi de Poisson $\mathcal{P}(\lambda)$: Les Événements Rares

Définition / Concept Clé : Comptages d'Événements Rares dans l'Espace ou le Temps


Pour des événements indépendants se produisant à un taux moyen constant $\lambda > 0$:

$$P(X = k) = \frac{\lambda^k \cdot e^{-\lambda}}{k!} \quad \text{avec} \quad \mathbb{E}(X) = \lambda \quad \text{et} \quad \mathbb{V}(X) = \lambda$$

Cas Pratique Biochimie : Applications en Microbiologie & Génétique

- ▶ Nombre de colonies bactériennes (UFC) dénombrées par boîte de gélose.
- ▶ Nombre de mutations spontanées apparaissant par million de paires de bases.
- ▶ **Alerte** : Si la variance observée dépasse nettement la moyenne ($s^2 > \lambda$), il y a sur-dispersion (agrégation cellulaire ou pipetage défectueux).

Visualisation HD : Lois Discrètes Binomiale vs. Poisson



💡 Message Clé à Retenir : Différence Conceptuelle

Gauche (Binomiale) : Effectif n fixé à l'avance (ex: 20 puits). Bornée entre 0 et n .

Droite (Poisson) : Pas de plafond n fixé ; comptage d'occurrences sur un continuum.

La Loi Normale de Gauss $\mathcal{N}(\mu, \sigma^2)$: La Reine des Distributions

Définition / Concept Clé : Densité de Probabilité Continue Symétrique en Cloche

Une variable continue X suit une loi normale d'espérance μ et de variance σ^2 si :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

Elle est strictement symétrique autour de son sommet unique μ (Moyenne = Médiane = Mode).

Cas Pratique Biochimie : Pourquoi la Nature Aime-t-elle la Loi Normale ?

Toute grandeur biologique issue de la somme d'un grand nombre de facteurs microscopiques indépendants (multiples gènes, nutriments) adopte naturellement une forme de Gauss.

La Règle Empirique des 68% – 95% – 99.7% & Score Z

Définition / Concept Clé : Les Aires Fondamentales sous la Cloche de Gauss

Pour toute variable normale :

- ▶ $[\mu - 1\sigma ; \mu + 1\sigma]$ contient exactement **68.27%** de la population.
- ▶ $[\mu - 2\sigma ; \mu + 2\sigma]$ contient **95.45%** ($\pm 1.96\sigma$ contient exactement **95.00%**).
- ▶ $[\mu - 3\sigma ; \mu + 3\sigma]$ contient **99.73%** des individus.

Cas Pratique Biochimie : Centrage et Réduction : Le Score Z

La transformation $Z = \frac{X - \mu}{\sigma}$ standardise n'importe quelle mesure en $\mathcal{N}(0, 1)$.

Un patient avec un score $Z > +2$ se situe dans le top 2.5% supérieur (valeur anormale suspecte).

Le Théorème Central Limite (TCL) : Le Miracle de la Statistique

Définition / Concept Clé : Énoncé Fondamental du Théorème Central Limite

Soit un échantillon indépendant tiré d'une population de moyenne μ et de variance finie σ^2 , **quelle que soit sa loi d'origine** (asymétrique, exponentielle, discrète) :


$$\text{Quand } n \geq 30, \quad \bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

La distribution des **moyennes d'échantillons** converge vers une loi normale !

Message Clé à Retenir : Conséquence Pratique

Même avec des cellules individuelles asymétriques, la moyenne d'un groupe d'animaux ($n \geq 30$) est normale, justifiant l'usage des tests paramétriques.

Visualisation HD : Le Théorème Central Limite en Action



💡 Message Clé à Retenir : Démonstration Numérique

Gauche : Population de départ exponentielle asymétrique ($n = 1$).

Centre : Les moyennes de 5 mesures ($n = 5$) s'arrondissent déjà nettement.

Droite : Pour $n = 30$, les moyennes épousent parfaitement la courbe normale théorique !

Les Lois Dérivées d'Échantillonnage : χ^2 , Student t , Fisher F

Définition / Concept Clé : Les 3 Outils Mathématiques Dérivés de la Loi Normale

Ces trois distributions constituent le socle de tous les tests inférentiels :

Loi	Définition	Usage Clé en Biochimie
Khi-deux (χ^2_ν)	Somme de carrés de ν variables normales.	Conformité génétique (Mendel), contingence, variances.
Student (t_ν)	Moyenne divisée par son écart-type estimé.	Comparaison de 2 moyennes quand σ est inconnu.
Fisher (F_{ν_1, ν_2})	Rapport de deux variances indépendantes.	Comparaison de variances et statistique clé de l' ANOVA .

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Le Principe Fondamental de l'Estimation Statistique

Définition / Concept Clé : De l'Estimateur Ponctuel à la Zone de Confiance

Une moyenne calculée sur 10 rats ($\bar{x} = 2.45 \text{ g/L}$) est une estimation ponctuelle qui ne sera jamais égale à la vraie valeur μ de l'espèce.

La statistique remplace l'estimation ponctuelle par une **zone de plausibilité** :

$$\text{Intervalle de Confiance à 95\%} = [\bar{x} - \text{Marge d'Erreur} ; \bar{x} + \text{Marge d'Erreur}]$$

Cas Pratique Biochimie : Définition Fréquentiste Exacte

Si 100 laboratoires répètent l'expérience et calculent leur IC 95%, **exactement 95 intervalles engloberont la vraie moyenne μ** , et 5 la manqueront.

Construction Mathématique de l'Intervalle de Confiance à 95%

Définition / Concept Clé : Formule Basée sur la Loi de Student

Lorsque la variance vraie est inconnue :

$$\mathbf{IC}_{95\%} = \left[\bar{x} - t_{0.05/2, n-1} \cdot \frac{s}{\sqrt{n}} \quad ; \quad \bar{x} + t_{0.05/2, n-1} \cdot \frac{s}{\sqrt{n}} \right]$$

Cas Pratique Biochimie : Exemple Résolu : Catalase Sérique ($N = 25$)


$\bar{x} = 142.0 \text{ U/mg}$, $s = 20.0 \text{ U/mg} \implies SEM = 20/\sqrt{25} = 4.0 \text{ U/mg}$.

Pour 24 ddl au seuil 5%, la table donne $t_{0.025, 24} = 2.064$:

$$IC_{95\%} = [142.0 - 2.064 \times 4.0 ; 142.0 + 2.064 \times 4.0] = [\mathbf{133.74} ; \mathbf{150.26 \text{ U/mg}}]$$

Confiants à 95% que l'activité vraie de la population est entre 133.7 et 150.3 U/mg.

Visualisation HD : Simulation de 25 Intervalles de Confiance à 95%



💡 Message Clé à Retenir : Analyse Visuelle

Gauche : 24 intervalles en vert capturent bien $\mu = 100$. Le 13^e en rouge manque μ (aléa du risque 5%).

Droite : Plus la taille N grandit, plus l'incertitude se resserre en $1/\sqrt{N}$.

Règle d'Or : Intervalles de Confiance & Prise de Décision

 Définition / Concept Clé : Comment Juger d'une Différence sans Même Faire de Test t ?

L'examen visuel des deux intervalles de confiance permet de statuer immédiatement :

- ▶ **Aucun chevauchement entre les deux IC 95%** : La différence est **statistiquement significative** au seuil $p < 0.05$.
- ▶ **Les IC 95% se chevauchent modérément** : Un test formel (Student) est requis pour obtenir la p -value exacte.
- ▶ **L'IC 95% de la différence contient 0** : L'effet du traitement n'est pas significatif.

 Message Clé à Retenir : Recommandation Éditoriale

Nature et *Science* exigent les IC 95% car ils informent sur la **significativité** et sur la **taille de l'effet**.

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Le Raisonnement par l'Absurde du Test Statistique

Définition / Concept Clé : La Structure Fondamentale de Neyman-Pearson

La science procède par **falsification et raisonnement par l'absurde** :

- ▶ **Hypothèse Nulle (H_0)** : Le traitement n'a aucun effet réel ($\mu_{\text{Traité}} = \mu_{\text{Témoin}}$).
- ▶ **Hypothèse Alternative (H_1)** : Le traitement modifie la réponse ($\mu_{\text{Traité}} \neq \mu_{\text{Témoin}}$).

Message Clé à Retenir : Démarche

On calcule la probabilité d'observer nos données **en supposant H_0 vraie**. Si cette probabilité est inférieure au seuil critique $\alpha = 0.05$, on déclare H_0 absurde et on la **rejette en faveur de H_1** .

La Matrice de Décision : Risques α , β et Puissance ($1 - \beta$)

Définition / Concept Clé : Les 4 Issues Possibles de Tout Test Statistique


La décision du biologiste est confrontée à la vérité biologique :

Décision Prise	H_0 Vraie (Pas d'effet)	H_1 Vraie (Effet réel)
Rejeter H_0 (Effet conclu)	Erreur Type I (α) Faux Positif (seuil fixé à 5%)	Décision Correcte (Puissance $1 - \beta$) Détection de l'effet (visée $\geq 80\%$)
Conserver H_0 (Pas d'effet)	Décision Correcte ($1 - \alpha$) Spécificité (95%)	Erreur Type II (β) Faux Négatif (effet manqué)

Cas Pratique Biochimie : Application

Erreur α : Déclarer active une molécule inefficace. **Erreur β** : Abandonner un bon candidat faute de rats suffisants.

Visualisation HD : Distributions H_0 et H_1 , Risques & Puissance



💡 Message Clé à Retenir : Analyse Visuelle de la Décision

Zone Rouge ($\alpha = 5\%$) : Extrême droite sous H_0 (rejet à tort).

Zone Orange (β) : Sous H_1 à gauche du seuil (échec de détection).

Zone Verte ($1 - \beta$) : Sous H_1 au-delà du seuil (puissance statistique réelle).

Démystification Rigoureuse de la p -value

📖 Définition / Concept Clé : Définition Exacte de l'American Statistical Association (ASA)

La p -value est la probabilité d'obtenir un résultat au moins aussi extrême que celui observé, **en supposant que H_0 est rigoureusement vraie** :

$$p\text{-value} = P(\text{Données observées ou plus extrêmes} \mid H_0 \text{ vraie})$$

⚠️ Piège Fréquent en Biologie : Les 3 Pièges Mortels à Éviter

1. **Faux** : « $p = 0.03$ signifie 97% de chances que le médicament marche ». $\implies p$ ne quantifie JAMAIS $P(H_1)$!
2. **Faux** : « $p = 0.03$ signifie 3% de chances que H_0 soit vraie ». $\implies H_0$ n'est pas une variable aléatoire !
3. **Faux** : « $p = 0.08$ prouve l'équivalence ». $\implies$ L'absence de preuve n'est pas la preuve de l'absence !

Significativité Statistique ($p < 0.05$) vs. Pertinence Biologique

📄 Définition / Concept Clé : Le Paradoxe des Grands Effectifs

Comme $t = \frac{\bar{x}_1 - \bar{x}_2}{s/\sqrt{n}}$, quand $n \rightarrow \infty$, $t \rightarrow \infty$ et $p \rightarrow 0$!

Avec 100 000 souris, un écart minuscule de glycémie (0.001 g/L) sera $p < 0.0001$ sans avoir aucun intérêt biologique.

🧪 Cas Pratique Biochimie : La Solution : Quantifier la Taille d'Effet (d de Cohen)

$$d = \frac{\bar{x}_1 - \bar{x}_2}{SD_{\text{pooled}}} \quad (d = 0.2 : \text{faible}, \quad d = 0.5 : \text{moyen}, \quad d \geq 0.8 : \text{fort})$$

Accompagnez toujours la p -value de la taille d'effet et de l'intervalle de confiance.

Progression Pédagogique du Cours

La Démarche Biostatistique et la Variabilité du Vivant

Typologie des Données du Laboratoire et Formatage Tidy Data

Statistique Descriptive et Paramètres Fondamentaux

Fondements des Probabilités et Diagnostic Biologique

Grandes Lois de Probabilité et Théorème Central Limite

Inférence Statistique et Intervalles de Confiance à 95%

Logique des Tests d'Hypothèses et p-value

Conditions d'Application et Arbre Décisionnel Universel

Les 3 Postulats Obligatoires des Tests Paramétriques

Définition / Concept Clé : Le Contrat Mathématique Préalable

Avant de lancer un test t , une ANOVA ou une régression :

1. **Indépendance des Mesures** : Pas de pseudoréplication (contrôle par randomisation).
2. **Normalité des Résidus** : Distribution gaussienne.
⇒ Contrôle par test de **Shapiro-Wilk** ($p > 0.05$ requis) et diagramme Q-Q plot.
3. **Homoscédasticité** : Égalité des variances entre groupes.
⇒ Contrôle par test de **Levene** ($p > 0.05$ requis).

Que Faire en Cas de Violation des Postulats ?

Définition / Concept Clé : Deux Stratégies Disponibles

Si vos données de laboratoire violent la normalité ou l'égalité des variances :

► Option A : La Transformation Mathématique


- Données asymétriques à droite (concentrations, cytokines) : $Y' = \log_{10}(Y)$.
- Données de comptage (Poisson) : $Y' = \sqrt{Y}$.
- Proportions ou pourcentages : $Y' = \arcsin(\sqrt{Y})$.

► Option B : Les Tests Non Paramétriques (Basés sur les Rangs)

- Remplacent les valeurs par leur rang de classement ($1^{\text{er}}, 2^{\text{e}}, \dots$).
- Parfaitement insensibles aux asymétries et aux outliers.

Visualisation HD : Arbre Décisionnel Universel des Tests Biologiques

Arbre Décisionnel Fondamental en Biostatistiques (Master 2)



💡 Message Clé à Retenir : Règle de Sélection Instantanée

2 Groupes Indépendants : Student t (Paramétrique) $\longleftrightarrow$ Mann-Whitney U (Non-Paramétrique).

≥ 3 Groupes : ANOVA (Paramétrique) $\longleftrightarrow$ Kruskal-Wallis (Non-Paramétrique).

Feuille de Route du Module de Biostatistiques Appliquées

Définition / Concept Clé : Progression Didactique des 7 Chapitres Suivants

Forts des concepts de variabilité, d'inférence et d'hypothèses acquis dans ce Chapitre 0 :

- ▶ **Chapitre 1 : ANOVA à Deux Facteurs Croisés** $\Rightarrow$ Interactions et synergies médicamenteuses.
- ▶ **Chapitre 2 : ANOVA Hiérarchisée (Nested)** $\Rightarrow$ Neutraliser les bioréacteurs et réplicats.
- ▶ **Chapitre 3 : Régression Linéaire** $\Rightarrow$ Gammes étalons (Bradford), limites LOD / LOQ.
- ▶ **Chapitre 4 : Régression Non Linéaire** $\Rightarrow$ Michaelis-Menten et modèles sigmoïdes 4PL.
- ▶ **Chapitre 5 : Analyse en Composantes Principales (ACP)** $\Rightarrow$ Omiques et réduction dimensionnelle.
- ▶ **Chapitre 6 : Classification Ascendante Hiérarchique (CAH)** $\Rightarrow$ Dendrogrammes.
- ▶ **Chapitre 7 : Interprétation Avancée & Présentation Graphique** $\Rightarrow$ Publications internationales.

Merci de votre attention !

Place aux Travaux Dirigés (Série 00) & Travaux Pratiques Python

Portail officiel & Simulateur Interactif :
<https://hosniadilemp-a11y.github.io/BioStat/>

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.) — Université de Boumerdès (UMBB)