

Biostatistiques Appliquées & Modélisation du Vivant

Chapitre 0 : Généralités sur les Statistiques, Probabilités & Démarche Expérimentale

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Plan Pédagogique du Chapitre 0

Définition / Concept Clé : Fondements Biostatistiques pour le Master 2

Ce chapitre établit les bases mathématiques et conceptuelles indispensables :

- ▶ **Section 1** : La Démarche Biostatistique & la Variabilité Intrinsèque du Vivant
- ▶ **Section 2** : Typologie des Données du Laboratoire & Formatage *Tidy Data*
- ▶ **Section 3** : Statistique Descriptive (Moyenne, Médiane, SD, SEM, IQR, Boxplot de Tukey)
- ▶ **Section 4** : Fondements des Probabilités & Théorème de Bayes dans le Diagnostic
- ▶ **Section 5** : Grandes Lois de Probabilité (Binomiale, Poisson, Normale) & TCL
- ▶ **Section 6** : Inférence Statistique & Intervalles de Confiance à 95%
- ▶ **Section 7** : Logique des Tests d'Hypothèses, Risques α/β & p -value
- ▶ **Section 8** : Conditions d'Application des Tests & Arbre Décisionnel

La Nature Intrinsèque du Vivant : Pourquoi les Statistiques ?

Définition / Concept Clé : Déterminisme Chimique versus Stochastique Biologique

En chimie minérale, des réactifs identiques donnent des résultats déterministes. En biologie :

Mêmes conditions expérimentales $\nRightarrow$ Résultats strictement identiques

Deux souris de même portée (C57BL/6) recevant la même molécule présenteront des réponses physiologiques distinctes (rythmes nycthémeraux, statut épigénétique).

Cas Pratique Biochimie : Rôle Vital de la Biostatistique pour le Biochimiste

La statistique fournit le cadre objectif pour :

- ▶ **Quantifier l'incertitude biologique** sans la masquer par de simples moyennes.
- ▶ **Isoler le signal thérapeutique réel** du bruit de fond aléatoire.
- ▶ **Prendre une décision rigoureuse** sur l'efficacité d'un traitement avec risque contrôlé.

L'Équation Fondamentale de la Mesure Expérimentale

Définition / Concept Clé : Décomposition Universelle de Toute Mesure de Laboratoire

Toute valeur numérique Y_i mesurée au laboratoire (spectrophotométrie, ELISA, qPCR) s'écrit :

$$Y_i = \underbrace{\mu}_{\text{Signal Vrai Inconnu}} + \underbrace{b}_{\text{Biais Systématique}} + \underbrace{\varepsilon_i}_{\text{Fluctuation Aléatoire (Bruit)}}$$

Cas Pratique Biochimie : Application au Dosage du Glucose Sérique (Glucose Oxydase)

- ▶ $\mu = 1.00 \text{ g/L}$: La glycémie physiologique réelle de l'animal.
 - ▶ $b = +0.08 \text{ g/L}$: Biais instrumental (spectrophotomètre mal mis à zéro).
 - ▶ $\varepsilon_i = \pm 0.02 \text{ g/L}$: Imprécisions de micropipetage et fluctuations thermiques.
- ⇒ La démarche expérimentale élimine le biais b (BPL) et modélise la variance de ε_i .

Variabilité Biologique (Inhérente) vs. Variabilité Technique (Artefact)

Définition / Concept Clé : Deux Sources d'Incertitude de Natures Distinctes

L'expérimentateur doit impérativement distinguer la biologie de l'artefact instrumental :

Critère	Variabilité Biologique (Inhérente)	Variabilité Technique (Artefact)
Origine	Génome, épigénétique, âge, statut hormonal.	Imprécision pipette, dérive optique, réactifs.
Statut	L'objet de la découverte scientifique !	Bruit parasite indésirable.
Action	On estime sa distribution dans l'espèce.	À éliminer par les Bonnes Pratiques (BPL).

Message Clé à Retenir : Règle d'Or

Répéter 10 fois le pipetage réduit l'erreur technique, mais n'informe pas sur la diversité biologique !

Réplicats Biologiques (N) versus Réplicats Techniques (k)

📄 Définition / Concept Clé : La Définition Exacte de l'Effectif de l'Échantillon (N)

La statistique inférentielle exige des unités expérimentales **strictement indépendantes** :

- ▶ **✓ Réplicats Biologiques (N)** : Animaux distincts, donneurs indépendants, extractions cellulaires séparées. $\Rightarrow$ **Seule base valide de calcul de N .**
- ▶ **✗ Réplicats Techniques (k)** : Mesures répétées sur le même échantillon (ex : triplicat ELISA du sérum du rat n°1, $k = 3$).

⚠ Piège Fréquent en Biologie : Le Piège de la Pseudoréplication

Doser 2 souris dans 5 puits chacune donne un effectif biologique de $N = 2$, et non $N = 10$!
Traiter les 10 mesures comme indépendantes dans un test t constitue une faute grave qui gonfle artificiellement les degrés de liberté et génère des faux positifs massifs.

De la Population Cible à l'Échantillon Expérimental

Définition / Concept Clé : Le Principe Fondamental de l'Inférence Statistique

On étudie un échantillon aléatoire pour extrapoler les conclusions à une population cible :



Cas Pratique Biochimie : Conditions Impératives de Validité

- ▶ **Représentativité** : Les animaux inclus doivent être représentatifs de l'espèce cible.
- ▶ **Randomisation** : Attribution aléatoire des lots pour neutraliser les facteurs de confusion.
- ▶ **Indépendance** : La mesure d'un animal n'influence en rien celle d'un autre.

Les Données Quantitatives Continues

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **quantitative continue** si elle peut prendre théoriquement toute valeur réelle sur un intervalle de $\mathbb{R}$. Elle possède une unité physique mesurable.

Cas Pratique Biochimie : Exemples Clés au Laboratoire de Biochimie

- ▶ Absorbance spectrophotométrique à 595 nm (gamme Bradford) : 0.452, 0.458 DO.
- ▶ Concentration sérique d'albumine : 41.25 g/L.
- ▶ Vitesse initiale d'une enzyme : $v_0 = 12.4 \mu\text{mol} \cdot \text{min}^{-1} \cdot \text{mg}^{-1}$.
- ▶ Expression relative par RT-qPCR : $2^{-\Delta\Delta C_t} = 3.42$.

⇒ Analysées par statistiques paramétriques (Moyenne, *SD*, *SEM*, Test *t*, ANOVA).

Les Données Quantitatives Discrètes

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **quantitative discrète** lorsqu'elle ne prend que des **valeurs entières dénombrables** ($\mathbb{N}$), résultant d'un processus de comptage d'occurrences.

Cas Pratique Biochimie : Exemples Clés en Microbiologie & Toxicologie

- ▶ Nombre de colonies bactériennes (UFC) dénombrées sur boîte de gélose ($k = 0, 1, 2, \dots$).
 - ▶ Nombre de métastases pulmonaires après induction tumorale ($k = 7$ nodules).
 - ▶ Nombre de cellules sanguines comptées sur cellule de Malassez.
 - ▶ Nombre d'épisodes d'hypoglycémie enregistrés par an.
- ⇒ Modélisées par la loi de Poisson $\mathcal{P}(\lambda)$ ou loi Binomiale Négative.

Les Données Qualitatives Nominales

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **qualitative nominale** lorsque ses modalités correspondent à des **catégories sans relation d'ordre** ni hiérarchie numérique.

Cas Pratique Biochimie : Exemples Biologiques Réels

- ▶ **Génotype d'un modèle murin** : Sauvage (WT), Hétérozygote (+/-), Knock-Out (KO).
- ▶ **Sexe biologique des animaux** : Mâle vs Femelle.
- ▶ **Localisation cellulaire** : Nucléaire, Cytosolique, Mitochondriale, Membranaire.
- ▶ **Groupe sanguin érythrocytaire** : A, B, AB, O.

⇒ Analysées par tableaux de contingence, test du χ^2 et test exact de Fisher.

Les Données Qualitatives Ordinales

Définition / Concept Clé : Définition & Propriétés Mathématiques

Une variable est dite **qualitative ordinale** lorsque ses catégories possèdent un **ordre intrinsèque**, mais dont la distance numérique entre échelons n'est pas mesurable.

Cas Pratique Biochimie : Exemples Médicaux & Histologiques

- ▶ **Score de fibrose hépatique (Métavir)** : F0 (absence), F1, F2, F3, F4 (cirrhose).
- ▶ **Intensité de coloration immunohistochimique** : Nulle (0), Faible (+), Forte (+++).
- ▶ **Échelle de douleur ou tolérance** : Mineure, Modérée, Sévère.

Règle clé : Interdiction de calculer une moyenne ! Utiliser la **médiane** et les tests non paramétriques de rangs (Mann-Whitney, Kruskal-Wallis).

Structuration Professionnelle des Données : Le Format *Tidy Data*

Définition / Concept Clé : Les 3 Principes de Wickham pour l'Analyse Informatique

Pour être exploitable sans erreur sous Python/Pandas ou GraphPad : **1.** Chaque ligne = 1 individu unique. **2.** Chaque colonne = 1 variable. **3.** Chaque cellule = 1 valeur.

ID_Animal	Genotype	Traitement	Dose_mgkg	MDA_nmol_g	GPx_U_mg
RAT_01	Wild-Type	Curcumine	50	5.82	142.5
RAT_02	Wild-Type	Curcumine	50	6.14	138.2
RAT_03	db/db	Curcumine	200	8.45	95.4
RAT_04	db/db	Véhicule	0	14.20	62.1

Message Clé à Retenir : À Bannir

Éviter absolument les cellules fusionnées dans Excel et les blocs de données juxtaposés.

Paramètres de Tendence Centrale : La Moyenne Arithmétique

Définition / Concept Clé : Définition & Formule Mathématique

La moyenne empirique $\bar{x}$ représente le barycentre gravitationnel de l'échantillon de taille n :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Piège Fréquent en Biologie : Vulnérabilité Majeure : Sensibilité Extrême aux Outliers

Soit la protéinémie de 5 tubes (en g/L) : 40, 42, 39, 41, 43 $\Rightarrow \bar{x} = 41.0$ g/L.

Si une bulle optique produit un artefact sur le 5^e tube (40, 42, 39, 41, **120**), la moyenne devient :

$$\bar{x} = 56.4 \text{ g/L}$$

La moyenne ne décrit plus aucun des animaux réels : elle a été déportée par l'aberrant !

Paramètres de Tendence Centrale : La Médiane

Définition / Concept Clé : Définition & Propriété de Robustesse

La médiane (Med) sépare l'échantillon ordonné en deux moitiés égales (50% au-dessus, 50% au-dessous) :

$$\text{Pour } n \text{ impair : Med} = x_{(\frac{n+1}{2})}, \quad \text{Pour } n \text{ pair : Med} = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

Cas Pratique Biochimie : L'Insensibilité Totale aux Valeurs Aberrantes

Sur notre série avec artefact : 39, 40, **41**, 42, **120**.

La médiane reste imperturbablement égale à **41.0 g/L** !

Que la dernière valeur soit 43 ou 1200 g/L, la médiane ne change pas. C'est l'indicateur de choix pour toutes les distributions asymétriques au laboratoire.

Paramètres de Tendence Centrale : Le Mode & Distributions Plurimodales

Définition / Concept Clé : Définition & Signification Biologique

Le **Mode** correspond à la valeur présentant la plus forte fréquence d'observation (sommet de la densité).


Cas Pratique Biochimie : Alerte Majeure : Les Distributions Bimodales

Si un biomarqueur tumoral présente **deux modes distincts**, cela révèle que l'échantillon n'est pas homogène, mais composé de **deux sous-populations distinctes** :

- ▶ **Mode 1** : Sous-clone sensible à la chimiothérapie (85% de mortalité cellulaire).
- ▶ **Mode 2** : Sous-clone résistant porteur d'une mutation de transporteur (10% de mortalité).

Calculer une moyenne globale masquerait complètement la résistance thérapeutique !

Visualisation HD : Moyenne vs. Médiane vs. Mode selon l'Asymétrie



💡 Message Clé à Retenir : Interprétation Clé

Normale (Gauche) : Symétrie parfaite $\implies$ Moyenne = Médiane = Mode.

Asymétrique (Droite, ex: IL-6) : Mode < Médiane < Moyenne. La moyenne est tirée vers la droite. Publiez impérativement la **Médiane** !

Paramètres de Dispersion : La Variance de Bessel (s^2)

Définition / Concept Clé : Formule Mathématique & Correction de Bessel ($n - 1$)

La variance quantifie la dispersion des observations individuelles autour de leur moyenne :

$$s^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Cas Pratique Biochimie : Pourquoi Divise-t-on par $n - 1$ et non par n ?

Dans l'échantillon, la vraie moyenne μ est inconnue et remplacée par $\bar{x}$. Or, les points x_i sont naturellement plus proches de $\bar{x}$ que de la vraie moyenne μ .

Diviser par n sous-estimerait la variance réelle de la population.

La division par $n - 1$ compense exactement cette perte d'un **degré de liberté** consommé par le calcul de $\bar{x}$.

Paramètres de Dispersion : L'Écart-Type (SD)

Définition / Concept Clé : Définition & Retour à l'Unité Physique d'Origine

L'écart-type est la racine carrée positive de la variance :

$$SD = s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Cas Pratique Biochimie : Signification Biologique Concrète

- ▶ Il exprime la **dispersion biologique intrinsèque** des individus au sein du groupe.
- ▶ Il possède la **même unité physique** que la variable brute ($\bar{x} \pm SD = 41.2 \pm 3.1 \text{ g/L}$).
- ▶ **Propriété clé** : L'écart-type SD **ne tend pas vers zéro** lorsque la taille de l'échantillon n augmente ! Il converge vers l'écart-type réel σ de la population.

Paramètre de Précision : L'Erreur Standard de la Moyenne (SEM)

📄 Définition / Concept Clé : Définition & Précision de l'Estimation


L'erreur standard quantifie **l'incertitude sur l'estimation de la moyenne $\bar{x}$** :

$$SEM = \frac{SD}{\sqrt{n}} = \frac{s}{\sqrt{n}}$$

⚠️ Piège Fréquent en Biologie : Mise en Garde Pédagogique

- ▶ Comme $SEM = SD/\sqrt{n}$, plus l'effectif n grandit, plus le SEM rétrécit vers zéro !
- ▶ Beaucoup d'auteurs publient le SEM pour avoir de petites barres d'erreur et masquer la variabilité.
- ▶ **Règle internationale** : Pour décrire la variabilité biologique, publiez le SD . Réservez le SEM pour la comparaison inférentielle de moyennes.

Visualisation HD : Écart-Type (SD) versus Erreur Standard (SEM)



💡 Message Clé à Retenir : Différence Visuelle

Gauche (SD) : Dispersion biologique individuelle ($\pm 1SD$ couvre 68%, $\pm 2SD$ couvre 95%).

Droite (SEM) : La distribution de la moyenne rétrécit drastiquement lorsque n grandit ($\propto 1/\sqrt{n}$).

Indicateurs Robustes : Quartiles & Écart Interquartile (*IQR*)

Définition / Concept Clé : Définition des Quartiles & Zone Centrale des 50% d'Individus

Les quartiles divisent la distribution ordonnée en 4 quarts : Q_1 (25%), Q_2 (Médiane, 50%), Q_3 (75%).

$$\mathbf{IQR} = Q_3 - Q_1 \quad (\text{Écart Interquartile : contient les 50\% d'individus centraux})$$

Cas Pratique Biochimie : Application au Laboratoire

Comme la médiane, l'*IQR* est **insensible aux valeurs aberrantes**. C'est l'indicateur obligatoire pour résumer des données non normales : Médiane [Q_1 ; Q_3].

Répétabilité Analytique : Le Coefficient de Variation ($CV\%$)

Définition / Concept Clé : Formule Relative de Dispersion


Le coefficient de variation exprime l'écart-type en pourcentage de la moyenne :

$$CV\% = \frac{SD}{\bar{x}} \times 100\% = \frac{s}{\bar{x}} \times 100\%$$

Cas Pratique Biochimie : Critères d'Acceptation selon les Bonnes Pratiques de Laboratoire (BPL)

- ▶ $CV < 5\%$: Dosage spectrophotométrique ou colorimétrique d'excellente répétabilité.
- ▶ $CV < 10\%$: Dosage immunologique ELISA validé.
- ▶ $CV > 15\%$: Imprécision analytique inacceptable : problème de pipetage ou d'étalonnage.

Visualisation HD : Anatomie Complète du Boxplot de Tukey



💡 Message Clé à Retenir : Règle de Détection Mathématique des Outliers de Tukey

Moustaches : Borne Basse = $Q_1 - 1.5 \times IQR$, Borne Haute = $Q_3 + 1.5 \times IQR$.
Tout point biologique au-delà des moustaches est un **outlier** potentiel devant être investigué.

Qu'est-ce qu'une Probabilité en Sciences du Vivant ?

Définition / Concept Clé : L'Approche Fréquentiste de Kolmogorov

La probabilité $P(A)$ d'un événement biologique représente la fréquence relative limite d'apparition de cet événement lorsque l'expérience est répétée un grand nombre de fois :

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}, \quad 0 \leq P(A) \leq 1, \quad P(\Omega) = 1$$

Cas Pratique Biochimie : Application : Efficacité d'un Vecteur Viral de Transfection

Sur 1000 cellules exposées à un lentivirus GFP, 720 émettent une fluorescence verte :

$$P(\text{Transfection Réussie}) = \frac{720}{1000} = 0.72 \quad (72\%)$$

Probabilités Conditionnelles & Indépendance Génétique

Définition / Concept Clé : Définition Mathématique du Conditionnement

La probabilité conditionnelle $P(A \mid B)$ est la probabilité que A se produise sachant que B est déjà réalisé :

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \quad \Longleftrightarrow \quad P(A \cap B) = P(A \mid B) \cdot P(B)$$

Cas Pratique Biochimie : L'Indépendance Mendélienne en Génétique

Deux événements A et B sont **indépendants** si la réalisation de B n'influence pas A :

$$P(A \mid B) = P(A) \quad \Longleftrightarrow \quad P(A \cap B) = P(A) \times P(B)$$

Exemple : Transmission de 2 gènes sur 2 chromosomes distincts (3^e loi de Mendel).

Le Théorème de Bayes au Cœur du Diagnostic Biologique

Définition / Concept Clé : L'Inversion Probabiliste Fondamentale


Le clinicien veut savoir : quelle est la probabilité d'être malade sachant que le test ELISA est positif ?

$$P(M \mid +) = \frac{P(+ \mid M) \cdot P(M)}{P(+)} = \frac{\text{Sensibilité} \times \text{Prévalence}}{\text{Sensibilité} \times \text{Prévalence} + (1 - \text{Spécificité}) \times (1 - \text{Prévalence})}$$

Cas Pratique Biochimie : Indicateurs Clés de Performance Analytique

- ▶ **Sensibilité (Se)** : $P(+ \mid M) \implies$ capacité à détecter les vrais malades.
- ▶ **Spécificité (Sp)** : $P(- \mid \bar{M}) \implies$ capacité à déclarer négatifs les sujets sains.
- ▶ **VPP** : $P(M \mid +) \implies$ Valeur Prédictive Positive (probabilité d'être malade si testé positif).

Visualisation HD : Arbre du Test ELISA & Calcul de la VPP



💡 Message Clé à Retenir : Analyse de la Catastrophe des Faux Positifs

Sur 10 000 individus testés pour une maladie rare (1%) avec $Se = 99\%$ et $Sp = 95\%$:
Vrais Positifs = 99, mais Faux Positifs = 495 personnes saines déclarées positives !
 $\Rightarrow VPP = 99 / (99 + 495) = 16.7\%$ seulement ! Plus de 5 tests positifs sur 6 sont faux.

Le Paradoxe des Maladies Rares en Dépistage Clinique

Définition / Concept Clé : Pourquoi un Test à 99% Échoue-t-il sur une Maladie Rare ?

Lorsque la prévalence est très faible ($P(M) < 1\%$), l'immense majorité de la population est saine ($> 99\%$).

Même avec 1% de faux positifs, ce taux s'applique à un réservoir géant d'individus sains !

Le nombre absolu de faux positifs submerge alors complètement les quelques vrais malades.

Cas Pratique Biochimie : Conséquence Pédagogique Immédiate

Ne jamais dépister en masse sans sélection préalable des sujets à risque (symptômes évocateurs augmentant la prévalence pré-test).

La Loi Binomiale $\mathcal{B}(n, p)$: Les Processus de Bernoulli

Définition / Concept Clé : Modélisation des Événements Discrets Binaires (Succès / Échec)

Lorsqu'une expérience binaire de probabilité p est répétée n fois de façon indépendante :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad \mathbb{E}(X) = n \cdot p, \quad \mathbb{V}(X) = n \cdot p \cdot (1 - p)$$

Cas Pratique Biochimie : Exemples Clés au Laboratoire

- ▶ Nombre de puits positifs sur une plaque PCR à dilution limite ($n = 96, p = 0.25$).
- ▶ Taux de survie d'une culture cellulaire après 48h d'exposition à un cytotoxique.
- ▶ Transmission mendélienne d'un allèle récessif létal ($p = 0.25$).

La Loi de Poisson $\mathcal{P}(\lambda)$: Les Événements Rares

Définition / Concept Clé : Comptages d'Événements Rares dans l'Espace ou le Temps


Pour des événements indépendants se produisant à un taux moyen constant $\lambda > 0$:

$$P(X = k) = \frac{\lambda^k \cdot e^{-\lambda}}{k!} \quad \text{avec} \quad \mathbb{E}(X) = \lambda \quad \text{et} \quad \mathbb{V}(X) = \lambda$$

Cas Pratique Biochimie : Applications en Microbiologie & Génétique

- ▶ Nombre de colonies bactériennes (UFC) dénombrées par boîte de gélose.
- ▶ Nombre de mutations spontanées apparaissant par million de paires de bases.
- ▶ **Alerte** : Si la variance observée dépasse nettement la moyenne ($s^2 > \lambda$), il y a sur-dispersion (agrégation cellulaire ou pipetage défectueux).

Visualisation HD : Lois Discrètes Binomiale vs. Poisson



💡 Message Clé à Retenir : Différence Conceptuelle

Gauche (Binomiale) : Effectif n fixé à l'avance (ex: 20 puits). Bornée entre 0 et n .

Droite (Poisson) : Pas de plafond n fixé ; comptage d'occurrences sur un continuum.

La Loi Normale de Gauss $\mathcal{N}(\mu, \sigma^2)$: La Reine des Distributions

Définition / Concept Clé : Densité de Probabilité Continue Symétrique en Cloche

Une variable continue X suit une loi normale d'espérance μ et de variance σ^2 si :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right)$$

Elle est strictement symétrique autour de son sommet unique μ (Moyenne = Médiane = Mode).

Cas Pratique Biochimie : Pourquoi la Nature Aime-t-elle la Loi Normale ?

Toute grandeur biologique issue de la somme d'un grand nombre de facteurs microscopiques indépendants (multiples gènes, nutriments) adopte naturellement une forme de Gauss.

La Règle Empirique des 68% – 95% – 99.7% & Score Z

Définition / Concept Clé : Les Aires Fondamentales sous la Cloche de Gauss

Pour toute variable normale :

- ▶ $[\mu - 1\sigma ; \mu + 1\sigma]$ contient exactement **68.27%** de la population.
- ▶ $[\mu - 2\sigma ; \mu + 2\sigma]$ contient **95.45%** ($\pm 1.96\sigma$ contient exactement **95.00%**).
- ▶ $[\mu - 3\sigma ; \mu + 3\sigma]$ contient **99.73%** des individus.

Cas Pratique Biochimie : Centrage et Réduction : Le Score Z

La transformation $Z = \frac{X - \mu}{\sigma}$ standardise n'importe quelle mesure en $\mathcal{N}(0, 1)$.

Un patient avec un score $Z > +2$ se situe dans le top 2.5% supérieur (valeur anormale suspecte).

Le Théorème Central Limite (TCL) : Le Miracle de la Statistique

Définition / Concept Clé : Énoncé Fondamental du Théorème Central Limite

Soit un échantillon indépendant tiré d'une population de moyenne μ et de variance finie σ^2 , **quelle que soit sa loi d'origine** (asymétrique, exponentielle, discrète) :


$$\text{Quand } n \geq 30, \quad \bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

La distribution des **moyennes d'échantillons** converge vers une loi normale !

Message Clé à Retenir : Conséquence Pratique

Même avec des cellules individuelles asymétriques, la moyenne d'un groupe d'animaux ($n \geq 30$) est normale, justifiant l'usage des tests paramétriques.

Visualisation HD : Le Théorème Central Limite en Action



💡 Message Clé à Retenir : Démonstration Numérique

Gauche : Population de départ exponentielle asymétrique ($n = 1$).

Centre : Les moyennes de 5 mesures ($n = 5$) s'arrondissent déjà nettement.

Droite : Pour $n = 30$, les moyennes épousent parfaitement la courbe normale théorique !

Les Lois Dérivées d'Échantillonnage : χ^2 , Student t , Fisher F

Définition / Concept Clé : Les 3 Outils Mathématiques Dérivés de la Loi Normale

Ces trois distributions constituent le socle de tous les tests inférentiels :

Loi	Définition	Usage Clé en Biochimie
Khi-deux (χ^2_ν)	Somme de carrés de ν variables normales.	Conformité génétique (Mendel), contingence, variances.
Student (t_ν)	Moyenne divisée par son écart-type estimé.	Comparaison de 2 moyennes quand σ est inconnu.
Fisher (F_{ν_1, ν_2})	Rapport de deux variances indépendantes.	Comparaison de variances et statistique clé de l' ANOVA .

Le Principe Fondamental de l'Estimation Statistique

Définition / Concept Clé : De l'Estimateur Ponctuel à la Zone de Confiance

Une moyenne calculée sur 10 rats ($\bar{x} = 2.45 \text{ g/L}$) est une estimation ponctuelle qui ne sera jamais égale à la vraie valeur μ de l'espèce.

La statistique remplace l'estimation ponctuelle par une **zone de plausibilité** :

$$\text{Intervalle de Confiance à 95\%} = [\bar{x} - \text{Marge d'Erreur} ; \bar{x} + \text{Marge d'Erreur}]$$

Cas Pratique Biochimie : Définition Fréquentiste Exacte

Si 100 laboratoires répètent l'expérience et calculent leur IC 95%, **exactement 95 intervalles engloberont la vraie moyenne μ** , et 5 la manqueront.

Construction Mathématique de l'Intervalle de Confiance à 95%

Définition / Concept Clé : Formule Basée sur la Loi de Student

Lorsque la variance vraie est inconnue :

$$IC_{95\%} = \left[\bar{x} - t_{0.05/2, n-1} \cdot \frac{s}{\sqrt{n}} \quad ; \quad \bar{x} + t_{0.05/2, n-1} \cdot \frac{s}{\sqrt{n}} \right]$$

Cas Pratique Biochimie : Exemple Résolu : Catalase Sérique ($N = 25$)


$\bar{x} = 142.0 \text{ U/mg}$, $s = 20.0 \text{ U/mg} \implies SEM = 20/\sqrt{25} = 4.0 \text{ U/mg}$.

Pour 24 ddl au seuil 5%, la table donne $t_{0.025, 24} = 2.064$:

$$IC_{95\%} = [142.0 - 2.064 \times 4.0 \ ; \ 142.0 + 2.064 \times 4.0] = [133.74 \ ; \ 150.26 \text{ U/mg}]$$

Confiants à 95% que l'activité vraie de la population est entre 133.7 et 150.3 U/mg.

Visualisation HD : Simulation de 25 Intervalles de Confiance à 95%



💡 Message Clé à Retenir : Analyse Visuelle

Gauche : 24 intervalles en vert capturent bien $\mu = 100$. Le 13^e en rouge manque μ (aléa du risque 5%).

Droite : Plus la taille N grandit, plus l'incertitude se resserre en $1/\sqrt{N}$.

Règle d'Or : Intervalles de Confiance & Prise de Décision

 Définition / Concept Clé : Comment Juger d'une Différence sans Même Faire de Test t ?

L'examen visuel des deux intervalles de confiance permet de statuer immédiatement :

- ▶ **Aucun chevauchement entre les deux IC 95%** : La différence est **statistiquement significative** au seuil $p < 0.05$.
- ▶ **Les IC 95% se chevauchent modérément** : Un test formel (Student) est requis pour obtenir la p -value exacte.
- ▶ **L'IC 95% de la différence contient 0** : L'effet du traitement n'est pas significatif.

 Message Clé à Retenir : Recommandation Éditoriale

Nature et *Science* exigent les IC 95% car ils informent sur la **significativité** et sur la **taille de l'effet**.

Le Raisonnement par l'Absurde du Test Statistique

Définition / Concept Clé : La Structure Fondamentale de Neyman-Pearson

La science procède par **falsification et raisonnement par l'absurde** :

- ▶ **Hypothèse Nulle (H_0)** : Le traitement n'a aucun effet réel ($\mu_{\text{Traité}} = \mu_{\text{Témoin}}$).
- ▶ **Hypothèse Alternative (H_1)** : Le traitement modifie la réponse ($\mu_{\text{Traité}} \neq \mu_{\text{Témoin}}$).

Message Clé à Retenir : Démarche

On calcule la probabilité d'observer nos données **en supposant H_0 vraie**. Si cette probabilité est inférieure au seuil critique $\alpha = 0.05$, on déclare H_0 absurde et on la **rejette en faveur de H_1** .

La Matrice de Décision : Risques α , β et Puissance ($1 - \beta$)

Définition / Concept Clé : Les 4 Issues Possibles de Tout Test Statistique


La décision du biologiste est confrontée à la vérité biologique :

Décision Prise	H_0 Vraie (Pas d'effet)	H_1 Vraie (Effet réel)
Rejeter H_0 (Effet conclu)	Erreur Type I (α) Faux Positif (seuil fixé à 5%)	Décision Correcte (Puissance $1 - \beta$) Détection de l'effet (visée $\geq 80\%$)
Conserver H_0 (Pas d'effet)	Décision Correcte ($1 - \alpha$) Spécificité (95%)	Erreur Type II (β) Faux Négatif (effet manqué)

Cas Pratique Biochimie : Application

Erreur α : Déclarer active une molécule inefficace. **Erreur β** : Abandonner un bon candidat faute de rats suffisants.

Visualisation HD : Distributions H_0 et H_1 , Risques & Puissance



💡 Message Clé à Retenir : Analyse Visuelle de la Décision

Zone Rouge ($\alpha = 5\%$) : Extrême droite sous H_0 (rejet à tort).

Zone Orange (β) : Sous H_1 à gauche du seuil (échec de détection).

Zone Verte ($1 - \beta$) : Sous H_1 au-delà du seuil (puissance statistique réelle).

Démystification Rigoureuse de la p -value

📖 Définition / Concept Clé : Définition Exacte de l'American Statistical Association (ASA)

La p -value est la probabilité d'obtenir un résultat au moins aussi extrême que celui observé, **en supposant que H_0 est rigoureusement vraie** :

$$p\text{-value} = P(\text{Données observées ou plus extrêmes} \mid H_0 \text{ vraie})$$

⚠️ Piège Fréquent en Biologie : Les 3 Pièges Mortels à Éviter

1. **Faux** : « $p = 0.03$ signifie 97% de chances que le médicament marche ». $\implies p$ ne quantifie JAMAIS $P(H_1)$!
2. **Faux** : « $p = 0.03$ signifie 3% de chances que H_0 soit vraie ». $\implies H_0$ n'est pas une variable aléatoire !
3. **Faux** : « $p = 0.08$ prouve l'équivalence ». $\implies$ L'absence de preuve n'est pas la preuve de l'absence !

Significativité Statistique ($p < 0.05$) vs. Pertinence Biologique

Définition / Concept Clé : Le Paradoxe des Grands Effectifs

Comme $t = \frac{\bar{x}_1 - \bar{x}_2}{s/\sqrt{n}}$, quand $n \rightarrow \infty$, $t \rightarrow \infty$ et $p \rightarrow 0$!

Avec 100 000 souris, un écart minuscule de glycémie (0.001 g/L) sera $p < 0.0001$ sans avoir aucun intérêt biologique.

Cas Pratique Biochimie : La Solution : Quantifier la Taille d'Effet (d de Cohen)

$$d = \frac{\bar{x}_1 - \bar{x}_2}{SD_{\text{pooled}}} \quad (d = 0.2 : \text{faible}, \quad d = 0.5 : \text{moyen}, \quad d \geq 0.8 : \text{fort})$$

Accompagnez toujours la p -value de la taille d'effet et de l'intervalle de confiance.

Les 3 Postulats Obligatoires des Tests Paramétriques

Définition / Concept Clé : Le Contrat Mathématique Préalable

Avant de lancer un test t , une ANOVA ou une régression :

1. **Indépendance des Mesures** : Pas de pseudoréplication (contrôle par randomisation).
2. **Normalité des Résidus** : Distribution gaussienne.
⇒ Contrôle par test de **Shapiro-Wilk** ($p > 0.05$ requis) et diagramme Q-Q plot.
3. **Homoscédasticité** : Égalité des variances entre groupes.
⇒ Contrôle par test de **Levene** ($p > 0.05$ requis).

Que Faire en Cas de Violation des Postulats ?

Définition / Concept Clé : Deux Stratégies Disponibles

Si vos données de laboratoire violent la normalité ou l'égalité des variances :

► Option A : La Transformation Mathématique


- Données asymétriques à droite (concentrations, cytokines) : $Y' = \log_{10}(Y)$.
- Données de comptage (Poisson) : $Y' = \sqrt{Y}$.
- Proportions ou pourcentages : $Y' = \arcsin(\sqrt{Y})$.

► Option B : Les Tests Non Paramétriques (Basés sur les Rangs)

- Remplacent les valeurs par leur rang de classement ($1^{\text{er}}, 2^{\text{e}}, \dots$).
- Parfaitement insensibles aux asymétries et aux outliers.

Visualisation HD : Arbre Décisionnel Universel des Tests Biologiques

Arbre Décisionnel Fondamental en Biostatistiques (Master 2)



💡 Message Clé à Retenir : Règle de Sélection Instantanée

2 Groupes Indépendants : Student t (Paramétrique) $\longleftrightarrow$ Mann-Whitney U (Non-Paramétrique).

≥ 3 Groupes : ANOVA (Paramétrique) $\longleftrightarrow$ Kruskal-Wallis (Non-Paramétrique).

Feuille de Route du Module de Biostatistiques Appliquées

Définition / Concept Clé : Progression Didactique des 7 Chapitres Suivants

Forts des concepts de variabilité, d'inférence et d'hypothèses acquis dans ce Chapitre 0 :

- ▶ **Chapitre 1 : ANOVA à Deux Facteurs Croisés** $\Rightarrow$ Interactions et synergies médicamenteuses.
- ▶ **Chapitre 2 : ANOVA Hiérarchisée (Nested)** $\Rightarrow$ Neutraliser les bioréacteurs et réplicats.
- ▶ **Chapitre 3 : Régression Linéaire** $\Rightarrow$ Gammes étalons (Bradford), limites LOD / LOQ.
- ▶ **Chapitre 4 : Régression Non Linéaire** $\Rightarrow$ Michaelis-Menten et modèles sigmoïdes 4PL.
- ▶ **Chapitre 5 : Analyse en Composantes Principales (ACP)** $\Rightarrow$ Omiques et réduction dimensionnelle.
- ▶ **Chapitre 6 : Classification Ascendante Hiérarchique (CAH)** $\Rightarrow$ Dendrogrammes.
- ▶ **Chapitre 7 : Interprétation Avancée & Présentation Graphique** $\Rightarrow$ Publications internationales.

Merci de votre attention !

Place aux Travaux Dirigés (Série 00) & Travaux Pratiques Python

Portail officiel & Simulateur Interactif :
<https://hosniadilemp-a11y.github.io/BioStat/>

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.) — Université de Boumerdès (UMBB)