

Biostatistiques Appliquées & Modélisation du Vivant

Chapitre V : Analyse en Composantes Principales (ACP) & Profilage Multivarié

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Plan Détaillé du Chapitre V

Définition / Concept Clé : 1. Fondements & Démonstration Géométrique 2D → 1D

Section 1 : L'Ère des Données Omiques & Le Besoin de Réduction

Section 2 : Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Section 3 : Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Cas Pratique Biochimie : 2. Algèbre, Espaces Factoriels & Diagnostic Multivarié

Section 4 : Algèbre Matricielle : Matrice R , Valeurs Propres & Éboulis de Kaiser

Section 5 : L'Espace des Variables : Le Cercle des Corrélations, $\cos^2$ & Contributions

Section 6 : L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Section 7 : Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Le Défi Omique : L'Explosion de la Haute Dimensionnalité

Cas Pratique Biochimie : La Matrice Expérimentale Moderne ($n \times p$)

En biochimie médicale, spectrométrie de masse, métabolomique et transcriptomique :

- ▶ n échantillons biologiques (lignes : souris, patients, lysats tissulaires).
- ▶ p biomarqueurs dosés simultanément (colonnes : métabolites, lipides, transaminases, cytokines).
- ▶ Un seul passage en LC-MS/MS quantifie simultanément 40 à 300 métabolites par goutte de plasma !

Piège Fréquent en Biologie : Pourquoi l'Approche Univariée Classique Échoue ?

- ▶ Tester les 40 métabolites un par un (40 tests t ou ANOVA séparés) multiplie le risque d'erreur globale α (faux positifs).
- ▶ Plus grave encore : cela **ignore totalement les corrélations biologiques** entre molécules appartenant à une même voie métabolique !

La Mission Fondamentale de l'ACP : Réduction Non Supervisée

Définition / Concept Clé : Définition Statistique : Comprimer Sans Perdre l'Essentiel

L'**Analyse en Composantes Principales (ACP)** est une méthode de réduction de dimensionnalité qui transforme p variables de départ corrélées en un petit nombre k ($k \ll p$, typiquement 2 ou 3) de nouvelles variables **artificielles**, **non corrélées entre elles** appelées **composantes principales** :

$$\mathbb{R}^p \xrightarrow{\text{Projection orthogonale}} \mathbb{R}^k \quad (k = 2 \text{ ou } 3)$$

Message Clé à Retenir : Les Trois Objectifs Majeurs pour le Biochimiste

1. **Résumer** : Conserver le maximum de l'inertie (variance biologique totale) sur un plan 2D lisible à l'œil nu.
2. **Détecter la redondance** : Identifier les groupes de biomarqueurs qui évoluent de concert (voies métaboliques).
3. **Discriminer** : Séparer spontanément les états phénotypiques (Sains vs Pathologiques) de manière non supervisée.

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Étude Préclinique chez la Souris : Modèle d'Obésité Métabolique

Cas Pratique Biochimie : Protocole Expérimental ($N = 24$ Souris C57BL/6J)

Pour comprendre la mécanique géométrique de l'ACP, étudions un modèle préclinique concret d'adiposité :

- ▶ **Groupe 1 (Témoins Chow, $n = 12$)** : Souris nourries avec une alimentation standard de laboratoire.
- ▶ **Groupe 2 (Obèses HFD, $n = 12$)** : Souris soumises à un régime riche en lipides (*High-Fat Diet*, 60% kcal de graisse).

On mesure sur chaque souris deux variables biométriques classiques :

1. **Variable 1 (X_1)** : Poids corporel total (exprimé en grammes, g).
2. **Variable 2 (X_2)** : Masse du tissu adipeux épидидymaire (exprimée en milligrammes, mg).

Définition / Concept Clé : La Question Pédagogique Fondamentale

Puisque le tissu adipeux augmente directement avec le poids total, les deux variables sont fortement liées.
Comment l'ACP peut-elle réduire ces 2 variables dépendantes en 1 seul axe synthétique d'adiposité sans perte d'information ?

Notion 1 : Le Constat Biologique de Redondance Linéaire

Définition / Concept Clé : Corrélation Linéaire Élevée : L'Effet « Cigare »


Lorsque deux variables mesurent deux facettes d'un même phénomène physiologique, les points expérimentaux s'étirent le long d'une diagonale dans l'espace 2D :

$$r(X_1, X_2) = \frac{\sum (X_{i1} - \bar{X}_1)(X_{i2} - \bar{X}_2)}{\sqrt{SS_{X_1} \cdot SS_{X_2}}} = +0.96 \quad (p < 10^{-10})$$

Cas Pratique Biochimie : Le Diagnostic du Biochimiste : Pourquoi Conserver Deux Axes ?

- ▶ Si l'on connaît le poids corporel d'une souris (45 g), on peut prédire avec une excellente précision sa masse adipeuse (1450 mg).
- ▶ Les deux axes X_1 et X_2 portent à 96% la **même information biologique**.
- ▶ Un espace à 2 dimensions est redondant : un seul axe incliné suffirait à décrire l'essentiel de la variabilité entre souris !

Visualisation Graphique : La Redondance Linéaire 2D chez la Souris



💡 Message Clé à Retenir : Lecture du Graphique 2D

Les souris témoins (vert) et obèses (rouge) s'alignent sur une trajectoire linéaire unique ($r = 0.96$). La variabilité perpendiculaire à cette droite est minimale (simple bruit biologique individuel).

Notion 2 : Pourquoi l'Étape de Centrage-Réduction est Impérative ?

⚠ Piège Fréquent en Biologie : Le Piège Mortel des Échelles & Unités Disparates

Comparons les dispersions numériques de nos deux grandeurs non standardisées :

- ▶ X_1 (Poids en g) : moyenne $\bar{X}_1 = 35.0$ g, variance $s_1^2 \approx 85.0 \text{ g}^2$.
- ▶ X_2 (Adipeux en mg) : moyenne $\bar{X}_2 = 860.0$ mg, variance $s_2^2 \approx 280\,000 \text{ mg}^2$!

Si l'on injectait les données brutes dans l'ACP : la variable X_2 posséderait à elle seule 99.97% de la variance numérique par le simple fait d'être mesurée en milligrammes !

💡 Message Clé à Retenir : Règle d'Or de l'ACP en Sciences de la Vie

En biologie, on utilise **exclusivement l'ACP normée** (centrée-réduite) basée sur la **matrice des corrélations** R . Chaque variable reçoit une variance initiale normalisée égale à 1, lui conférant un poids analytique équitable.

Notion 3 : La Transformation en Variables Centrées-Réduites (Z)

Définition / Concept Clé : Formule Mathématique du Z -Score

Chaque mesure individuelle X_{ij} (souris i , variable j) est transformée selon :

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j} \quad \text{avec } \bar{X}_j = \text{moyenne de la variable } j, \quad s_j = \text{écart-type de la variable } j$$

Cas Pratique Biochimie : Propriétés Algébriques & Sens Biologique

- ▶ **Moyenne nulle** : $\mathbb{E}(Z_j) = 0 \implies$ Le nuage de points est translaté pour avoir son barycentre à l'origine $(0, 0)$.
- ▶ **Variance unitaire** : $\text{Var}(Z_j) = 1 \implies$ Toutes les variables jouent à armes égales, sans effet d'échelle d'appareil.
- ▶ **Interprétation** : Une souris avec $Z_{i1} = +2.0$ a un poids corporel situé à $+2$ écarts-types au-dessus de la moyenne.

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Notion 4 : Le Principe Géométrique : Rechercher la Variance Maximale

Définition / Concept Clé : Recherche de la Meilleure Droite de Projection

Au lieu de projeter sur les anciens axes Z_1 et Z_2 , l'ACP fait pivoter le système de coordonnées d'un angle θ optimal :

Axe PC1 = Direction qui rend maximale la dispersion (variance) des points projetés

Équivalence géométrique de Pythagore : Maximiser la variance des projections orthogonales revient rigoureusement à **minimiser la somme des carrés des distances résiduelles** (perte d'information minimale).

Cas Pratique Biochimie : Application au Modèle Souris

La direction de plus grand allongement de l'ellipse coïncide avec la droite passant par le centre des témoins (minces) et le centre des obèses (lourds). C'est précisément l'axe de la première composante principale (PC1).

Notion 5 : La Première Composante Principale (PC1)

Définition / Concept Clé : Définition Algébrique : Combinaison Linéaire Optimale

La coordonnée (score) de chaque souris sur le nouvel axe PC1 est une somme pondérée des variables centrées-réduites :

$$PC1_i = a_{11}Z_{i1} + a_{12}Z_{i2} \quad \text{avec la contrainte de normalité : } a_{11}^2 + a_{12}^2 = 1$$

Les coefficients (a_{11}, a_{12}) forment le premier **vecteur propre normé** $\mathbf{v}_1$.

Cas Pratique Biochimie : Vecteur Propre Obtenu chez la Souris

Pour notre jeu de données à forte corrélation ($r = 0.96$) :

$$\mathbf{v}_1 = \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix} \Rightarrow PC1_i = 0.707 \cdot Z_{i1} + 0.707 \cdot Z_{i2}$$

Sens biologique : Les deux variables contribuent de façon exactement égale et positive à l'axe PC1. Plus une souris est lourde et adipeuse, plus son score PC1 est fortement positif !

Notion 6 : La Deuxième Composante Principale (PC2) : L'Orthogonalité

Définition / Concept Clé : Définition de l'Axe Orthogonal (Non Corrélé)

Le deuxième axe PC2 doit être **strictement perpendiculaire** à PC1 ($\mathbf{v}_1 \cdot \mathbf{v}_2 = 0$) tout en captant le maximum de la variance résiduelle :

$$\mathbf{v}_2 = \begin{pmatrix} -0.707 \\ +0.707 \end{pmatrix} \Rightarrow \text{PC2}_i = -0.707 \cdot \text{Z}_{i1} + 0.707 \cdot \text{Z}_{i2}$$


Propriété statistique fondamentale : $\text{cor}(\text{PC1}, \text{PC2}) = 0$. Les deux axes sont mathématiquement indépendants !

Cas Pratique Biochimie : Interprétation Biologique du Contraste sur PC2

- ▶ PC2 oppose la masse adipeuse au poids corporel (différence $\text{Z}_{i2} - \text{Z}_{i1}$).
- ▶ Une souris avec un score $\text{PC2} > 0$ possède un tissu adipeux disproportionné par rapport à sa corpulence générale.
- ▶ Une souris avec $\text{PC2} < 0$ est plus musclée ou dense (poids élevé mais adipeux modéré).

Visualisation Graphique : La Rotation des Axes chez la Souris

B. Rotation des Axes : PC1 Maximise l'Inertie, PC2 est Orthogonal



💡 Message Clé à Retenir : Lecture Géométrique

L'axe PC1 (bleu foncé) s'aligne sur le grand axe de l'ellipse de dispersion. L'axe PC2 (turquoise) est orthogonal. Les traits pointillés illustrent la projection orthogonale sans déformation de chaque souris sur PC1.

Notion 7 : Comment l'ACP Réduit 2 Dimensions Corrélées en 1 Seule ?

Définition / Concept Clé : Bilan de Variance : Partition de l'Inertie Totale


- ▶ **Inertie totale de départ** : $\text{Var}(Z_1) + \text{Var}(Z_2) = 1.0 + 1.0 = 2.00$ (Inertie totale = p).
- ▶ **Variance captée par PC1** : $\lambda_1 = 1.93$ (soit $\frac{1.93}{2.00} \times 100 = 96.5\%$ de toute l'information !).
- ▶ **Variance résiduelle sur PC2** : $\lambda_2 = 0.07$ (soit $\frac{0.07}{2.00} \times 100 = 3.5\%$).

Message Clé à Retenir : La Décision de Réduction : Abandonner PC2

En abandonnant purement et simplement l'axe PC2, le biologiste :

1. Ne perd que 3.5% d'aléa ou de bruit individuel mineur.
2. **Conserve 96.5% de la variabilité biologique réelle** dans une seule dimension composite (PC1).
3. Réduit un tableau 2D complexe en une échelle 1D continue et intuitive.

Visualisation Graphique : Les Souris Projetées sur l'Axe Unique PC1



💡 Message Clé à Retenir : Séparation Phénotypique en 1D

Sur l'axe 1D unique PC1, la frontière entre souris témoins (vert) et souris obèses (rouge) est absolue ($p < 10^{-8}$). La distribution montre une séparation bimodale parfaite.

Notion 8 : Sens Biologique du Nouveau Score 1D

Définition / Concept Clé : L'Émergence d'une Variable Synthétique Latente

L'axe PC1 n'est plus ni la variable « Poids » ni la variable « Tissu Adipeux » :
Il s'agit d'un **Score Composite d'Adiposité Globale / Sévérité Métabolique**.

Cas Pratique Biochimie : Application Biomédicale & Pharmacologique

- ▶ **Souris Témoins (Chow)** : Scores PC1 négatifs ($PC1 \in [-2.5; -0.5]$). Phénotype mince et métaboliquement sain.
- ▶ **Souris HFD (Régime gras)** : Scores PC1 positifs ($PC1 \in [+0.5; +2.8]$). Phénotype obèse pathologique.
- ▶ **Évaluation d'un traitement antidiabétique** : Si une molécule thérapeutique ramène les scores PC1 des souris HFD de +2.2 à -0.4, son efficacité globale est démontrée sur un indice synthétique validé sans redondance !

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Notion 9 : La Matrice des Corrélations R ($p \times p$)

Définition / Concept Clé : Structure Mathématique de la Matrice R

Pour p variables biologiques centrées-réduites, la matrice de corrélation s'écrit :

$$R = \frac{1}{n} Z^T Z = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix} \quad \text{Dans notre exemple 2D : } R = \begin{pmatrix} 1.00 & 0.96 \\ 0.96 & 1.00 \end{pmatrix}$$

Cas Pratique Biochimie : Propriétés Capitales pour l'ACP

- ▶ R est une matrice **carrée symétrique** ($r_{jk} = r_{kj}$) semi-définie positive.
- ▶ Sa diagonale principale est constituée exclusivement de 1 (corrélation de chaque variable avec elle-même).
- ▶ C'est cette matrice R qui est diagonalisée pour extraire les axes de variabilité biologique.

Notion 10 : L'Équation aux Valeurs Propres : $R\mathbf{v} = \lambda\mathbf{v}$

Définition / Concept Clé : Théorie Spectrale de Diagonalisation

La recherche des axes principaux équivaut à trouver les scalaires λ et les vecteurs $\mathbf{v} \neq 0$ vérifiant :

$$R\mathbf{v} = \lambda\mathbf{v} \iff (R - \lambda I)\mathbf{v} = 0 \implies \det(R - \lambda I) = 0$$

Cas Pratique Biochimie : Résolution Analytique Complète sur l'Exemple Souris ($p = 2$)

$$\det \begin{pmatrix} 1 - \lambda & 0.96 \\ 0.96 & 1 - \lambda \end{pmatrix} = (1 - \lambda)^2 - 0.96^2 = 0 \implies (1 - \lambda) = \pm 0.96$$

$$\lambda_1 = 1 + 0.96 = 1.96, \quad \lambda_2 = 1 - 0.96 = 0.04$$

$\implies$ La première valeur propre capte 1.96 sur une inertie totale de 2, soit **98.0%** de l'information théorique !

Notion 11 : La Trace de la Matrice & Conservation de l'Inertie Totale

Définition / Concept Clé : Théorème Fondamental de Conservation de l'Inertie

La somme de toutes les valeurs propres λ_k est rigoureusement égale à la **trace** de la matrice R :

$$\sum_{k=1}^p \lambda_k = \text{Tr}(\mathbf{R}) = p \quad (\text{Le nombre total de variables de départ})$$

Message Clé à Retenir : Principe Fondamental de Conservation

- ▶ L'ACP ne génère aucune information nouvelle et n'en détruit aucune lors de la diagonalisation.
- ▶ L'inertie totale de départ (p) est simplement **redistribuée de façon décroissante** :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

- ▶ Les premiers axes concentrent la quasi-totalité du signal utile, tandis que les derniers ne contiennent que du bruit de mesure.

Notion 12 : Le Pourcentage de Variance Expliquée

Définition / Concept Clé : Formules du Taux d'Inertie par Axe & Taux Cumulé

Pourcentage de variabilité biologique capté par le k -ième axe factoriel :

$$\% \text{ Inertie}(\text{PC}_k) = \frac{\lambda_k}{p} \times 100, \quad \% \text{ Cumulé}(K) = \frac{\sum_{k=1}^K \lambda_k}{p} \times 100$$

Cas Pratique Biochimie : Application Numérique sur le Panel Multivarié ($p = 5$ Biomarqueurs TD 05)

Soient 5 biomarqueurs (MDA, Catalase, SOD, IL-6, TNF- α) avec $\lambda = [2.65, 1.25, 0.60, 0.35, 0.15]$:

- ▶ $\text{PC1} : \frac{2.65}{5} \times 100 = 53.0\%$ | $\text{PC2} : \frac{1.25}{5} \times 100 = 25.0\%$
- ▶ $\text{PC3} : \frac{0.60}{5} \times 100 = 12.0\%$ | $\text{PC4} : \frac{0.35}{5} \times 100 = 7.0\%$ | $\text{PC5} : \frac{0.15}{5} \times 100 = 3.0\%$
- ▶ **Inertie cumulée du premier plan (PC1 – PC2) : $53.0\% + 25.0\% = 78.0\%$.**
- ▶ Deux axes suffisent à résumer près de 80% de toute la pathologie oxydative et inflammatoire !

Notion 13 : Critères de Sélection du Nombre d'Axes Factoriels


Définition / Concept Clé : Les Deux Règles Internationales de Décision

1. **Critère de Kaiser-Guttman ($\lambda_k \geq 1.0$)** : Une composante principale ne mérite d'être conservée que si elle explique **plus de variance qu'une variable unitaire de départ**. Tout axe ayant $\lambda < 1.0$ contient moins d'information qu'un seul gène ou métabolite isolé.
2. **Règle du Coude de Cattell (Scree Plot)** : Sur le graphique décroissant des valeurs propres, repérer le point d'inflexion où la chute s'atténue brusquement (le « coude » géologique) et s'arrêter juste avant ce palier.

Cas Pratique Biochimie : Application au Panel de Biomarqueurs

- ▶ $\lambda_1 = 2.65 \geq 1.0$ (Conservé) | $\lambda_2 = 1.25 \geq 1.0$ (Conservé).
- ▶ $\lambda_3 = 0.60 < 1.0$ (Rejeté) | $\lambda_4 = 0.35$ (Rejeté) | $\lambda_5 = 0.15$ (Rejeté).
- ▶ $\Rightarrow$ On retient formellement ****2 axes factoriels**** (PC1 et PC2), totalisant 78% de la variance.

Visualisation Graphique : L'Éboulis des Valeurs Propres (Scree Plot)



💡 Message Clé à Retenir : Décision Visuelle Immédiate

Les deux premières barres dépassent nettement la ligne pointillée de Kaiser ($\lambda = 1$). Le coude d'inflexion s'amorce à PC2. On retient le plan 2D (PC1 - PC2) sans hésitation.

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Notion 14 : Les Coordonnées des Variables sur les Axes (Loadings)

Définition / Concept Clé : Formule Mathématique des Coordonnées Factorielles

La coordonnée de la variable biologique j sur l'axe principal k est rigoureusement égale à son ****coefficient de corrélation linéaire**** avec cette composante :

$$F_{jk} = \text{cor}(X_j, \text{PC}_k) = v_{jk} \sqrt{\lambda_k} \quad \text{avec} \quad -1 \leq F_{jk} \leq +1$$

Cas Pratique Biochimie : Interprétation Directe pour le Biologiste

- ▶ Si $F_{j1} = +0.92$ (cas de l'IL-6 sur PC1) : la cytokine est extraordinairement corrélée positivement à l'axe PC1.
- ▶ Si $F_{j1} = -0.80$ (cas de la Catalase sur PC1) : l'enzyme antioxydante est fortement corrélée négativement à PC1.
- ▶ $\Rightarrow$ Les coordonnées indiquent immédiatement le sens et l'intensité de liaison entre la molécule et l'axe.

Notion 15 : Le Cercle des Corrélations de Rayon $R = 1$

Définition / Concept Clé : Construction Géométrique du Disque Unité

Puisqu'un coefficient de corrélation ne peut jamais dépasser $+1$ ni être inférieur à -1 :

$$[r(X_j, \text{PC1})]^2 + [r(X_j, \text{PC2})]^2 \leq 1 \implies \text{Toutes les variables sont contenues dans un cercle de rayon 1}$$

Cas Pratique Biochimie : Signification de la Longueur du Vecteur Variable

- ▶ La flèche part de l'origine $(0, 0)$ et se termine aux coordonnées (F_{j1}, F_{j2}) .
- ▶ **Flèche proche de la circonférence** ($r \rightarrow 1$) : La variable est parfaitement expliquée et modélisée par le plan 1-2.
- ▶ **Flèche courte proche du centre** $(0, 0)$: La variable est mal représentée sur ce plan (son information est sur PC3 ou PC4).

Notion 16 : Qualité de Représentation d'une Variable : Le $\cos^2$

Définition / Concept Clé : Formule Mathématique du $\cos^2$

La proportion de variance de la variable X_j captée par l'axe k correspond au carré de sa coordonnée :

$$\cos^2(X_j, PC_k) = [r(X_j, PC_k)]^2 = F_{jk}^2, \quad \cos_{1+2}^2 = \cos^2(X_j, PC1) + \cos^2(X_j, PC2)$$

Cas Pratique Biochimie : Calcul Numérique Pas-à-Pas (Données TD 05)

- ▶ **MDA** ($F_1 = +0.88, F_2 = -0.20$) : $\cos^2(PC1) = 0.88^2 = \mathbf{0.774}$, $\cos^2(PC2) = (-0.20)^2 = \mathbf{0.040}$.
- ▶ **Qualité globale sur le plan** : $\cos_{1+2}^2 = 0.774 + 0.040 = \mathbf{0.814}$ (soit 81.4% de sa variance expliquée).
- ▶ **Règle de validation** : Si $\cos_{1+2}^2 \geq 0.60$, la variable est jugée très fidèlement représentée et son interprétation est solide.

Notion 17 : Règle de Lecture 1 : Angle Aigu ($< 90^\circ$, Corrélation Positive)

Définition / Concept Clé : Signification Géométrique : Flèches Pointant dans la Même Direction

Le cosinus de l'angle θ entre deux vecteurs variables approxime leur coefficient de corrélation mutuel :

$$\cos(\theta) \approx r(X_j, X_l) \implies \text{Angle aigu } (\theta < 90^\circ) \iff r(X_j, X_l) > 0$$

Cas Pratique Biochimie : Interprétation Biologique Concrète

Faisceau IL-6, TNF- α et MDA :

- ▶ Les flèches de l'IL-6 (+0.92) et du MDA (+0.88) forment un angle très fermé ($\theta \approx 15^\circ$).
- ▶ $\implies$ L'élévation de la cytokine pro-inflammatoire s'accompagne systématiquement d'une flambée de peroxydation lipidique membranaire chez l'animal malade.
- ▶ Deux variables très proches sont **redondantes** dans le panel diagnostique.

Notion 18 : Règle de Lecture 2 : Angle Droit ($\approx 90^\circ$, Indépendance)

Définition / Concept Clé : Signification Géométrique : Vecteurs Orthogonaux

Deux flèches formant un angle proche de 90° ont un cosinus nul :

$$\cos(90^\circ) = 0 \iff r(X_j, X_l) \approx 0 \quad (\text{Absence totale de corrélation linéaire})$$

Cas Pratique Biochimie : Interprétation Biologique Concrète

SOD ($F_1 = -0.10, F_2 = +0.85$) vs **MDA** ($F_1 = +0.88, F_2 = -0.20$) :

- ▶ Les deux flèches sont quasiment perpendiculaires ($\theta \approx 95^\circ$).
- ▶ $\implies$ L'activité enzymatique de la superoxyde dismutase (SOD) varie de manière totalement indépendante de la peroxydation du MDA.
- ▶ Ces deux molécules explorent deux facettes physiologiques distinctes et non redondantes !

Notion 19 : Règle de Lecture 3 : Angle Plat ($\approx 180^\circ$, Antagonisme)

Définition / Concept Clé : Signification Géométrique : Flèches Diamétralement Opposées

Deux flèches pointant dans des directions opposées forment un angle proche de 180° :

$$\cos(180^\circ) = -1 \iff r(X_j, X_l) < 0 \quad (\text{Forte corrélation négative / Anti-corrélation})$$

Cas Pratique Biochimie : Interprétation Biologique Concrète

Catalase ($F_1 = -0.80$) vs **MDA** ($F_1 = +0.88$) :

- ▶ Les deux flèches pointent à l'opposé le long de l'axe horizontal PC1.
- ▶ $\implies$ Quand la peroxydation lipidique (MDA) s'effondre chez les témoins sains, la défense antioxydante hépatique par la Catalase est maximale.
- ▶ À l'inverse, l'oxydation sévère chez les souris malades s'accompagne d'un épuisement enzymatique en Catalase.

Notion 20 : Contribution d'une Variable à l'Axe (CTR)

Définition / Concept Clé : Formule Mathématique de la Contribution

Pourcentage de l'inertie de l'axe PC_k apporté par la variable X_j :

$$CTR_{jk} = \frac{F_{jk}^2}{\lambda_k} \times 100 \quad \text{avec} \quad \sum_{j=1}^p CTR_{jk} = 100\%$$

Seuil de significativité théorique : Une variable contribue significativement à l'axe si sa contribution dépasse la moyenne équitable : $CTR > \frac{100\%}{p} = \frac{100\%}{5} = \mathbf{20.0\%}$.

Cas Pratique Biochimie : Dénomination Biologique Objective de l'Axe PC1

- ▶ Contribution de l'IL-6 à PC1 : $CTR = \frac{0.92^2}{2.65} \times 100 = \frac{0.8464}{2.65} \times 100 = \mathbf{31.9\%} \gg 20\%$.
- ▶ Contribution du MDA à PC1 : $CTR = \frac{0.88^2}{2.65} \times 100 = \frac{0.7744}{2.65} \times 100 = \mathbf{29.2\%} \gg 20\%$.
- ▶ $\Rightarrow$ L'axe PC1 est formellement baptisé : ****« Axe du Stress Oxydant & de l'Inflammation Aiguë »****.

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Notion 21 : Coordonnées des Échantillons : Les Scores Factoriels

Définition / Concept Clé : Formule Mathématique du Score Individuel

Chaque individu biologique (souris ou patient i) reçoit une nouvelle coordonnée S_{ik} sur l'axe PC_k par combinaison linéaire de ses Z -scores :

$$S_{ik} = \sum_{j=1}^p Z_{ij}v_{jk} = Z_{i1}v_{1k} + Z_{i2}v_{2k} + \cdots + Z_{ip}v_{pk}$$

Cette valeur sans dimension S_{ik} est le ****Score Factoriel****.

Cas Pratique Biochimie : Sens Clinique des Scores

- ▶ Un patient avec un score $S_{i1} = +3.2$ se situe très loin à droite sur l'axe du stress oxydant.
- ▶ Le tableau initial $n \times p$ (ex: 40×7) est désormais réduit à un tableau léger $n \times 2$ (40×2 scores : PC1 et PC2).
- ▶ On peut représenter l'ensemble des 40 malades sur un plan cartésien 2D classique !

Notion 22 : Propriétés Statistiques Fondamentales des Scores

Définition / Concept Clé : Centrage & Variance des Composantes Principales

- ▶ **Moyenne Nulle** : $\mathbb{E}(\text{PC}_k) = \frac{1}{n} \sum_{i=1}^n S_{ik} = 0 \implies$ Le centre $(0,0)$ est le « profil moyen ».
- ▶ **Variance Égale à la Valeur Propre** : $\text{Var}(\text{PC}_k) = \frac{1}{n} \sum_{i=1}^n S_{ik}^2 = \lambda_k \implies$ Dispersion égale à λ_k .
- ▶ **Orthogonalité Absolue** : $\text{cor}(\text{PC}_k, \text{PC}_l) = 0$ pour tout $k \neq l$.

Message Clé à Retenir : Conséquence Visuelle

Le nuage des scores est toujours plus étiré horizontalement le long de PC1 que verticalement le long de PC2 car $\lambda_1 > \lambda_2$.

Notion 23 : L'Interprétation Conjointe (Biplot Conceptuel)


Définition / Concept Clé : Règle de Superposition des Deux Espaces

L'espace des variables (cercle) et l'espace des individus (score plot) s'interprètent en miroir direct :

Cas Pratique Biochimie : La Clé de Lecture Physiopathologique

- ▶ Un patient projeté dans la région où pointent les flèches IL-6 et MDA présente des taux sériques anormalement élevés de ces deux marqueurs.
- ▶ Un patient projeté à l'opposé exact de ces flèches possède des taux bas d'IL-6 et de MDA, mais des taux élevés de Catalase.
- ▶ Les individus proches du centre (0,0) possèdent un profil standard sans anomalie biologique saillante.

Visualisation Graphique : Cercle des Corrélations & Plan des Patients



💡 Message Clé à Retenir : Séparation Métabolique Clinique Nette

À gauche : Cercle des variables identifiant les clusters métaboliques. À droite : Plan des patients séparant parfaitement les Témoins sains (vert), les Diabétiques (bleu sur l'Axe 1) et les Stéatohépatites NASH (orange sur l'Axe 2).

Notion 24 : La Nature Non Supervisée de l'ACP

Définition / Concept Clé : Définition Statistique : Aucune Connaissance Préalable des Classes

L'ACP est un algorithme **strictement non supervisé** :

- ▶ La matrice de calcul Z ne contient que les concentrations biochimiques continues (X_j).
- ▶ Le diagnostic clinique ou le groupe de traitement (Témoin, Diabétique, NASH) n'est **jamais fourni au modèle**.

Cas Pratique Biochimie : Pourquoi le Regroupement Spontané a-t-il une Valeur Inestimable ?

- ▶ Lorsque les individus d'un même groupe se rassemblent spontanément en amas distincts sur le graphique, c'est la démonstration rigoureuse que ****l'empreinte biologique globale porte la signature intrinsèque de la pathologie****.
- ▶ Cela valide la pertinence du panel omique sans biais de sélection artificiel.

Notion 25 : Projection d'Individus & Variables Supplémentaires

Définition / Concept Clé : Principe des Éléments Illustratifs (Passifs)

On peut projeter de nouvelles observations sans recalculer ni déformer les axes de référence :

$$S_{\text{nouveau},k} = \sum_{j=1}^p \left(\frac{X_{\text{nouveau},j} - \bar{X}_j}{s_j} \right) v_{jk}$$

Cas Pratique Biochimie : Application au Diagnostic d'un Patient Inconnu

Cas d'un nouveau patient admis aux urgences :

- ▶ On dose ses 7 biomarqueurs plasmatiques. On calcule ses coordonnées : PC1 = +2.40, PC2 = +1.85.
- ▶ En reportant ce point sur le plan de référence, il tombe en plein cœur du cluster « Atteinte Hépatique NASH ».
- ▶ L'ACP oriente immédiatement le clinicien vers une biopsie hépatique ciblée !

Progression Pédagogique du Chapitre V

L'Ère des Données Omiques & Le Besoin de Réduction

Exemple Fil Conducteur chez la Souris : La Redondance Linéaire 2D

Géométrie de l'ACP : Rotation des Axes & Réduction vers 1D

Algèbre Matricielle : Matrice R, Valeurs Propres & Kaiser

L'Espace des Variables : Le Cercle des Corrélations

L'Espace des Individus : Le Plan Factoriel des Scores (Score Plot)

Pièges Méthodologiques, Sélection de Biomarqueurs & Synthèse

Notion 26 : Piège 1 : Les Variables Mal Représentées ($\cos^2$ Faible)

⚠ Piège Fréquent en Biologie : L'Illusion d'Optique des Variables Proches du Centre

- ▶ Si une flèche est courte et reste proche de l'origine (ex: longueur $r < 0.40 \implies \cos^2 < 0.16$), la variable est située hors du plan 1-2.
- ▶ **Erreur grave fréquente** : Dédire que cette molécule n'a aucun rôle ou qu'elle est indépendante des autres.
- ▶ **Réalité** : Son information s'exprime sur les axes suivants (PC3 ou PC4). Interpréter sa proximité sur le plan 1-2 est un contresens géométrique !

💡 Message Clé à Retenir : Règle de Bonne Pratique

Ne jamais interpréter la position d'une variable dont la qualité de représentation globale $\cos^2_{1+2}$ est inférieure à 0.50 (ou examiner son cercle sur le plan 1-3).

Notion 27 : Piège 2 : L'Effet Taille (Size Effect) en Morphométrie

⚠ Piège Fréquent en Biologie : Quand l'Axe 1 N'est qu'un Réflecteur de Corpulence

En biologie animale et pharmacologie :

- ▶ Si toutes les variables sont morphométriques ou de volumétrie tissulaire (poids foie, poids rate, adiposité, longueur du tibia), toutes les corrélations r_{jk} sont positives.
- ▶ L'axe PC1 capte alors un pur **« Effet de Taille »** général ($\lambda_1 > 80\%$).
- ▶ Les animaux se classent simplement du plus petit au plus gros sur PC1.

💡 Message Clé à Retenir : Où se Cache l'Information Biologique Fine ?

Dans ce cas précis, la véritable information de forme ou de dysfonction d'organe spécifique réside sur l'**Axe PC2** (qui oppose par exemple le volume adipeux à la masse musculaire). Le chercheur averti doit regarder l'axe secondaire !

Notion 28 : Sélection de Biomarqueurs & Élimination de la Redondance

Définition / Concept Clé : Conception d'une Trousse de Diagnostic Rapide (Point-of-Care)

Doser 10 biomarqueurs en routine hospitalière est coûteux et redondant. L'ACP permet d'extraire le panel minimal d'information maximale :

Cas Pratique Biochimie : Application Stratégique au Panel du TD 05

1. **Axe PC1 (Inflammation / Stress oxydant)** : L'IL-6 ($F_1 = 0.92, \cos^2 = 0.85$) et le TNF- α ($F_1 = 0.85, \cos^2 = 0.72$) sont redondants. On conserve uniquement ****IL-6****, molécule la mieux corrélée à l'axe.
2. **Axe PC2 (Défense antioxydante spécifique)** : La ****SOD**** ($F_2 = 0.85, \cos^2 = 0.72$) capture orthogonalement l'axe 2.
3. **Bilan analytique** : Deux biomarqueurs bien choisis (IL-6 + SOD) suffisent à capturer l'ensemble de la cartographie pathologique avec une économie réactive de 60% !

Synthèse : L'Algorithme Décisionnel de l'ACP pour le Biochimiste

Définition / Concept Clé : Phase 1 : Préparation & Validation Algébrique

- ▶ Centrer et réduire la matrice : $Z_{ij} = (X_{ij} - \bar{X}_j)/s_j \rightarrow$ Calculer la matrice des corrélations R .
- ▶ Extraire les valeurs propres $\lambda_k \rightarrow$ Vérifier $\sum \lambda_k = p$.
- ▶ Choisir le nombre d'axes via Kaiser ($\lambda \geq 1$) et l'éboulis (scree plot) pour atteindre $> 70-80\%$ d'inertie.

Cas Pratique Biochimie : Phase 2 : Interprétation Biologique Conjointe (Biplot)

- ▶ **Cercle des variables** : Vérifier les $\cos^2$, interpréter les angles (aigus = co-régulation, droits = indépendance, plats = antagonisme). Nommer les axes avec les CTR.
- ▶ **Plan des individus** : Repérer les clusters spontanés, identifier les phénotypes atypiques, projeter les inconnus.

Fin du Chapitre V

Félicitations ! Vous maîtrisez la réduction factorielle et l'ACP normée.

Prochaine étape : Comment regrouper automatiquement les profils d'individus en classes homogènes ?

Chapitre VI : Classification Ascendante Hiérarchique (CAH) & Dendrogrammes

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie

Université M'Hamed Bougara de Boumerdès (UMBB)