

Biostatistiques Appliquées & Modélisation du Vivant

Chapitre VI : Classification Ascendante Hiérarchique (CAH) & Dendrogrammes

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée

Université M'Hamed Bougara de Boumerdès (UMBB)

Année Universitaire 2024 – 2025

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 1 : Apprentissage Supervisé vs Non-Supervisé en Biologie

Définition / Concept Clé : Fondement Conceptuel de la Découverte Non-Supervisée

Contrairement aux approches supervisées (Régression linéaire, ANOVA, classification guidée) où une variable cible Y étiquetée est connue :

- ▶ En classification non-supervisée (*Clustering*), **aucune étiquette diagnostique n'est fournie à l'algorithme.**
- ▶ L'algorithme opère exclusivement sur les matrices d'abondances ou d'expressions pour découvrir la structure latente naturelle.
- ▶ Objectif : révéler des sous-groupes homogènes (*clusters*) d'individus ou de biomolécules partageant des caractéristiques physico-chimiques communes.

Cas Pratique Biochimie : Application Médicale : Découverte de Sous-Types Tumoraux

En oncologie moléculaire, des patientes atteintes d'un cancer du sein cliniquement semblable présentent en réalité des profils transcriptomiques très distincts (Luminal A, Luminal B, HER2+, Basal-like). Le clustering non-supervisé permet de redéfinir la nosologie des maladies sans a priori humain.

Notion 2 : Principe Fondamental de la CAH (Approche Ascendante)

Définition / Concept Clé : Algorithme Agglomératif « Du Bas vers le Haut » (Bottom-Up)

La Classification Ascendante Hiérarchique (CAH) procède par regroupements itératifs successifs :

1. **État Initial (N classes)** : Chaque échantillon biologique forme un groupe singleton isolé : $\{X_1\}, \{X_2\}, \dots, \{X_N\}$.
2. **Fusion Itérative** : À chaque étape, on recherche la paire d'entités les plus proches (distance minimale) et on les fusionne en une nouvelle classe.
3. **État Final (1 classe)** : L'algorithme s'arrête lorsque l'ensemble des échantillons est réuni en un unique macro-groupe racine.

Message Clé à Retenir : La Propriété d'Emboîtement Hiérarchique

Les partitions obtenues sont strictement emboîtées. L'intégralité de l'historique des fusions est conservée et représentée sous la forme d'un arbre binaire : le **Dendrogramme**.

Notion 3 : Domaines d'Application Clés en Biochimie & Santé

Définition / Concept Clé : Typologie des Objets à Classifier

En biologie moderne, la CAH est appliquée selon deux axes d'analyse orthogonaux :

- ▶ **Clustering des Individus / Échantillons (N)** : Identifier des sous-populations de patients, des souches bactériennes ou des réponses toxiques.
- ▶ **Clustering des Variables / Biomolécules (p)** : Regrouper des gènes, des métabolites ou des protéines partageant des patrons d'activation identiques.

Cas Pratique Biochimie : Exemples Pratiques au Laboratoire

- ▶ **Microbiologie Médicale** : Regroupement d'isolats bactériens nosocomiaux selon leur résistance aux carbapénèmes et céphalosporines.
- ▶ **Génomique Fonctionnelle** : Identification de modules de gènes corégulés au cours du cycle cellulaire ou d'une infection virale.
- ▶ **Écotoxicologie** : Classification de biomarqueurs de stress oxydatif chez des bivalves exposés à des xénobiotiques.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 4 : Contexte Biologique : Résistance aux Antibiotiques en Réanimation

Définition / Concept Clé : Modèle d'Étude : Surveillance d'Infections Nosocomiales

Dans une unité de réanimation du CHU, des souches de *Klebsiella pneumoniae* sont isolées chez des patients sous antibiothérapie prolongée. On suspecte l'émergence d'un clone bactérien multirésistant.

Cas Pratique Biochimie : Mécanismes Moléculaires Mesurés par RT-qPCR

Deux mécanismes enzymatiques et structuraux majeurs sont quantifiés simultanément en RT-qPCR relative ($\Delta\Delta C_t$) :

- ▶ **Gène G_1 (Pompe d'Efflux AcrAB-TolC)** : Surexpression expulsant activement les antibiotiques hors de la bactérie.
- ▶ **Gène G_2 (β -Lactamase à Spectre Élargi CTX-M)** : Enzyme hydrolysant le noyau β -lactame des pénicillines et céphalosporines.

Notion 5 : Données Expérimentales Brutes de RT-qPCR ($N = 4$ Isolats)

Définition / Concept Clé : Tableau d'Expression Relative ($\Delta\Delta Ct$)

On analyse 4 isolats bactériens notés S_1, S_2, S_3, S_4 . Les expressions relatives des deux gènes sont consignées ci-dessous :

Isolat Bactérien	Isolat S_1	Isolat S_2	Isolat S_3	Isolat S_4
Gène G_1 (Pompe d'Efflux)	1.0	2.0	5.0	6.0
Gène G_2 (β -Lactamase)	2.0	1.0	5.0	4.0
Coordonnées Vectorielles	$\mathbf{x}_1 = (1.0 ; 2.0)$	$\mathbf{x}_2 = (2.0 ; 1.0)$	$\mathbf{x}_3 = (5.0 ; 5.0)$	$\mathbf{x}_4 = (6.0 ; 4.0)$

Cas Pratique Biochimie : Première Constatation Biologique

À vue d'œil, S_1 et S_2 présentent des niveaux d'expression faibles à modérés (≤ 2.0), tandis que S_3 et S_4 affichent des niveaux d'expression massifs (≥ 4.0 – 6.0). Comment l'algorithme va-t-il formaliser mathématiquement ces regroupements ?

Notion 6 : Représentation Géométrique dans l'Espace des Gènes (G_1, G_2)

Définition / Concept Clé : Visualisation Spatiale des Isolats

Chaque isolat bactérien correspond à un point dans l'espace $\mathbb{R}^2$ défini par les axes des deux gènes :

- ▶ Axe des abscisses : niveau d'expression de G_1 (Efflux).
- ▶ Axe des ordonnées : niveau d'expression de G_2 (β -lactamase).

Message Clé à Retenir : Intérêt de la Géométrie pour la Classification

Classifier ces bactéries revient à identifier des îlots denses de points géographiquement proches dans cet espace vectoriel, séparés par de grands espaces vides de phénotypes inexistants.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 7 : Propriétés Fondamentales d'une Distance Mathématique

Définition / Concept Clé : Les 4 Axiomes Fondamentaux d'une Métrique

Une fonction $d(A, B)$ mesurant la dissimilarité entre deux profils biologiques A et B est une distance mathématique au sens strict si et seulement si elle vérifie pour tous A, B, C :

1. **Positivité** : $d(A, B) \geq 0$.
2. **Séparation** : $d(A, B) = 0 \iff A = B$ (deux bactéries identiques ont une dissimilarité nulle).
3. **Symétrie** : $d(A, B) = d(B, A)$ (la distance de A à B est égale à celle de B à A).
4. **Inégalité Triangulaire** : $d(A, C) \leq d(A, B) + d(B, C)$ (le trajet direct est le plus court).

Message Clé à Retenir : Impact sur l'Analyse

Ces axiomes garantissent que la géométrie de l'arbre (dendrogramme) possède une cohérence métrique rigoureuse sans boucle temporelle ni inversion de hauteur.

Notion 8 : La Distance Euclidienne (d_E) : Définition & Formule

Définition / Concept Clé : Définition Géométrique en Ligne Droite

Pour deux échantillons $A = (x_{A1}, \dots, x_{Ap})$ et $B = (x_{B1}, \dots, x_{Bp})$ caractérisés par p paramètres :

$$d_E(A, B) = \sqrt{\sum_{k=1}^p (x_{Ak} - x_{Bk})^2} = \sqrt{(x_{A1} - x_{B1})^2 + (x_{A2} - x_{B2})^2 + \dots + (x_{Ap} - x_{Bp})^2}$$

Cas Pratique Biochimie : Calcul Numérique entre les Isolats $S_1(1, 2)$ et $S_2(2, 1)$

$$d_E(S_1, S_2) = \sqrt{(1.0 - 2.0)^2 + (2.0 - 1.0)^2} = \sqrt{(-1)^2 + (+1)^2} = \sqrt{1 + 1} = \sqrt{2} \approx \mathbf{1.414}$$

Cette distance mesure l'écart géométrique direct entre les profils de ces deux premières souches bactériennes.

Notion 9 : La Distance de Manhattan (d_M ou City-Block)

Définition / Concept Clé : Définition en Somme des Écarts Absolus

La distance de Manhattan correspond au déplacement en grille le long des axes de coordonnées :

$$d_M(A, B) = \sum_{k=1}^p |x_{Ak} - x_{Bk}| = |x_{A1} - x_{B1}| + |x_{A2} - x_{B2}| + \cdots + |x_{Ap} - x_{Bp}|$$

Cas Pratique Biochimie : Application Numérique Comparée (S_1 vs S_2)

$$d_M(S_1, S_2) = |1.0 - 2.0| + |2.0 - 1.0| = 1.0 + 1.0 = \mathbf{2.000}$$

- ▶ **Propriété clé** : La distance de Manhattan n'élève pas les écarts au carré.
- ▶ **Conséquence biologique** : Elle est beaucoup moins sensible aux valeurs aberrantes ou extrêmes (*outliers*) que la distance euclidienne.

Notion 10 : La Distance de Corrélacion ($d_{\text{cor}} = 1 - r$)

Définition / Concept Clé : Mesure de la Similarité de Forme / Cinétique

Lorsque deux profils présentent des cinétiques parallèles mais avec des échelles absolues différentes :

$d_{\text{cor}}(A, B) = 1 - r(A, B)$ où $r(A, B)$ est le coefficient de corrélation linéaire de Pearson.

- ▶ Si $r = +1.0$ (profils parfaitement colinéaires) $\implies d_{\text{cor}} = 0.0$ (ressemblance parfaite).
- ▶ Si $r = 0.0$ (profils indépendants) $\implies d_{\text{cor}} = 1.0$.
- ▶ Si $r = -1.0$ (profils rigoureusement opposés) $\implies d_{\text{cor}} = 2.0$ (dissimilarité maximale).

Cas Pratique Biochimie : Cas Typique en Transcriptomique

Deux gènes induits simultanément suite à un choc thermique possèdent $d_{\text{cor}} \approx 0$, même si le gène A produit 500 copies d'ARNm et le gène B seulement 20 copies.

Notion 11 : L'Impératif de Standardisation (Z-Score) des Variables

Définition / Concept Clé : Le Piège des Unités et Ordres de Grandeur Hétérogènes

Considérons une étude clinique associant la Glycémie (en g/L, variance $s_1^2 = 0.06$) et les Transaminases ALAT (en UI/L, variance $s_2^2 = 900.0$) :

- ▶ Dans la formule de distance : $\Delta x_2^2 = (105 - 45)^2 = 3600$, écrasant complètement $\Delta x_1^2 = (1.6 - 1.1)^2 = 0.25$.
- ▶ La distance euclidienne brute reflète à 99.9% l'ALAT et ignore la glycémie !

Cas Pratique Biochimie : Règle d'Or en Biochimie

Toute CAH appliquée à des variables de natures et d'unités distinctes doit obligatoirement être précédée d'un **centrage-réduction** :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \implies \text{Chaque paramètre acquiert un poids statistique strictement égal (variance} = 1\text{)}.$$

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 12 : Construction de la Matrice de Dissimilarité D_0 ($N \times N$)

Définition / Concept Clé : Propriétés Algébriques de D_0

Pour N échantillons, la matrice de dissimilarité D_0 recense les distances entre toutes les paires possibles :

$$D_0 = \begin{pmatrix} 0 & d(S_1, S_2) & d(S_1, S_3) & \cdots & d(S_1, S_N) \\ d(S_2, S_1) & 0 & d(S_2, S_3) & \cdots & d(S_2, S_N) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ d(S_N, S_1) & d(S_N, S_2) & d(S_N, S_3) & \cdots & 0 \end{pmatrix}$$

- **Diagonale Principale** : Nulle ($d(S_i, S_i) = 0$).
- **Symétrie** : $d(S_i, S_j) = d(S_j, S_i) \implies$ on ne calcule que la partie **triangulaire inférieure**.

Message Clé à Retenir : Complexité Combinatoire

Le nombre de distances deux-à-deux à évaluer s'élève à $\binom{N}{2} = \frac{N(N-1)}{2}$. Pour nos 4 souches : $\frac{4 \times 3}{2} = 6$ calculs.

Notion 13 : Calcul Explicite des 6 Distances Euclidiennes de l'Exemple

Définition / Concept Clé : Application de la Formule Euclidienne sur les 4 Isolats

Rappel des coordonnées : $S_1(1, 2)$, $S_2(2, 1)$, $S_3(5, 5)$, $S_4(6, 4)$.

$$d(S_1, S_2) = \sqrt{(2-1)^2 + (1-2)^2} = \sqrt{1+1} = \sqrt{2} \approx \mathbf{1.414}$$

$$d(S_3, S_4) = \sqrt{(6-5)^2 + (4-5)^2} = \sqrt{1+1} = \sqrt{2} \approx \mathbf{1.414}$$

$$d(S_1, S_3) = \sqrt{(5-1)^2 + (5-2)^2} = \sqrt{4^2+3^2} = \sqrt{16+9} = \sqrt{25} = \mathbf{5.000}$$

$$d(S_2, S_3) = \sqrt{(5-2)^2 + (5-1)^2} = \sqrt{3^2+4^2} = \sqrt{9+16} = \sqrt{25} = \mathbf{5.000}$$

$$d(S_2, S_4) = \sqrt{(6-2)^2 + (4-1)^2} = \sqrt{4^2+3^2} = \sqrt{16+9} = \sqrt{25} = \mathbf{5.000}$$

$$d(S_1, S_4) = \sqrt{(6-1)^2 + (4-2)^2} = \sqrt{5^2+2^2} = \sqrt{25+4} = \sqrt{29} \approx \mathbf{5.385}$$

Notion 14 : La Matrice Triangulaire Inférieure D_0 & Première Fusion

Définition / Concept Clé : Dressage de la Matrice D_0

En insérant les calculs dans la matrice triangulaire inférieure :

	S_1	S_2	S_3	S_4
S_1	0			
S_2	1.414	0		
S_3	5.000	5.000	0	
S_4	5.385	5.000	1.414	0

Cas Pratique Biochimie : Décision Algorithmique

- ▶ Les plus petites distances sont ex aequo : $d(S_1, S_2) = 1.414$ et $d(S_3, S_4) = 1.414$.
- ▶ Regroupements immédiats : **Cluster** $C_1 = \{S_1, S_2\}$ et **Cluster** $C_2 = \{S_3, S_4\}$.
- ▶ Question clé : comment calculer désormais la distance entre ces deux nouveaux groupes ?

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 15 : Définition du Problème : Distance Entre Deux Clusters

Définition / Concept Clé : Le Passage de l'Élément au Groupe

Soient deux clusters $A = \{x_1, \dots, x_{n_A}\}$ et $B = \{y_1, \dots, y_{n_B}\}$ contenant respectivement n_A et n_B échantillons biologiques.

- ▶ Il existe $n_A \times n_B$ distances individuelles reliant un point de A à un point de B .
- ▶ Une méthode d'agrégation (*Linkage Method*) est une règle mathématique permettant de synthétiser ces multiples distances en une valeur unique $D(A, B)$.

Message Clé à Retenir : Impact Décisif sur la Morphologie de l'Arbre

Le choix de la méthode d'agrégation modifie profondément la structure géométrique des clusters détectés (formes sphériques, groupes allongés ou branches étirées).

Notion 16 : Méthode du Saut Minimum (*Single Linkage*)

Définition / Concept Clé : Règle du Plus Proche Voisin

La distance entre deux groupes est définie comme la **distance minimale** entre n'importe quelle paire d'éléments :

$$D_{\min}(A, B) = \min_{x \in A, y \in B} d(x, y)$$

Cas Pratique Biochimie : Application à nos Deux Clusters $C_1 = \{S_1, S_2\}$ et $C_2 = \{S_3, S_4\}$

Les distances croisées valent : $d(S_1, S_3) = 5.0$, $d(S_1, S_4) = 5.385$, $d(S_2, S_3) = 5.0$, $d(S_2, S_4) = 5.0$.

$$D_{\min}(C_1, C_2) = \min(5.000, 5.385, 5.000, 5.000) = \mathbf{5.000}$$

Deux groupes fusionnent dès qu'un seul élément périphérique de l'un est proche d'un élément de l'autre, peu importe l'éloignement des autres membres.

Notion 17 : Le Piège du Single Linkage : L'Effet de Chaînage (*Chaining*)

Définition / Concept Clé : Mécanisme du Chaînage Artificiel

Si des individus biologiques isolés ou du bruit de fond expérimental forment une suite de « ponts » discrets entre deux populations distinctes :

- ▶ Le Single Linkage fusionne ces points de proche en proche un à un en un filament allongé.
- ▶ Il produit des arbres asymétriques où des éléments isolés s'agrègent continuellement à un méga-groupe amorphe.

Piège Fréquent en Biologie : Danger en Diagnostic Médical

En cytométrie en flux ou en séquençage single-cell, la présence d'artéfacts de mesure (doublets cellulaires) amène le Single Linkage à regrouper à tort des sous-populations immunitaires pourtant biologiquement antagonistes !

Notion 18 : Méthode du Saut Maximum (*Complete Linkage*)

Définition / Concept Clé : Règle du Plus Lointain Voisin (Diamètre Maximal)

La distance entre deux groupes est définie comme la **distance maximale** séparant deux éléments :

$$D_{\max}(A, B) = \max_{x \in A, y \in B} d(x, y)$$

Cas Pratique Biochimie : Application Numérique (C_1 vs C_2)

$$D_{\max}(C_1, C_2) = \max(5.000, 5.385, 5.000, 5.000) = \mathbf{5.385} \quad (\text{distance entre } S_1 \text{ et } S_4)$$

- ▶ Pour fusionner, **tous** les éléments des deux groupes doivent être raisonnablement proches.
- ▶ Forme des clusters très compacts, denses et sphériques, mais très sensible aux valeurs extrêmes isolées.

Notion 19 : Méthode du Lien Moyen (*Average Linkage* / UPGMA)

Définition / Concept Clé : Moyenne Arithmétique des Distances Paires

La méthode UPGMA (*Unweighted Pair Group Method with Arithmetic Mean*) calcule la moyenne de toutes les distances :


$$D_{\text{avg}}(A, B) = \frac{1}{n_A \cdot n_B} \sum_{x \in A} \sum_{y \in B} d(x, y)$$

Cas Pratique Biochimie : Application Numérique (C_1 vs C_2)

$$D_{\text{avg}}(C_1, C_2) = \frac{5.000 + 5.385 + 5.000 + 5.000}{2 \times 2} = \frac{20.385}{4} = \mathbf{5.096}$$

- ▶ Représente un compromis robuste et naturel entre le laxisme du Single et la sévérité du Complete.
- ▶ Standard historique pour la reconstruction des arbres phylogénétiques en systématique moléculaire.

Notion 20 : Comparaison Visuelle des 4 Méthodes d'Agrégation (Figure)



💡 Message Clé à Retenir : Synthèse Visuelle pour le Biochimiste

- ▶ **Single :** Arbres dissymétriques à branches étirées (chaînage). À proscrire pour les profils métaboliques.
- ▶ **Complete & Average :** Arbres structurés, bien adaptés aux études de taxonomie bactérienne.
- ▶ **Ward :** Segmente l'échantillon en groupes homogènes d'inertie minimale. Méthode reine en biomédecine.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Définition / Concept Clé : Décomposition de la Variabilité Biologique

En mécanique comme en statistique, l'inertie totale I_{tot} d'un nuage de N points de centre de gravité G se décompose rigoureusement selon la formule de Huygens :

$$I_{\text{tot}} = I_{\text{intra}} + I_{\text{inter}}$$

- ▶ I_{intra} (**Inertie Intra-Classe**) : Mesure la dispersion interne des points autour du centre de leur propre groupe (hétérogénéité résiduelle). On souhaite la **minimiser**.
- ▶ I_{inter} (**Inertie Inter-Classes**) : Mesure l'éloignement mutuel entre les différents groupes. On souhaite la **maximiser**.

Message Clé à Retenir : Loi de Conservation

Comme I_{tot} est constante pour un jeu de données fixé, **minimiser l'inertie intra-classe revient exactement à maximiser la séparation inter-classes !**

Notion 22 : La Formule du Saut d'Inertie de Ward ($\Delta I(A, B)$)

Définition / Concept Clé : Critère de Minimisation de la Variance

Lorsqu'on fusionne deux clusters A et B d'effectifs n_A, n_B et de centres de gravité g_A, g_B , l'inertie intra-classe augmente obligatoirement d'une quantité exacte appelée le **Saut d'Inertie** :

$$\Delta I(A, B) = \frac{n_A \cdot n_B}{n_A + n_B} \cdot d_E^2(g_A, g_B)$$

- ▶ $d_E^2(g_A, g_B)$: Carré de la distance euclidienne entre les barycentres des deux groupes.
- ▶ $\frac{n_A \cdot n_B}{n_A + n_B}$: Masse géométrique réduite pondérant la taille relative des deux groupes.

Cas Pratique Biochimie : Règle Algorithmique de Ward

À chaque étape de l'algorithme, on fusionne la paire de groupes qui produit la **plus faible augmentation d'inertie intra-classe** : $\min \Delta I(A, B)$.

Notion 23 : Pourquoi la Méthode de Ward est la Référence en Biomédecine

Définition / Concept Clé : Propriétés Statistiques Uniques du Critère de Ward

1. **Groupes Compacts et Équilibrés** : Évite la formation de clusters résiduels contenant 99% des échantillons et de multiples singletons sans intérêt.
2. **Lien Direct avec l'ANOVA** : Elle repose sur la même décomposition des carrés de dispersion ($SS_{\text{tot}} = SS_{\text{intra}} + SS_{\text{inter}}$) que l'analyse de variance enseignée aux chapitres I et II.
3. **Hauteurs Interprétables en Énergie / Inertie** : L'axe vertical du dendrogramme représente directement des unités réelles de variance biologique perdue.

Cas Pratique Biochimie : Standard International

Tous les grands consortiums de recherche biomédicale (TCGA en cancérologie, Human Microbiome Project) utilisent par défaut l'algorithme de Ward sur matrices centrées-réduites.

Notion 24 : Étape 1 : Fusion des Singletons S_1 et S_2 ($n_1 = 1, n_2 = 1$)

Définition / Concept Clé : Calcul du Saut d'Inertie Initial

Pour deux points individuels isolés, $g_1 = S_1(1, 2)$ et $g_2 = S_2(2, 1)$:

- Carré de la distance : $d_E^2(S_1, S_2) = (1 - 2)^2 + (2 - 1)^2 = 1 + 1 = 2.0$.
- Facteur d'effectif : $\frac{n_1 \cdot n_2}{n_1 + n_2} = \frac{1 \times 1}{1 + 1} = \frac{1}{2} = 0.5$.

$$\Delta I(S_1, S_2) = 0.5 \times 2.0 = \mathbf{1.000}$$

Cas Pratique Biochimie : Coordonnées du Nouveau Barycentre g_1

Le centre de gravité du nouveau cluster $C_1 = \{S_1, S_2\}$ correspond à la moyenne des profils :

$$g_1 = \left(\frac{1.0 + 2.0}{2} ; \frac{2.0 + 1.0}{2} \right) = (\mathbf{1.500} ; \mathbf{1.500})$$

Biologiquement, ce barycentre définit le profil moyen du groupe de souches sensibles.

Notion 25 : Étape 2 : Fusion des Singletons S_3 et S_4 ($n_3 = 1, n_4 = 1$)

Définition / Concept Clé : Calcul du Saut d'Inertie Associé

Pour $S_3(5, 5)$ et $S_4(6, 4)$:

- ▶ Carré de la distance : $d_E^2(S_3, S_4) = (5 - 6)^2 + (5 - 4)^2 = 1 + 1 = 2.0$.
- ▶ Facteur d'effectif : $\frac{1 \times 1}{1+1} = 0.5$.

$$\Delta I(S_3, S_4) = 0.5 \times 2.0 = \mathbf{1.000}$$

Cas Pratique Biochimie : Coordonnées du Nouveau Barycentre g_2

Le centre de gravité du second cluster $C_2 = \{S_3, S_4\}$ vaut :

$$g_2 = \left(\frac{5.0 + 6.0}{2} ; \frac{5.0 + 4.0}{2} \right) = (\mathbf{5.500} ; \mathbf{4.500})$$

Biologiquement, ce barycentre caractérise le clone bactérien surexprimant massivement les mécanismes de résistance.

Notion 26 : Étape 3 : Fusion Finale des Deux Clusters (C_1 et C_2)

Définition / Concept Clé : Calcul du Saut d'Inertie Majeur

Regroupons maintenant $C_1 = \{S_1, S_2\}$ ($n_1 = 2$) et $C_2 = \{S_3, S_4\}$ ($n_2 = 2$) :

- ▶ Écart entre barycentres : $g_2 - g_1 = (5.5 - 1.5; 4.5 - 1.5) = (4.0; 3.0)$.
- ▶ Carré de la distance : $d_E^2(g_1, g_2) = 4.0^2 + 3.0^2 = 16.0 + 9.0 = \mathbf{25.0}$.
- ▶ Facteur d'effectif pondéré : $\frac{n_1 \cdot n_2}{n_1 + n_2} = \frac{2 \times 2}{2 + 2} = \frac{4}{4} = \mathbf{1.0}$.


$$\Delta I(C_1, C_2) = 1.0 \times 25.0 = \mathbf{25.000}$$

Cas Pratique Biochimie : Révélation Biologique Majeure

La progression des sauts d'inertie est spectaculaire : $1.0 \rightarrow 1.0 \rightarrow \mathbf{25.0}$!

La fusion des deux groupes détruit une quantité colossale d'homogénéité (25 fois plus que les fusions initiales), ce qui prouve de façon irréfutable que ces deux groupes correspondent à deux entités biologiques radicalement distinctes.

Notion 27 : Visualisation Géométrique des Fusions & Barycentres (Figure)



💡 Message Clé à Retenir : Synthèse Géométrique

Les cercles en pointillés délimitent les clusters initiaux très resserrés (C_1, C_2). Le vecteur pointillé reliant les croix g_1 et g_2 illustre l'immense distance ($d_E = 5.0$, $\Delta I = 25.0$) séparant les phénotypes sensibles des phénotypes multi-résistants.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 28 : Anatomie d'un Dendrogramme (Feuilles, Nœuds, Tronc)

Définition / Concept Clé : Structure Arborescente de la Classification

Le dendrogramme est un arbre binaire enraciné dont chaque composant possède une signification précise :

- ▶ **Feuilles (Bas de l'arbre)** : Les échantillons biologiques individuels ($S_1, S_2, \dots, S_N$). Dissimilarité nulle au départ ($h = 0$).
- ▶ **Nœuds (Fourches horizontales)** : Chaque nœud représente la fusion de deux branches en un cluster unifié.
- ▶ **Racine (Sommet de l'arbre)** : Le nœud terminal fusionnant l'intégralité des échantillons dans la population globale.

Message Clé à Retenir : Sens de Lecture Rigoureux

La lecture chronologique de l'algorithme s'effectue strictement de bas en haut (ascendance). L'ordre horizontal des feuilles sur l'axe des abscisses est arbitraire et peut pivoter autour de chaque nœud sans altérer la topologie.

Notion 29 : Signification Métrique de la Hauteur des Branches Verticales

Définition / Concept Clé : Hauteur = Degré de Dissimilarité Biologique

L'ordonnée d'un nœud horizontal correspond exactement à la valeur de l'indice d'agrégation lors de la fusion :

- ▶ Dans une CAH de Ward : $h = \Delta I(A, B)$ (coût en inertie intra-classe de la réunion des deux groupes).
- ▶ **Branches courtes** : Groupes très proches biologiquement, profils d'expression quasiment interchangeables.
- ▶ **Branches verticales longues** : Séparation franche entre deux sous-types profondément différents.

Cas Pratique Biochimie : Règle de Décision Clinique

Plus une branche verticale est haute avant de se ramifier, plus les groupes qu'elle porte sont robustes, reproductibles et cliniquement significatifs.

Notion 30 : Construction Manuelle du Dendrogramme de nos 4 Isolats

Définition / Concept Clé : Graduation Précise de l'Axe des Ordonnées


Reportons les résultats calculés aux Notions 24 à 26 sur le graphique :

- ▶ $h_1 = \Delta I(S_1, S_2) = 1.0$: Premier nœud reliant les feuilles S_1 et S_2 .
- ▶ $h_2 = \Delta I(S_3, S_4) = 1.0$: Deuxième nœud reliant les feuilles S_3 et S_4 .
- ▶ $h_3 = \Delta I(C_1, C_2) = 25.0$: Nœud supérieur réunissant les deux branches à la hauteur 25.0.

Message Clé à Retenir : Observation Visuelle

L'arbre comporte deux petits ponts horizontaux à hauteur $h = 1.0$, surmontés de deux très longues tiges verticales grimpant jusqu'à $h = 25.0$. Cette morphologie en « haltère » démontre sans ambiguïté une bipartition naturelle.

Notion 31 : Le Dendrogramme de Ward avec Ligne de Coupure (Figure)



💡 Message Clé à Retenir : Ligne de Coupure Optimale

Le trait rouge en pointillé matérialise la coupure horizontale optimale. Elle traverse les deux branches verticales les plus longues, divisant automatiquement l'échantillon en $k = 2$ clusters hautement contrastés.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 32 : Le Principe de la Ligne de Coupure Horizontale

Définition / Concept Clé : Du Dendrogramme Continu aux Classes Discrètes

Le dendrogramme fournit une hiérarchie complète (de N individus à 1 groupe), mais le praticien a besoin d'une partition discrète en k classes d'intérêt :

- ▶ Tracer une ligne horizontale de hauteur de coupe h_{cut} coupe l'arbre en un certain nombre de branches verticales indépendantes.
- ▶ Le nombre de branches traversées par la ligne définit exactement le nombre de classes k .
- ▶ Chaque branche qui tombe sous le trait constitue un cluster d'échantillons.

Cas Pratique Biochimie : Application Diagnostique

Fixer la coupure revient à attribuer formellement chaque patient ou bactérie à une catégorie clinique (ex: Classe 1 = Sensible, Classe 2 = Résistante).

Notion 33 : Où Couper ? Le Critère du Plus Grand Saut d'Inertie

Définition / Concept Clé : Règle Mathématique du Saut Maximal


Pour choisir rationnellement la hauteur de coupure sans arbitraire :

- ▶ On classe les fusions par ordre décroissant de hauteur : $\Delta I_1 > \Delta I_2 > \Delta I_3 \dots$
- ▶ On identifie le plus grand saut d'indice : $\max(\Delta I_m - \Delta I_{m+1})$.
- ▶ **Règle d'or** : On positionne la ligne de coupure immédiatement sous le nœud dont la fusion provoquerait la perte d'homogénéité la plus brutale.

Cas Pratique Biochimie : Application à nos Isolats

Le saut entre la fusion finale ($\Delta I = 25.0$) et les fusions précédentes ($\Delta I = 1.0$) est de $25.0 - 1.0 = \mathbf{24.0}$. Couper entre 1.0 et 25.0 (par exemple à $h = 8.5$) isole parfaitement $k = 2$ classes sans dénaturer la cohérence des données.

Notion 34 : La Règle du Coude sur le Graphe des Sauts d'Inertie (Figure)



💡 Message Clé à Retenir : Lecture Graphique de l'Elbow Plot

La courbe bleue montre la chute drastique de l'inertie intra-classe résiduelle à $k = 2$, matérialisée par la barre orange géante du saut d'inertie ($\Delta I = 36.8$). Au-delà de $k = 2$, rajouter des classes ne gagne que des miettes de variance.

Notion 35 : Profilage Biologique Moyen des Classes Obtenues ($k = 2$)

Définition / Concept Clé : Calcul des Centroïdes de Classes

Une fois la partition validée, on calcule la moyenne de chaque biomarqueur au sein de chaque groupe :

Biomarqueur Quantifié	Classe 1 ($n = 2$)	Classe 2 ($n = 2$)	Ratio de Surexpression
Gène G_1 (Efflux)	$\frac{1.0+2.0}{2} = 1.50$	$\frac{5.0+6.0}{2} = 5.50$	$\times 3.67$ (+267%)
Gène G_2 (β -lactamase)	$\frac{2.0+1.0}{2} = 1.50$	$\frac{5.0+4.0}{2} = 4.50$	$\times 3.00$ (+200%)

Message Clé à Retenir : Synthèse Phénotypique

La Classe 2 présente une surexpression conjointe et massive des deux systèmes de défense enzymatique et membranaire par rapport à la Classe 1.

Notion 36 : Caractérisation Clinique & Conséquences Thérapeutiques

Définition / Concept Clé : Dénomination Nosologique des Groupes

L'analyse non-supervisée permet d'établir une nomenclature clinique claire et opérationnelle :

- ▶ **Classe 1** : « **Souches Sensibles / Vulnérables** » : Niveaux basaux d'efflux et de β -lactamase.
- ▶ **Classe 2** : « **Clone Épidémique Multi-Résistant** » : Phénotype hautement pathogène capable d'échapper à la fois aux céphalosporines de 3^e génération et aux fluoroquinolones.

Cas Pratique Biochimie : Impact Immédiat sur la Décision Médicale

- ▶ Isolement strict des patients porteurs du clone Classe 2 en chambre à pression négative.
- ▶ Adaptation immédiate de l'antibiothérapie de première ligne (bascule vers la colistine ou un nouvel inhibiteur de β -lactamase comme le ceftazidime-avibactam).

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 37 : Le Double Clustering Simultané (Lignes $\times$ Colonnes)

Définition / Concept Clé : Principe de la Clustermap Bivariée

La Clustermap représente le summum de l'analyse exploratoire en omique en croisant deux CAH indépendantes sur la même matrice :

1. **CAH sur les Lignes (Échantillons / Patients)** : Réorganise l'ordre des patients pour rassembler les phénotypes similaires.
2. **CAH sur les Colonnes (Gènes / Protéines / Métabolites)** : Réorganise l'ordre des variables pour regrouper les molécules coréglées.

Message Clé à Retenir : Effet Visuel : L'Émergence de Blocs Colorés

Le réordonnancement simultané des deux axes transforme un nuage de pixels bruité en une mosaïque structurée de **blocs homogènes contrastés** (signatures moléculaires).

Notion 38 : Rôle du Dendrogramme Supérieur (Colonnes : Biomarqueurs)

Définition / Concept Clé : Identification des Modules Fonctionnels Co-Activés

L'arbre horizontal placé au sommet de la carte classifie les biomarqueurs en fonction de leur corrélation mutuelle :

- ▶ Deux enzymes catalysant des étapes successives d'une même voie métabolique s'agrègent immédiatement en un sous-arbre commun.
- ▶ Permet d'isoler des grappes fonctionnelles de gènes sans connaître préalablement la physiologie de la bactérie.

Cas Pratique Biochimie : Exemple Concret

Les cytokines pro-inflammatoires (IL-6, TNF- α , CRP) forment un cluster compact de colonnes, tandis que les enzymes antioxydantes (SOD, Catalase, GPx) constituent un second cluster bien distinct.

Notion 39 : Rôle du Dendrogramme Latéral (Lignes : Échantillons)

Définition / Concept Clé : Stratification Clinique des Patients


L'arbre vertical placé à gauche de la carte classe les individus selon la globalité de leur profil biologique :

- ▶ Les témoins sains se regroupent naturellement dans une branche homogène.
- ▶ Les patients sévères ou résistants forment une ou plusieurs branches pathologiques distinctes.
- ▶ Permet de repérer instantanément des patients « atypiques » (répondeurs exceptionnels ou faux négatifs).

Message Clé à Retenir : Double Information Intégrée

Chaque case colorée de la matrice se trouve désormais à l'intersection d'un **module moléculaire défini** et d'un **sous-groupe de patients caractérisé**.

Notion 40 : Visualisation Complète : La Clustermap en Action (Figure)



💡 Message Clé à Retenir : Clé de Lecture Visuelle

- ▶ **Rouge vif** : Forte surexpression ($Z\text{-score} > +1.0$).
- ▶ **Bleu sombre** : Forte sous-expression ou répression ($Z\text{-score} < -1.0$).
- ▶ Les patients infectés (Pat_1 à Pat_8) affichent un bloc rouge massif pour les marqueurs d'inflammation.

Notion 41 : Extraction de Signatures Moléculaires Pathologiques

Définition / Concept Clé : Définition d'une Signature en Biochimie Médicale

Une signature moléculaire est la combinaison minimale de biomarqueurs dont l'expression conjointe caractérise de façon univoque une pathologie ou un stade évolutif :

- ▶ Dans la Clustermap, elle correspond à l'intersection d'un cluster de lignes et d'un cluster de colonnes.
- ▶ Évite de doser des centaines de paramètres superflus en isolant les molécules sentinelles clés.

Cas Pratique Biochimie : Validation Biologique

Si un nouveau patient inconnu arrive et présente la coloration caractéristique de la signature rouge, il est classé avec une très forte certitude dans le groupe pathologique sans nécessiter de confirmation invasive.

Progression Pédagogique du Chapitre VI

La Classification Non-Supervisée en Sciences du Vivant

Exemple Fil Conducteur : Isolats Bactériens & Gènes de Résistance

Mesures de Dissimilarité Biologique (Distances)

La Matrice de Dissimilarité Initiale D_0

Stratégies de Liaison (Linkage Methods)

La Méthode de Ward (Variance Minimale & Inertie)

Le Dendrogramme : Lecture, Hauteurs & Interprétation

Détermination de la Partition Optimale (Seuil de Coupure)

La Clustermap (Heatmap Bi-Clusterisée) en Biochimie

Pièges Méthodologiques, Validation & Synthèse

Notion 42 : Piège Méthodologique 1 : L'Omission du Centrage-Réduction

Piège Fréquent en Biologie : Le Biais d'Échelle Absolue

- ▶ Réaliser une CAH sur des concentrations brutes (mg/L vs $\mu\text{g/L}$ vs UI/L) sans standardisation préalable fausse totalement les distances euclidiennes.
- ▶ La variable ayant les valeurs numériques les plus massives dicte à 100% les fusions, reléguant des marqueurs cellulaires ultra-sensibles au rang de bruit nul.

Définition / Concept Clé : La Bonne Pratique Obligatoire

Toujours appliquer la transformation Z-score ($z = \frac{x - \bar{x}}{s}$) sur l'ensemble des variables avant de calculer la matrice de dissimilarité D_0 .

Notion 43 : Piège Méthodologique 2 : Forcer une Partition Sans Structure

⚠ Piège Fréquent en Biologie : L'Algorithme Trouvera Toujours des Groupes, Même dans le Hasard !

- ▶ L'algorithme de CAH est purement déterministe : même si on lui injecte du pur bruit gaussien aléatoire, il construira quand même un dendrogramme complet !
- ▶ **Erreur classique** : Couper arbitrairement l'arbre en 3 classes alors que les branches verticales sont minuscules et de longueurs équivalentes.

📄 Définition / Concept Clé : Critère de Réfutation

S'il n'existe aucun saut d'inertie majeur sur le graphique de coude, la population biologique est continue et homogène : il n'y a pas de sous-types distincts.

Notion 44 : Validation Statistique Post-Hoc des Classes Découvertes

Définition / Concept Clé : Validation Croisée Biologique

Une partition obtenue par CAH ne doit jamais être considérée comme une vérité absolue sans confirmation statistique indépendante :

1. **ANOVA ou Test de Student** : Comparer les moyennes des biomarqueurs entre les clusters formés pour vérifier que les différences sont statistiquement significatives ($p < 0.001$).
2. **Reproductibilité sur Cohorte Indépendante** : Vérifier que les mêmes clusters émergent sur une nouvelle série d'échantillons prélevés dans un autre hôpital.
3. **Courbes de Survie (Kaplan-Meier)** : Vérifier si les clusters identifiés présentent des pronostics de survie cliniquement divergents.

Notion 45 : Tableau Comparatif : ACP vs CAH

Définition / Concept Clé : Deux Approches Complémentaires en Biostatistiques

Caractéristique	Analyse en Composantes Principales (ACP)	Classification Hiérarchique (CAH)
Nature de la Réduction	Réduction d'espace continu (projette les p dimensions sur quelques axes orthogonaux PC1, PC2).	Réduction discrète (regroupe les N échantillons en k classes discontinues).
Sortie Visuelle Principale	Plan factoriel continu & Cercle des corrélations.	Arbre généalogique hiérarchique (Dendrogramme) & Heatmap.
Hypothèse Sous-Jacente	Recherche de gradients continus et de trajectoires linéaires globales.	Recherche de sous-populations isolées, discontinues et compactes.
Synergie Recommandée	Pratique optimale : Réaliser d'abord une ACP pour débruiter, puis classifier sur les scores factoriels !	

Notion 46 : Synthèse Méthodologique Globale du Chapitre VI

Définition / Concept Clé : Le Pipeline Idéal de la Classification en Biochimie

1. **Standardisation** : Centrage-réduction obligatoire (Z -scores) sur toutes les variables quantitatives.
2. **Matrice de Distance** : Calcul des distances euclidiennes (ou corrélation pour les cinétiques).
3. **Agrégation de Ward** : Minimisation de l'accroissement d'inertie intra-classe (ΔI).
4. **Choix de k** : Analyse du plus grand saut d'inertie sur le dendrogramme ou le graphe de coude.
5. **Clustermap** : Croisement bivarié lignes/colonnes pour extraire la signature moléculaire.

Cas Pratique Biochimie : Objectif Ultime

Transformer des millions de données moléculaires brutes en une nomenclature clinique limpide, personnalisée et directement actionnable pour la prise en charge des patients.

Fin du Chapitre VI

Classification Ascendante Hiérarchique (CAH) & Dendrogrammes

Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

Faculté des Sciences — Département de Biologie
Université M'Hamed Bougara de Boumerdès (UMBB)