

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : Biostatistiques Appliquées & Modélisation

Enseignante : Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

color BioNavy



Portail Interactif Web

Scannez pour les simulateurs

SUPPORT DE COURS & GUIDE PRATIQUE RÉDIGÉ (CHAPITRE 2)

Analyse de la Variance Hiérarchisée (Nested ANOVA)

Facteurs Emboîtés & Lutte contre la Pseudoréplication

1 Introduction : Pourquoi l'ANOVA Hiérarchisée ?

Dans la recherche biologique et biopharmaceutique, les protocoles expérimentaux présentent très souvent une organisation en **niveaux emboîtés (hiérarchiques)**.

⚠ Piège à Éviter / Règle d'Or : Le Danger de la Pseudoréplication en Laboratoire

Considérons l'expérience suivante : un étudiant en Master souhaite tester deux milieux de culture sur la production d'anticorps monoclonaux. Ilensemence **une seule fiole de culture** avec le Milieu 1 et **une seule fiole** avec le Milieu 2. À la fin de la culture, il prélève **10 aliquotes de 100 μ L** dans chaque fiole et les dose par spectrophotométrie.

- ✗ L'étudiant injecte ses $2 \times 10 = 20$ valeurs dans un logiciel et obtient un test de Student triomphant avec $p < 0.001$.
- ✗ **C'est une erreur méthodologique gravissime !** L'étudiant a confondu $n = 10$ mesures techniques avec 10 répétitions biologiques. En réalité, la taille biologique de son échantillon est $N = 1$ **fiole par condition**.
- ✗ Si la fiole 1 a produit plus que la fiole 2, cela peut être dû au milieu, mais aussi à une légère contamination, une différence de température locale dans l'étuve, ou un défaut d'oxygénation. **L'effet du milieu est totalement confondu avec l'effet de la fiole !**

Cette erreur s'appelle la **pseudoréplication**. L'ANOVA hiérarchisée est précisément l'outil mathématique qui permet de traiter rigoureusement ces structures emboîtées.

💡 Facteurs Croisés ($A \times B$) vs Facteurs Emboîtés ($B \subset A$)

Pour bien choisir entre ANOVA croisée (Chapitre 1) et ANOVA hiérarchisée (Chapitre 2), posez-vous une question simple : « **La modalité 1 du Facteur B a-t-elle la même signification biologique sous toutes les modalités du Facteur A ?** »

Plan Croisé ($A \times B$)

Chaque niveau de B est combiné avec chaque niveau de A.

Exemple : Facteur A = Génotype (Sain vs Diabétique), Facteur B = Dose d'insuline (0, 10, 50 nM). La dose 10 nM est exactement la même pour les deux génotypes.

Test : On teste l'effet A, l'effet B et l'**Interaction** $A \times B$.

Plan Hiérarchisé / Emboîté ($B \subset A$)

Les niveaux de B sont **uniques et différents** pour chaque niveau de A.

Exemple : Facteur A = Souche bactérienne (Souche 1 vs Souche 2), Facteur B = Cuve de bioréacteur (Cuves 1, 2, 3 sous Souche 1 ; Cuves 4, 5, 6 sous Souche 2). La cuve 1 de la Souche 1 n'a aucun rapport avec la cuve 1 de la Souche 2 !

Test : L'interaction n'a **aucun sens mathématique**. On teste l'effet principal A et l'**effet d'emboîtement** $B(A)$.

2 Modèle Linéaire d'Emboîtement & Décomposition de la Variance

2.1 Équation du Modèle

Pour un plan hiérarchisé à deux niveaux équilibré :

- ▶ a modalités du Facteur Principal A ($i = 1, 2, \dots, a$).
- ▶ b sous-unités du Facteur Emboîté B à l'intérieur de chaque modalité de A ($j = 1, 2, \dots, b$).
- ▶ n réplicats techniques ou aliquotes par sous-unité ($k = 1, 2, \dots, n$).
- ▶ Nombre total de mesures : $N = a \times b \times n$.

Chaque mesure biologique x_{ijk} s'écrit :

$$x_{ijk} = \mu + \alpha_i + \beta_{j(i)} + \varepsilon_{ijk}$$

où :

- μ est la moyenne générale de référence.
- α_i est l'effet du Facteur Principal A ($\sum \alpha_i = 0$).
- $\beta_{j(i)}$ est l'effet de la sous-unité j emboîtée dans la modalité i de A.
- $\varepsilon_{ijk} \sim \mathcal{N}(0, \sigma^2)$ est l'erreur résiduelle aléatoire de mesure.

2.2 Décomposition des Sommes de Carrés

La variabilité totale SCT se décompose en trois composantes indépendantes :

$$SCT = SCA + SCB(A) + SCR$$

- 📊 **1. Somme des Carrés du Facteur Principal (SCA) :** Variabilité entre les moyennes des modalités du facteur principal :

$$SCA = b \cdot n \sum_{i=1}^a (\bar{x}_{i..} - \bar{X})^2 \quad \text{avec} \quad df_A = a - 1$$

- 📊 **2. Somme des Carrés du Facteur Emboîté ($SCB(A)$) :** Variabilité entre les sous-unités à l'intérieur d'une même modalité de A :

$$SCB(A) = n \sum_{i=1}^a \sum_{j=1}^b (\bar{x}_{ij.} - \bar{x}_{i..})^2 \quad \text{avec} \quad df_{B(A)} = a(b - 1)$$

3. **Somme des Carrés Résiduelle (SCR) :** Variabilité technique entre les réplicats au sein de chaque sous-unité :

$$SCR = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (x_{ijk} - \bar{x}_{ij.})^2 \quad \text{avec} \quad df_{\text{res}} = ab(n-1)$$

4. **Somme des Carrés Totale (SCT) :**

$$SCT = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (x_{ijk} - \bar{X})^2 \quad \text{avec} \quad df_{\text{total}} = N - 1$$

3 La Règle d'Or Cruciale du Test F dans l'ANOVA Hiérarchisée

⚠ Piège à Éviter / Règle d'Or : Attention au Dénominateur du Test F pour le Facteur Principal A !

Dans une ANOVA standard, on divise toujours par le carré moyen résiduel MS_R . **Dans une ANOVA hiérarchisée, c'est formellement interdit pour le facteur principal !**

⚠ Pour tester le Facteur Emboîté B ($B \subset A$) :

$$F_{B(A)} = \frac{MS_{B(A)}}{MS_R} \quad \text{avec} \quad df = [a(b-1), ab(n-1)]$$

On teste si les cuves/animaux diffèrent significativement entre eux par rapport à l'erreur de pipetage.

⚠ Pour tester le Facteur Principal A :

$$F_A = \frac{MS_A}{MS_{B(A)}} \quad (\text{et NON } \frac{MS_A}{MS_R} !) \quad \text{avec} \quad df = [a-1, a(b-1)]$$

Raison biologique fondamentale : Pour prouver que le Facteur A (ex: Souche bactérienne) est réellement efficace, il faut que sa variabilité MS_A domine la variabilité biologique naturelle entre les cuves $MS_{B(A)}$, et non pas seulement la précision du spectrophotomètre MS_R ! Diviser par MS_R gonflerait artificiellement F et conduirait à de faux espoirs thérapeutiques ou industriels.

3.1 Tableau Récapitulatif d'ANOVA Hiérarchisée

Source de Variation	ddl	Somme des Carrés	Carré Moyen (MS)	Statistique F_{obs}	Valeur Critique ($\alpha = 5\%$)
Facteur Principal A	$a - 1$	SCA	$MS_A = \frac{SCA}{a-1}$	$F_A = \frac{MS_A}{MS_{B(A)}}$	$F_{0.05}(a-1, a(b-1))$
Facteur Emboîté B(A)	$a(b-1)$	$SCB(A)$	$MS_{B(A)} = \frac{SCB(A)}{a(b-1)}$	$F_{B(A)} = \frac{MS_{B(A)}}{MS_R}$	$F_{0.05}(a(b-1), ab(n-1))$
Résiduelle (Technique)	$ab(n-1)$	SCR	$MS_R = \frac{SCR}{ab(n-1)}$	—	—
Total	$N - 1$	SCT			

4 Exemple Numérique : Bioproduction en Bioréacteurs

Problématique Biologique : Une équipe de bio-ingénierie optimise le rendement de production d'une protéine recombinante thérapeutique (en g/L de surnageant de fermentation) :

- ✓ **Facteur Principal A (Souche d'expression) :** $a = 2$ souches testées : Souche Sauvage (A_1) vs Souche Modifiée CRISPR (A_2).

- ✓ **Facteur Emboîté B (Bioréacteurs / Cuves) :** Pour chaque souche, $b = 3$ cuves de culture indépendantes sont lancées en parallèle (Cuves 1, 2, 3 sous Souche 1 ; Cuves 4, 5, 6 sous Souche 2).
- ✓ **Réplicats techniques de dosage :** Dans chaque cuve, $n = 3$ aliquotes indépendantes sont prélevées et dosées par HPLC ($N = 2 \times 3 \times 3 = 18$ dosages au total).

Tableau des Données Brutes & Moyennes par Cuve ($n = 3$)

Souche (Facteur A)	Bioréacteur 1	Bioréacteur 2	Bioréacteur 3	Moyenne de la Souche ($\bar{x}_{i..}$)
Souche Sauvage (A_1)	10, 12, 11 $\Rightarrow$ 11.0	11, 13, 12 $\Rightarrow$ 12.0	9, 11, 10 $\Rightarrow$ 10.0	$\bar{x}_{1..} = \frac{11+12+10}{3} = \mathbf{11.0}$ g/L
Souche CRISPR (A_2)	18, 20, 19 $\Rightarrow$ 19.0	20, 22, 21 $\Rightarrow$ 21.0	19, 21, 20 $\Rightarrow$ 20.0	$\bar{x}_{2..} = \frac{19+21+20}{3} = \mathbf{20.0}$ g/L

Étape 1 : Calcul de la Moyenne Générale ($\bar{X}$)

$$\bar{X} = \frac{11.0 + 20.0}{2} = \mathbf{15.5} \text{ g/L}$$

Étape 2 : Somme des Carrés du Facteur Principal (Souches - SCA)

$a = 2$, chaque souche totalise $b \times n = 3 \times 3 = 9$ observations :

$$\text{Souche Sauvage } (A_1) : 9 \times (11.0 - 15.5)^2 = 9 \times (-4.5)^2 = 9 \times 20.25 = 182.25$$

$$\text{Souche CRISPR } (A_2) : 9 \times (20.0 - 15.5)^2 = 9 \times (+4.5)^2 = 9 \times 20.25 = 182.25$$

$$\mathbf{SCA} = 182.25 + 182.25 = \mathbf{364.5} \quad \text{avec } df_A = a - 1 = 2 - 1 = 1$$

Étape 3 : Somme des Carrés du Facteur Emboîté (Cuves - SCB(A))

On compare la moyenne de chaque cuve $\bar{x}_{ij.}$ à la moyenne de sa propre souche $\bar{x}_{i..}$ (pondérée par $n = 3$) :

$$\text{Souche 1 : } 3 \times [(11.0 - 11.0)^2 + (12.0 - 11.0)^2 + (10.0 - 11.0)^2] = 3 \times [0 + 1 + 1] = 6.0$$

$$\text{Souche 2 : } 3 \times [(19.0 - 20.0)^2 + (21.0 - 20.0)^2 + (20.0 - 20.0)^2] = 3 \times [1 + 1 + 0] = 6.0$$

$$\mathbf{SCB(A)} = 6.0 + 6.0 = \mathbf{12.0} \quad \text{avec } df_{B(A)} = a(b - 1) = 2 \times (3 - 1) = 2 \times 2 = 4$$

Étape 4 : Somme des Carrés Résiduelle (Erreur Technique - SCR)

Dans chacune des 6 cuves, les 3 aliquotes HPLC présentent des écarts par rapport à leur moyenne de cuve : Pour chaque cuve, les valeurs sont $(m - 1, m + 1, m) \Rightarrow (-1)^2 + (+1)^2 + 0^2 = 2.0$. Comme il y a 6 cuves indépendantes :

$$\mathbf{SCR} = 6 \times 2.0 = \mathbf{12.0} \quad \text{avec } df_{\text{res}} = ab(n - 1) = 2 \times 3 \times (3 - 1) = 6 \times 2 = 12$$

Vérification de la somme totale : $SCT = 364.5 + 12.0 + 12.0 = \mathbf{388.5}$ avec $df_{\text{total}} = 18 - 1 = 17$.

Étape 5 : Tableau d'ANOVA Hiérarchisée & Calculs des Ratios F_{obs}						
Source de Variation	ddl	SC	Carré Moyen (MS)	Statistique F_{obs}	$F_{critique}(5\%)$	Décision
Souches (Facteur A)	1	364.5	$MS_A = \frac{364.5}{1} = 364.5$	$F_A = \frac{MS_A}{MS_{B(A)}} = \frac{364.5}{3.0} = 121.5$	$F_{0.05}(1, 4) = 7.71$	$p < 0.001$ (Signif.)
Cuves(Souches) ($B \subset A$)	4	12.0	$MS_{B(A)} = \frac{12.0}{4} = 3.0$	$F_{B(A)} = \frac{MS_{B(A)}}{MS_R} = \frac{3.0}{1.0} = 3.00$	$F_{0.05}(4, 12) = 3.26$	$p = 0.063$ (Non signif.)
Résiduelle (HPLC)	12	12.0	$MS_R = \frac{12.0}{12} = 1.0$	—	—	—
Total	17	388.5				

✓ Synthèse & Décision Biologique : Décisions & Conclusions Biologiques Rédigées

✓ 1. Test de l'effet Cuves [$F_{B(A)} = 3.00 < F_{crit}(4, 12) = 3.26, p = 0.063$] : L'effet de la variabilité entre bioréacteurs n'est **pas statistiquement significatif au seuil de 5%**. Cela démontre que les cuves de fermentation sont bien étalonnées et que le process de bioréaction est hautement reproductible.

✓ 2. Test de l'effet Souche [$F_A = 121.5 \gg F_{crit}(1, 4) = 7.71, p < 0.001$] : Puisque F_A a été rigoureusement testé par rapport à la variance inter-cuves ($MS_{B(A)} = 3.0$), nous avons la preuve mathématique formelle que **la Souche CRISPR surpasse la Souche Sauvage de façon hautement significative**.

✓ 3. Impact industriel : La souche modifiée produit en moyenne **20.0 g/L** de protéine contre seulement **11.0 g/L** pour la souche sauvage, soit un gain de rendement spectaculaire de **+81.8%**, parfaitement exploitable à l'échelle pilote industrielle sans risque de biais de cuve.

5 Exercices d'Application avec Solutions Détaillées

✎ Exercice 1 : Audit Méthodologique & Diagnostic de Pseudoréplication

Analysez les deux situations expérimentales suivantes rapportées par des stagiaires en laboratoire :

• **Protocole 1** : Pour évaluer un neuroprotecteur, un chercheur traite 2 rats au placebo et 2 rats au neuroprotecteur. Après sacrifice, il découpe 5 coupes coronales de cerveau par rat et compte le nombre de neurones viables par coupe ($N = 2 \times 2 \times 5 = 20$ mesures). Il affirme que sa taille d'échantillon est $N = 10$ coupes par condition et applique un test de Student à $df = 18$.

• **Protocole 2** : Dans un essai agronomique, une biologiste compare 2 types de biofertilisants ($a = 2$). Pour chaque fertilisant, elle prépare 3 parcelles de serre indépendantes ($b = 3$). Dans chaque parcelle, elle mesure le rendement de 4 plants ($n = 4, N = 24$ plants). Elle analyse les données par ANOVA hiérarchisée.

Questions :

a. Le Protocole 1 présente-t-il une pseudoréplication ? Pourquoi ? Quel est le véritable nombre de réplicats biologiques (N) ?

b. Comment les données du Protocole 1 doivent-elles être correctement analysées ?

c. Dans le Protocole 2, identifiez le facteur principal et le facteur emboîté. Écrivez les degrés de liberté de chaque source ($SCA, SCB(A), SCR, SCT$).

d. Quel ratio F testera la significativité du biofertilisant ?

✓ Solution : Exercice 1

a. Diagnostic du Protocole 1 : Oui, il y a pseudoréplication flagrante. Les 5 coupes de cerveau issues d'un même animal ne sont pas des individus indépendants, mais des **réplicats techniques (aliquotes histologiques)** d'un seul animal. Le véritable échantillon biologique est de $N = 2$ **rats par lot** (taille d'échantillon dramatiquement insuffisante, $df = 2 + 2 - 2 = 2$).

b. Correction méthodologique : Deux options rigoureuses :

- Soit faire la moyenne des 5 coupes pour chaque rat, et obtenir ainsi une seule valeur par rat ($n = 2$ par groupe).
- Soit appliquer une ANOVA hiérarchisée (Coupes emboîtées dans les Rats) où l'effet du traitement est testé par rapport à la variance inter-animale (MS_{Rats}), mais avec seulement 2 rats par lot, la puissance statistique reste trop faible ($df_{\text{dénominateur}} = 2(2 - 1) = 2$). Il faut augmenter le nombre de rats ($n \geq 6$).

c. Analyse du Protocole 2 :

- Facteur Principal A = Biofertilisant ($a = 2$ modalités).
- Facteur Emboîté B = Parcelles ($b = 3$ parcelles par fertilisant, $B \subset A$).
- Réplicats techniques = Plants par parcelle ($n = 4$).
- Degrés de liberté :

$$\begin{aligned} df_A &= a - 1 = 2 - 1 = \mathbf{1} \\ df_{B(A)} &= a(b - 1) = 2 \times (3 - 1) = \mathbf{4} \\ df_{\text{res}} &= ab(n - 1) = 2 \times 3 \times (4 - 1) = 6 \times 3 = \mathbf{18} \\ df_{\text{total}} &= N - 1 = 24 - 1 = \mathbf{23} \end{aligned}$$

d. Statistique de test valide : Pour le biofertilisant : $F_A = \frac{MS_A}{MS_{B(A)}}$ comparé à $F_{0.05}(1, 4) = \mathbf{7.71}$ (et NON par rapport à MS_R !).

✎ Exercice 2 : ANOVA Hiérarchisée Complète (Production d'un Vaccin Recombinant)

Un laboratoire biopharmaceutique compare deux Procédés de purification d'un vaccin recombinant (Facteur Principal A, $a = 2$: Procédé Standard A_1 vs Procédé Optimisé A_2). Pour chaque procédé, $b = 2$ Lots industriels indépendants sont produits ($B \subset A$). Dans chaque lot, $n = 3$ ampoules sont dosées par chromatographie ($N = 2 \times 2 \times 3 = 12$ dosages) :

- Procédé A_1 , Lot 1 : 11.0, 13.0, 12.0 $\Rightarrow \bar{x}_{11} = 12.0 \mu\text{g/mL}$.
- Procédé A_1 , Lot 2 : 9.0, 11.0, 10.0 $\Rightarrow \bar{x}_{12} = 10.0 \mu\text{g/mL}$.
- Procédé A_2 , Lot 3 : 19.0, 21.0, 20.0 $\Rightarrow \bar{x}_{21} = 20.0 \mu\text{g/mL}$.
- Procédé A_2 , Lot 4 : 17.0, 19.0, 18.0 $\Rightarrow \bar{x}_{22} = 18.0 \mu\text{g/mL}$.

Questions :

- Calculez les moyennes de procédé $\bar{x}_{1..}$, $\bar{x}_{2..}$ et la moyenne générale $\bar{X}$.
- Calculez SCA , $SCB(A)$ et SCR .
- Complétez le tableau d'ANOVA hiérarchisée et déterminez F_A et $F_{B(A)}$.

- d. Au seuil $\alpha = 5\%$ avec $F_{\text{critique}}(1, 2) = 18.51$ et $F_{\text{critique}}(2, 8) = 4.46$, concluez pour le procédé et pour les lots.

✓ Solution : Exercice 2

- a. **Moyennes** : $\bar{x}_{1..} = \frac{12.0+10.0}{2} = 11.0 \mu\text{g/mL}$; $\bar{x}_{2..} = \frac{20.0+18.0}{2} = 19.0 \mu\text{g/mL}$.
Moyenne générale : $\bar{X} = \frac{11.0+19.0}{2} = \mathbf{15.0 \mu\text{g/mL}}$.

- b. **Sommes des carrés** :

$$\begin{aligned} SCA &= b \cdot n \times \left[(11.0 - 15.0)^2 + (19.0 - 15.0)^2 \right] \\ &= 6 \times [(-4)^2 + (+4)^2] = 6 \times 32 = \mathbf{192.0} \quad (df = 1) \\ SCB(A) &= n \times \sum \left[(\bar{x}_{ij} - \bar{x}_i)^2 \right] \\ &= 3 \times \left[(12 - 11)^2 + (10 - 11)^2 + (20 - 19)^2 + (18 - 19)^2 \right] \\ &= 3 \times [1 + 1 + 1 + 1] = 3 \times 4 = \mathbf{12.0} \quad (df = 2(2 - 1) = 2) \\ SCR &= 4 \text{ lots} \times [(-1)^2 + (+1)^2 + 0^2] = 4 \times 2 = \mathbf{8.0} \quad (df = 8) \\ SCT &= 192.0 + 12.0 + 8.0 = \mathbf{212.0} \quad (df = 12 - 1 = 11) \end{aligned}$$

- c. **Tableau d'ANOVA Hiérarchisée** :

Source	ddl	SC	Carré Moyen (MS)	F_{obs}	$F_{\text{critique}}(5\%)$	Décision
Procédé (A)	1	192.0	$MS_A = \frac{192.0}{1} = 192.0$	$F_A = \frac{MS_A}{MS_{B(A)}} = \frac{192.0}{6.0} = \mathbf{32.0}$	$F_{0.05}(1, 2) = \mathbf{18.51}$	Rejet H_0 ($p < 0.05$)
Lots(Procédé) ($B \subset A$)	2	12.0	$MS_{B(A)} = \frac{12.0}{2} = 6.0$	$F_{B(A)} = \frac{MS_{B(A)}}{MS_R} = \frac{6.0}{1.0} = \mathbf{6.0}$	$F_{0.05}(2, 8) = \mathbf{4.46}$	Rejet H_0 ($p = 0.026$)
Résiduelle (Ampoules)	8	8.0	$MS_R = \frac{8.0}{8} = 1.0$	—	—	—
Total	11	212.0				

- d. **Conclusions Biologiques & Industrielles** :

- **Effet des Lots** [$F_{B(A)} = 6.0 > 4.46$, $p < 0.05$] : Il existe une variabilité inter-lots significative (12.0 vs 10.0 dans le procédé A ; 20.0 vs 18.0 dans le B). Les conditions de fabrication varient légèrement d'une cuve à l'autre.
- **Effet du Procédé** [$F_A = 32.0 > 18.51$, $p = 0.030$] : Même en tenant compte de cette instabilité inter-lots ($MS_{B(A)} = 6.0$), le Procédé Optimisé produit significativement plus d'antigène (19.0 $\mu\text{g/mL}$ vs 11.0 $\mu\text{g/mL}$, gain de +72.7%). Le changement de procédé est validé.

Annexe : Extrait de la Table de Fisher-Snedecor (F au seuil $\alpha = 0.05$)

ddl Dénominateur (df_2)	$df_1 = 1$	$df_1 = 2$	$df_1 = 3$	$df_1 = 4$	$df_1 = 5$	$df_1 = 6$	$df_1 = 8$	$df_1 = 12$
1	161.45	199.50	215.71	224.58	230.16	233.99	238.88	243.91
2 (Test Procédé Ex. 2)	18.51	19.00	19.16	19.25	19.30	19.33	19.37	19.41
3	10.13	9.55	9.28	9.12	9.01	8.94	8.85	8.74
4 (Test Souches Cours)	7.71	6.94	6.59	6.39	6.26	6.16	6.04	5.91
5	6.61	5.79	5.41	5.19	5.05	4.95	4.82	4.68
6	5.99	5.14	4.76	4.53	4.39	4.28	4.15	4.00
8 (Test Lots Ex. 2)	5.32	4.46	4.07	3.84	3.69	3.58	3.44	3.28
10	4.96	4.10	3.71	3.48	3.33	3.22	3.07	2.91
12 (Test Cuves Cours)	4.75	3.89	3.49	3.26	3.11	3.00	2.85	2.69
20	4.35	3.49	3.10	2.87	2.71	2.60	2.45	2.28
∞	3.84	3.00	2.60	2.37	2.21	2.10	1.94	1.75