

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : Biostatistiques Appliquées & Modélisation

Enseignante : Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

color BioNavy



Portail Interactif Web

Scannez pour les simulateurs

SUPPORT DE COURS & GUIDE PRATIQUE RÉDIGÉ (CHAPITRE 3)

Corrélation, Régression Linéaire & Gammes d'Étalonnage

Modélisation Statistique, Moindres Carrés Ordinaires & Inférence Analytique

1 Introduction : La Transduction du Signal Analytique

En biochimie et biologie médicale, les automates de laboratoire ne comptent jamais directement le nombre de molécules dans une éprouvette :

- Le **spectrophotomètre** mesure l'atténuation d'un faisceau lumineux (A_{595} dans un dosage de Bradford).
- Le **luminomètre ELISA** mesure une intensité de fluorescence émise par une sonde enzymatique (RLU).
- Le **thermocycleur qPCR** quantifie un cycle seuil d'amplification (C_t).

Pour convertir ce signal physique abstrait Y en concentration massique ou molaire réelle X ($\mu\text{g/mL}$, mM), l'expérimentateur prépare une **gamme étalon** de concentrations connues, mesure les signaux correspondants, et ajuste un modèle mathématique.

💡 Corrélation vs Régression : Une Différence Fondamentale

- ✓ **La Corrélation (r)** : Mesure la force et le sens de l'association linéaire **symétrique** entre deux variables aléatoires conjointes (X et Y). Aucune variable n'explique l'autre (ex : corrélation entre les transaminases ASAT et ALAT lors d'une cytolyse hépatique).
- ✓ **La Régression ($Y = f(X) + \varepsilon$)** : Établit une relation fonctionnelle **directionnelle et causale**. La variable indépendante X (fixée sans erreur par le manipulateur) prédit la variable dépendante Y (réponse expérimentale bruitée).

2 Le Coefficient de Corrélation Linéaire de Pearson (r)

Pour deux variables quantitatives continues X et Y mesurées sur n individus, le coefficient de Pearson mesure l'alignement des points :

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{SP_{xy}}{\sqrt{SS_{xx} \cdot SS_{yy}}}$$

avec $-1 \leq r \leq +1$.

⚠ Piège à Éviter / Règle d'Or : Corrélation n'est pas Causalité

Deux biomarqueurs peuvent présenter une corrélation de $r = 0.98$ sous l'effet d'une troisième variable cachée (variable confondante, ex : la masse corporelle ou la sévérité globale de la pathologie), sans qu'aucun ne cause directement l'autre.

3 Le Modèle Linéaire Simple & Moindres Carrés Ordinaires (MCO)

Le modèle statistique postule :

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad \text{avec } \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

La droite des moindres carrés $\hat{y}_i = ax_i + b$ minimise la somme des carrés des écarts verticaux $\sum (y_i - \hat{y}_i)^2$:

$$a = \frac{SP_{xy}}{SS_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad (\text{Pente} = \text{Sensibilité analytique})$$

$$b = \bar{y} - a\bar{x} \quad (\text{Ordonnée à l'origine} = \text{Signal du blanc réactif})$$

🔗 Exemple & Signification Biologique : Interprétation Biochimique des Paramètres

- ▶ **Pente a (Sensibilité)** : Variation d'absorbance par unité de concentration ($\Delta A / \Delta C$). Plus a est élevée, plus la méthode détecte de fines variations.
- ▶ **Ordonnée b (Bruit de fond)** : Absorbance théorique à concentration nulle ($X = 0$). Un test de Student teste si $b = 0$.

4 Qualité de l'Ajustement & Décomposition de la Variance

La dispersion totale du signal optique SCT se décompose en :

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2 \iff SCT = SCE + SCR$$

✓ **Coefficient de Détermination ($R^2 = r^2$)** :

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

Représente la fraction de variance du signal optique expliquée par la concentration en étalon.

✓ **Variance Résiduelle ($s_{y/x}^2$)** :

$$s_{y/x}^2 = \frac{SCR}{n-2} \implies s_{y/x} = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n-2}}$$

5 Prédiction Inverse & Formule de Mandel (Dosage d'Inconnus)

Pour un échantillon biologique inconnu donnant une réponse moyenne y_0 (moyenne de m lectures répliquées) :

$$\hat{x}_0 = \frac{y_0 - b}{a}$$

L'erreur standard sur cette concentration estimée est calculée par la **formule de Mandel** :

$$s_{\hat{x}_0} = \frac{s_{y/x}}{a} \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(y_0 - \bar{y})^2}{a^2 \cdot SS_{xx}}}$$

L'intervalle de confiance à 95% est :

$$IC_{95\%}(\hat{x}_0) = [\hat{x}_0 \pm t_{0.05}(n-2) \cdot s_{\hat{x}_0}]$$

⚠ Piège à Éviter / Règle d'Or : Le Piège de l'Extrapolation

L'intervalle de Mandel s'élargit en forme d'hyperbole dès qu'on s'éloigne du centre de gravité $\bar{y}$.
Ne jamais prédire en dehors de l'intervalle étalonné $[x_{\min}, x_{\max}]$!

6 Limites Analytiques Réglementaires (ICH Q2R1 : LOD & LOQ)

D'après les normes internationales de validation bioanalytique (ICH Q2R1) :

$$\text{LOD} = \frac{3.3 \cdot s_{y/x}}{a} \quad (\text{Limite de Détection}) \qquad \text{LOQ} = \frac{10 \cdot s_{y/x}}{a} \quad (\text{Limite de Quantification})$$

7 Exercices d'Application & Solutions

✏ Exercice 1 : Étalonnage Bradford & Validation Analytique

Un biochimiste prépare une gamme étalon d'albumine bovine (BSA) à $n = 5$ concentrations pour étalonner un spectrophotomètre à 595 nm :

Tube	1	2	3	4	5
Concentration BSA (x_i , $\mu\text{g/mL}$)	2.0	4.0	6.0	8.0	10.0
Absorbance A_{595} (y_i)	0.125	0.245	0.380	0.495	0.635

Données calculées : $\sum x_i = 30.0$, $\sum y_i = 1.880$, $\sum x_i^2 = 220.0$, $\sum y_i^2 = 0.868775$, $\sum x_i y_i = 13.820$.

- Calculez SS_{xx} , SS_{yy} et SP_{xy} .
- Déterminez le coefficient de corrélation linéaire de Pearson (r).
- Calculez la pente a , l'ordonnée à l'origine b et écrivez l'équation de la droite d'étalonnage.
- Calculez le coefficient de détermination R^2 . La méthode satisfait-elle le critère de validation accréditée ($R^2 \geq 0.995$) ?

✓ Solution : Exercice 1

- a. Calcul des sommes d'écarts :**

$$SS_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n} = 220.0 - \frac{30.0^2}{5} = 220.0 - 180.0 = \mathbf{40.0}$$

$$SS_{yy} = \sum y_i^2 - \frac{(\sum y_i)^2}{n} = 0.868775 - \frac{1.880^2}{5} = 0.868775 - 0.706880 = \mathbf{0.161895}$$

$$SP_{xy} = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n} = 13.820 - \frac{30.0 \times 1.880}{5} = 13.820 - 11.280 = \mathbf{2.540}$$

- b. Coefficient de Pearson (r) :**

$$r = \frac{SP_{xy}}{\sqrt{SS_{xx} \cdot SS_{yy}}} = \frac{2.540}{\sqrt{40.0 \times 0.161895}} = \frac{2.540}{\sqrt{6.4758}} = \frac{2.540}{2.54476} = \mathbf{0.9981}$$

c. Droite des moindres carrés :

$$a = \frac{SP_{xy}}{SS_{xx}} = \frac{2.540}{40.0} = \mathbf{0.0635 \text{ OD}/(\mu\text{g/mL})}$$

$$b = \bar{y} - a\bar{x} = \frac{1.880}{5} - 0.0635 \times \frac{30.0}{5}$$

$$= 0.376 - 0.381 = \mathbf{-0.005 \text{ OD}}$$

Équation : $\hat{y} = \mathbf{0.0635 x - 0.005}$.

d. Coefficient de détermination & Décision :

$$R^2 = r^2 = (0.99813)^2 = \mathbf{0.9963} \quad (99.63\%)$$

Puisque $R^2 = 0.9963 \geq 0.995$, la gamme étalon satisfait rigoureusement le critère de linéarité internationale.

✏ Exercice 2 : Dosage d'un Extrait Hépatique Inconnu & Limites LOD / LOQ

À partir de la gamme étalon précédente ($a = 0.0635$, $b = -0.005$, $SS_{xx} = 40.0$, $\bar{x} = 6.0$, $\bar{y} = 0.376$, $s_{y/x} = 0.00894$) : Un extrait d'homogénat hépatique de rat dilué au $1/100^{\text{e}}$ donne une absorbance moyenne de $y_0 = 0.376 \text{ OD}$ ($m = 1$). La valeur critique de Student pour $df = 5 - 2 = 3$ est $t_{0.05}(3) = 3.182$.

- Estimez la concentration $\hat{x}_0$ dans l'éprouvette diluée.
- Calculez l'erreur type $s_{\hat{x}_0}$ via la formule de Mandel et déterminez l'intervalle de confiance à 95%.
- Calculez la concentration en protéines du tissu hépatique initial en g/L (facteur 100).
- Calculez la LOD et la LOQ de cette méthode analytique.

✓ Solution : Exercice 2**a. Concentration estimée :**

$$\hat{x}_0 = \frac{y_0 - b}{a} = \frac{0.376 - (-0.005)}{0.0635} = \frac{0.381}{0.0635} = \mathbf{6.00 \mu\text{g/mL}}$$

- b. Erreur type de Mandel ($m = 1, y_0 = \bar{y}$) :** Comme $y_0 = \bar{y} = 0.376$, le terme d'éloignement $(y_0 - \bar{y})^2 = 0$:

$$s_{\hat{x}_0} = \frac{s_{y/x}}{a} \sqrt{1 + \frac{1}{n} + 0} = \frac{0.00894}{0.0635} \sqrt{1 + \frac{1}{5}} = 0.1408 \times \sqrt{1.20}$$

$$= 0.1408 \times 1.0954 = \mathbf{0.154 \mu\text{g/mL}}$$

$$IC_{95\%}(\hat{x}_0) = 6.00 \pm (3.182 \times 0.154) = 6.00 \pm 0.49 = \mathbf{[5.51 ; 6.49] \mu\text{g/mL}}$$

- c. Concentration dans l'homogénat hépatique natif :** Avec le facteur de dilution $\times 100$:

$$C_{\text{foie}} = 6.00 \mu\text{g/mL} \times 100 = 600 \mu\text{g/mL} = \mathbf{0.60 \text{ g/L}} \quad (\pm 0.049 \text{ g/L})$$

d. Limites analytiques réglementaires (LOD & LOQ) :

$$\text{LOD} = \frac{3.3 \times s_{y/x}}{a} = \frac{3.3 \times 0.00894}{0.0635} = \frac{0.0295}{0.0635} = \mathbf{0.465 \mu\text{g/mL}}$$
$$\text{LOQ} = \frac{10 \times s_{y/x}}{a} = \frac{10 \times 0.00894}{0.0635} = \frac{0.0894}{0.0635} = \mathbf{1.408 \mu\text{g/mL}}$$

Formulaire Récapitulatif & Bonnes Pratiques

Paramètre Statistique	Formule Mathématique	Signification en Laboratoire
Pente de sensibilité (<i>a</i>)	$a = SP_{xy} / SS_{xx}$	Signal optique généré par unité de concentration
Ordonnée à l'origine (<i>b</i>)	$b = \bar{y} - a\bar{x}$	Signal d'absorbance du blanc réactionnel (<i>X</i> = 0)
Variance résiduelle ($s^2_{y/x}$)	$s^2_{y/x} = \frac{\sum (y_i - \hat{y}_i)^2}{n-2}$	Bruit de fond instrumental aléatoire
Coefficient de détermination	$R^2 = 1 - (SCR / SCT)$	Qualité globale de linéarité (≥ 0.995)
Incertitude inverse (Mandel)	$s_{\hat{x}_0} = \frac{s_{y/x}}{a} \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(y_0 - \bar{y})^2}{a^2 SS_{xx}}}$	Précision réelle du dosage de l'échantillon
Limite de Détection (LOD)	$\text{LOD} = 3.3 \cdot s_{y/x} / a$	Plus petite concentration discernable du bruit
Limite de Quantification (LOQ)	$\text{LOQ} = 10 \cdot s_{y/x} / a$	Plus petite concentration dosable avec exactitude