

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : Biostatistiques Appliquées & Modélisation

Enseignante : Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

color BioNavy



Portail Interactif Web

Scannez pour les simulateurs

SUPPORT DE COURS & GUIDE PRATIQUE RÉDIGÉ (CHAPITRE 5)

Analyse en Composantes Principales (ACP)

Réduction de Dimension, Décomposition Spectrale & Phénotypage Omique

1 Introduction : Le Défi de la Haute Dimensionnalité Omique

En biochimie moderne, l'expérimentateur ne mesure plus une seule variable à la fois :

- **Protéomique et Métabolomique** : Des dizaines de métabolites ou cytokines sont quantifiés simultanément chez les mêmes patients.
- **Phénotypage multi-paramétrique** : Paramètres sanguins, enzymatiques, histologiques et d'imagerie.

Face à un tableau de données de n échantillons et p variables corrélées entre elles ($p > 3$), l'esprit humain ne peut pas visualiser un espace à p dimensions. **L'Analyse en Composantes Principales (ACP)** est la méthode non supervisée reine qui projette ce nuage de points multidimensionnel sur un plan 2D optimal en **préservant le maximum de variabilité biologique (inertie)**.

Le Principe Fondamental de l'ACP

L'ACP construit de nouvelles variables synthétiques appelées **Composantes Principales** ($PC_1, PC_2, \dots$), qui sont des combinaisons linéaires des variables initiales :

1. Elles sont **strictement orthogonales (indépendantes)** entre elles (corrélation nulle).
2. Elles sont classées par **ordre décroissant de variance expliquée** : PC_1 capture le plus grand axe d'éparpillement des données, puis PC_2 capture le second axe orthogonal, etc.

2 Centrage-Réduction : L'Obligation de l'ACP Normée

En biologie, les variables sont mesurées dans des unités et avec des amplitudes radicalement hétérogènes :

- ✖ Glycémie : $\approx 1.10 \pm 0.25$ g/L (variance $\sigma^2 = 0.0625$).
- ✖ Transaminases ALAT : $\approx 45 \pm 30$ UI/L (variance $\sigma^2 = 900$).

⚠ Piège à Éviter / Règle d'Or : Le Piège de l'Effet d'Échelle en Biologie

Si l'on appliquait l'ACP sur les données brutes, l'ALAT capterait à elle seule plus de 99% de la variance totale, simplement parce que son unité produit de grands nombres ! Pour que chaque variable pèse équitablement avec un poids de 1, il faut impérativement **centrer et réduire**

chaque mesure :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

L'ACP réalisée sur ces données centrées-réduites s'appelle une **ACP normée** (elle diagonalise la matrice des corrélations R , dont la trace vaut $\sum \lambda_j = p$).

3 Valeurs Propres (λ_k) & Choix du Nombre d'Axes

L'inertie totale du nuage de points standardisé est égale au nombre total de variables p . Chaque composante principale PC_k est associée à une **valeur propre** λ_k :

$$\% \text{ Inertie}(PC_k) = \frac{\lambda_k}{p} \times 100$$

Pour sélectionner le nombre optimal d'axes à retenir :

- ✓ **La Règle de Kaiser** : On ne retient que les axes dont la valeur propre est supérieure à la moyenne :

$$\lambda_k \geq 1.0 \quad (\text{un axe qui explique plus de variance qu'une variable originale standardisée})$$

- ✓ **Le Critère du Coude (Scree plot)** : On trace l'éboulis des valeurs propres et l'on retient les axes situés avant le décrochage net (le coude d'éboulis).

4 Le Cercle des Corrélations (Interprétation des Variables)

Sur le cercle de rayon 1 formé par le plan factoriel (PC_1, PC_2) :

- › La coordonnée d'une variable X_j sur l'axe PC_k est égale à son coefficient de corrélation linéaire : $r(X_j, PC_k)$.
- › **Qualité de représentation ($\cos^2$)** :

$$\cos^2(PC_k) = [r(X_j, PC_k)]^2 \qquad \cos^2_{1+2} = \cos^2(PC_1) + \cos^2(PC_2)$$

Une variable proche de la circonférence ($\cos^2_{1+2} \rightarrow 1$) est parfaitement interprétable sur ce plan.

- › **Signification biologique des angles entre flèches** :

- Flèches très proches (angle $\approx 0^\circ$) $\implies$ Forte corrélation biologique positive (synergie fonctionnelle).
- Flèches opposées (angle $\approx 180^\circ$) $\implies$ Forte corrélation négative (antagonisme métabolique).
- Flèches à angle droit (angle $\approx 90^\circ$) $\implies$ Indépendance biologique totale.

5 Exercices d'Application & Solutions

Exercice 1 : Centrage-Réduction & Critère de Kaiser

Une étude omique mesure $p = 5$ biomarqueurs de stress oxydatif et d'inflammation (MDA, Catalase, SOD, IL-6, TNF- α) chez $N = 40$ patients. La matrice de corrélation R diagonalisée fournit les 5 valeurs propres ordonnées :

$$\lambda_1 = 2.65, \quad \lambda_2 = 1.25, \quad \lambda_3 = 0.60, \quad \lambda_4 = 0.35, \quad \lambda_5 = 0.15$$

- Calculez la somme des valeurs propres $\sum_{j=1}^5 \lambda_j$. Pourquoi est-elle exactement égale à 5 ?
- Calculez le pourcentage de variance expliquée par chaque axe et le pourcentage cumulé.
- Selon la règle de Kaiser ($\lambda \geq 1.0$), combien d'axes factoriels doit-on retenir ?
- Quel pourcentage cumulé de l'information biologique totale le premier plan factoriel (PC1 – PC2) résume-t-il ?

✓ Solution : Exercice 1

- a. Somme des valeurs propres :

$$\sum_{j=1}^5 \lambda_j = 2.65 + 1.25 + 0.60 + 0.35 + 0.15 = \mathbf{5.00}$$

Elle vaut exactement $p = 5$ car dans une ACP normée, chaque variable centrée-réduite a une variance de 1, et la trace de la matrice des corrélations est égale à la somme des éléments diagonaux : $\text{Tr}(R) = \sum_{j=1}^p 1 = 5$.

- b. Pourcentages de variance par axe :

$$\text{PC}_1 : \frac{2.65}{5} \times 100 = \mathbf{53.0\%} \quad (\text{Cumulé : } 53.0\%)$$

$$\text{PC}_2 : \frac{1.25}{5} \times 100 = \mathbf{25.0\%} \quad (\text{Cumulé : } 78.0\%)$$

$$\text{PC}_3 : \frac{0.60}{5} \times 100 = \mathbf{12.0\%} \quad (\text{Cumulé : } 90.0\%)$$

$$\text{PC}_4 : \frac{0.35}{5} \times 100 = \mathbf{7.0\%} \quad (\text{Cumulé : } 97.0\%)$$

$$\text{PC}_5 : \frac{0.15}{5} \times 100 = \mathbf{3.0\%} \quad (\text{Cumulé : } 100.0\%)$$

- c. **Règle de Kaiser** : Seuls les axes ayant $\lambda_k \geq 1.0$ sont retenus : $\lambda_1 = 2.65 \geq 1.0$ et $\lambda_2 = 1.25 \geq 1.0$, tandis que $\lambda_3 = 0.60 < 1.0$. On retient donc exactement **2 axes factoriels** (PC₁ et PC₂).
- d. **Qualité globale du résumé 2D** : Le plan factoriel (PC₁, PC₂) restitue **78.0%** de l'inertie biologique totale de l'étude (perte d'information limitée à 22%).

✎ Exercice 2 : Interprétation du Cercle des Corrélations

Sur le cercle des corrélations du premier plan factoriel (PC₁, PC₂), les coordonnées des 5 biomarqueurs sont :

Biomarqueur	PC ₁ (r)	PC ₂ (r)	cos ² (PC ₁)	cos ² (PC ₂)
MDA (Peroxydation)	+0.88	−0.20	0.774	0.040
IL-6 (Cytokine)	+0.92	−0.15	0.846	0.023
TNF-α (Cytokine)	+0.85	−0.25	0.723	0.063
Catalase (Antioxydant)	−0.80	−0.45	0.640	0.203
SOD (Antioxydant)	−0.10	+0.85	0.010	0.723

- a. Calculez la qualité de représentation globale $\cos^2_{1+2}$ pour la cytokine IL-6 et pour la SOD. Sont-elles bien représentées ?

- b. Quels biomarqueurs sont fortement corrélés positivement entre eux sur PC_1 ? Quelle est leur signification pathologique ?
- c. Interprétez l'opposition entre le cluster inflammatoire (MDA, IL-6, TNF- α) et la Catalase.
- d. Donnez une signification biologique concise pour l'axe PC_1 et pour l'axe PC_2 .

✓ Solution : Exercice 2

a. Qualité de représentation ($\cos^2_{1+2}$) :

$$\text{Pour l'IL-6 : } \cos^2_{1+2} = 0.846 + 0.023 = \mathbf{0.869} \quad (86.9\%)$$

$$\text{Pour la SOD : } \cos^2_{1+2} = 0.010 + 0.723 = \mathbf{0.733} \quad (73.3\%)$$

Toutes deux sont largement supérieures à 0.50 : elles sont très fidèlement représentées dans ce premier plan factoriel.

- b. **Corrélations positives sur PC_1** : L'IL-6 (+0.92), le MDA (+0.88) et le TNF- α (+0.85) pointent ensemble vers le côté positif de PC_1 . **Signification biologique** : Il existe une association étroite entre l'orage cytokinique inflammatoire et la peroxydation lipidique des membranes cellulaires.

- c. **Opposition Antioxydante vs Inflammatoire** : La Catalase a une coordonnée négative élevée sur PC_1 (−0.80), diamétralement opposée au MDA et à l'IL-6 (angle proche de 180°). **Signification biologique** : L'effondrement des défenses enzymatiques antioxydantes est directement corrélé à la flambée de l'inflammation tissulaire.

d. Dénomination biologique des axes factoriels :

- **Axe PC_1 (53% d'inertie)** : *Axe de l'atteinte inflammatoire et du stress oxydatif* (oppose les patients très enflammés à droite aux patients protégés à gauche).
- **Axe PC_2 (25% d'inertie)** : *Axe du statut enzymatique SOD* (différencie les profils de régulation de la superoxyde dismutase).

Formulaire Récapitulatif : Métriques de l'ACP Normée

Métrique ACP	Formule	Signification en Biologie
Standardisation (Z-score)	$z_{ij} = (x_{ij} - \bar{x}_j) / s_j$	Égalisation du poids de toutes les variables
Inertie totale	$\sum_{k=1}^p \lambda_k = p$	Somme des variances de toutes les variables
Proportion de variance	$\% = (\lambda_k / p) \times 100$	Poids informatif d'un axe factoriel
Règle de Kaiser	Retenir si $\lambda_k \geq 1.0$	Seuil de pertinence statistique
Coordonnée factorielle	$F_{jk} = r(X_j, PC_k)$	Corrélation de la variable avec l'axe
Qualité de représentation	$\cos^2(PC_k) = r^2(X_j, PC_k)$	Part de la variance de la variable captée par l'axe