

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : Biostatistiques Appliquées & Modélisation

Enseignante : Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

color BioNavy



Portail Interactif Web

Scannez pour les simulateurs

📖 SUPPORT DE COURS & GUIDE PRATIQUE RÉDIGÉ (CHAPITRE 5)

Analyse en Composantes Principales (ACP)

Réduction de Dimension, Décomposition Spectrale & Phénotypage Omique

1 Introduction : Le Défi de la Haute Dimensionnalité Omique

En biochimie moderne, l'expérimentateur ne mesure plus une seule variable à la fois :

- › **Protéomique et Métabolomique** : Des dizaines de métabolites ou cytokines sont quantifiés simultanément chez les mêmes patients.
- › **Phénotypage multi-paramétrique** : Paramètres sanguins, enzymatiques, histologiques et d'imagerie.

Face à un tableau de données de n échantillons et p variables corrélées entre elles ($p > 3$), l'esprit humain ne peut pas visualiser un espace à p dimensions. **L'Analyse en Composantes Principales (ACP)** est la méthode non supervisée reine qui projette ce nuage de points multidimensionnel sur un plan 2D optimal en **préservant le maximum de variabilité biologique (inertie)**.


💡 Le Principe Fondamental de l'ACP

L'ACP construit de nouvelles variables synthétiques appelées **Composantes Principales** ($PC_1, PC_2, \dots$), qui sont des combinaisons linéaires des variables initiales :

1. Elles sont **strictement orthogonales (indépendantes)** entre elles (corrélation nulle).
2. Elles sont classées par **ordre décroissant de variance expliquée** : PC_1 capture le plus grand axe d'éparpillement des données, puis PC_2 capture le second axe orthogonal, etc.

Figure & Analyse Visuelle : Rotation Orthogonale & Construction des Axes Principaux

B. Rotation des Axes : PC1 Maximise l'Inertie, PC2 est Orthogonal



Intuition géométrique de la décomposition spectrale :

- ✦ **Espace d'origine corrélé** : Les variables biologiques initiales (ex : glycémie et insulïnémie) présentent une forte corrélation oblique, générant une redondance d'information.
- ✦ **Rotation optimale vers PC₁ et PC₂** : L'ACP effectue une rotation rigide des axes sans déformer les distances inter-individuelles. Le premier axe PC₁ s'aligne exactement sur le grand axe d'élongation de l'ellipse de dispersion, captant le maximum de variance possible.
- ✦ **Orthogonalité stricte** : Le second axe PC₂ est orienté à 90° du premier. Il capture la variabilité résiduelle indépendante, éliminant toute corrélation parasite entre composantes.

2 Centrage-Réduction : L'Obligation de l'ACP Normée

En biologie, les variables sont mesurées dans des unités et avec des amplitudes radicalement hétérogènes :

- ✖ Glycémie : $\approx 1.10 \pm 0.25$ g/L (variance $\sigma^2 = 0.0625$).
- ✖ Transaminases ALAT : $\approx 45 \pm 30$ UI/L (variance $\sigma^2 = 900$).

⚠ Piège à Éviter / Règle d'Or : Le Piège de l'Effet d'Échelle en Biologie

Si l'on appliquait l'ACP sur les données brutes, l'ALAT capterait à elle seule plus de 99% de la variance totale, simplement parce que son unité produit de grands nombres ! Pour que chaque variable pèse équitablement avec un poids de 1, il faut impérativement **centrer et réduire** chaque mesure :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

L'ACP réalisée sur ces données centrées-réduites s'appelle une **ACP normée** (elle diagonalise la matrice des corrélations R , dont la trace vaut $\sum \lambda_j = p$).

3 Valeurs Propres (λ_k) & Choix du Nombre d'Axes


L'inertie totale du nuage de points standardisé est égale au nombre total de variables p . Chaque composante principale PC_k est associée à une **valeur propre** λ_k issue de la diagonalisation de la matrice des corrélations $R \cdot u_k = \lambda_k \cdot u_k$:

$$\% \text{ Inertie}(PC_k) = \frac{\lambda_k}{p} \times 100 \quad \sum_{k=1}^p \lambda_k = p$$

Pour sélectionner le nombre optimal d'axes factoriels à retenir :

- ✓ **1. La Règle de Kaiser-Guttman** : On ne retient que les axes dont la valeur propre est supérieure à la moyenne ($\lambda_k \geq 1.0$). Un axe avec $\lambda < 1$ apporte moins d'information qu'une seule variable brute standardisée.
- ✓ **2. Le Critère du Coude (Scree Plot de Cattell)** : On ordonne les valeurs propres de manière décroissante sur un graphique d'éboulis. On conserve les axes situés à gauche du point d'inflexion (le « coude »), au-delà duquel l'éboulis ne reflète que du bruit statistique résiduel.

Figure & Analyse Visuelle : Éboulis des Valeurs Propres (Scree Plot) & Seuil de Kaiser



Analyse du graphique d'éboulis spectral :

- › **Seuil horizontal de Kaiser** ($\lambda = 1.0$) : La ligne en pointillés rouges matérialise la coupure objective. Seuls les axes situés au-dessus de cette ligne sont retenus pour l'interprétation biologique approfondie.
- › **Règle du Coude** : Le décrochage majeur se produit après le 2^e axe. Les composantes PC_1 et PC_2 suffisent à capturer l'essentiel de l'information omique, permettant de réduire la dimensionnalité sans sacrifier le signal biologique.

4 Le Plan Factoriel : Cercle des Corrélations & Carte des Individus

L'interprétation conjointe de l'ACP repose sur deux graphiques complémentaires :

4.1 1. Le Cercle des Corrélations (Espace des Variables)

Sur le cercle de rayon unité ($r = 1$) dans le plan (PC_1, PC_2) :

- La coordonnée d'une variable X_j sur l'axe PC_k est son coefficient de corrélation linéaire : $F_{jk} = r(X_j, PC_k)$.
- Qualité de représentation ($\cos^2$)** : $\cos^2_{1+2} = r^2(X_j, PC_1) + r^2(X_j, PC_2)$. Une flèche atteignant la circonférence ($\cos^2 \approx 1$) est parfaitement interprétable sur ce plan.
- Contribution relative (CTR_j)** : Fraction de variance de l'axe PC_k imputable à la variable X_j :


$$CTR_j(PC_k) = \frac{r^2(X_j, PC_k)}{\lambda_k} \times 100$$

Une variable contribue significativement si sa contribution dépasse le seuil moyen $100/p\%$.

4.2 2. La Carte des Individus (Scores Factoriels)

Chaque échantillon biologique i reçoit des coordonnées de score : $s_{ik} = \sum_{j=1}^p z_{ij} \cdot u_{jk}$. Deux échantillons proches sur la carte partagent des profils biochimiques quasi-identiques.

Figure & Analyse Visuelle : Cercle des Corrélations (Variables) & Projection 2D des Individus (Scores)



Lecture croisée de l'ACP biomédicale :

- Cercle des Corrélations (Gauche) :** Le groupe de vecteurs pointant vers la droite associe étroitement les biomarqueurs pro-inflammatoires et oxydatifs, tandis que les enzymes antioxydantes pointent dans la direction opposée, révélant un antagonisme fonctionnel direct.
- Plan des Scores Individuels (Droite) :** Les points représentant les animaux ou patients se séparent nettement en clusters distincts (Témoins vs Diabétiques vs Traités) le long de l'axe PC_1 , démontrant la capacité de l'ACP à phénotyper sans supervision préalable les états pathologiques.

5 Exercices d'Application & Solutions

Exercice 1 : Centrage-Réduction & Critère de Kaiser

Une étude omique mesure $p = 5$ biomarqueurs de stress oxydatif et d'inflammation (MDA, Catalase, SOD, IL-6, TNF- α) chez $N = 40$ patients. La matrice de corrélation R diagonalisée fournit les 5 valeurs propres ordonnées :

$$\lambda_1 = 2.65, \quad \lambda_2 = 1.25, \quad \lambda_3 = 0.60, \quad \lambda_4 = 0.35, \quad \lambda_5 = 0.15$$

- Calculez la somme des valeurs propres $\sum_{j=1}^5 \lambda_j$. Pourquoi est-elle exactement égale à 5 ?
- Calculez le pourcentage de variance expliquée par chaque axe et le pourcentage cumulé.
- Selon la règle de Kaiser ($\lambda \geq 1.0$), combien d'axes factoriels doit-on retenir ?
- Quel pourcentage cumulé de l'information biologique totale le premier plan factoriel (PC1 – PC2) résume-t-il ?

Solution : Exercice 1

- a. Somme des valeurs propres :**

$$\sum_{j=1}^5 \lambda_j = 2.65 + 1.25 + 0.60 + 0.35 + 0.15 = \mathbf{5.00}$$

Elle vaut exactement $p = 5$ car dans une ACP normée, chaque variable centrée-réduite a une variance de 1, et la trace de la matrice des corrélations est égale à la somme des éléments diagonaux : $\text{Tr}(R) = \sum_{j=1}^p 1 = 5$.

- b. Pourcentages de variance par axe :**

$$\text{PC}_1 : \frac{2.65}{5} \times 100 = \mathbf{53.0\%} \quad (\text{Cumulé : } 53.0\%)$$

$$\text{PC}_2 : \frac{1.25}{5} \times 100 = \mathbf{25.0\%} \quad (\text{Cumulé : } 78.0\%)$$

$$\text{PC}_3 : \frac{0.60}{5} \times 100 = \mathbf{12.0\%} \quad (\text{Cumulé : } 90.0\%)$$

$$\text{PC}_4 : \frac{0.35}{5} \times 100 = \mathbf{7.0\%} \quad (\text{Cumulé : } 97.0\%)$$

$$\text{PC}_5 : \frac{0.15}{5} \times 100 = \mathbf{3.0\%} \quad (\text{Cumulé : } 100.0\%)$$

- c. Règle de Kaiser :** Seuls les axes ayant $\lambda_k \geq 1.0$ sont retenus : $\lambda_1 = 2.65 \geq 1.0$ et $\lambda_2 = 1.25 \geq 1.0$, tandis que $\lambda_3 = 0.60 < 1.0$. On retient donc exactement **2 axes factoriels (PC₁ et PC₂)**.

- d. Qualité globale du résumé 2D :** Le plan factoriel (PC₁, PC₂) restitue **78.0%** de l'inertie biologique totale de l'étude (perte d'information limitée à 22%).

Exercice 2 : Interprétation du Cercle des Corrélations

Sur le cercle des corrélations du premier plan factoriel (PC₁, PC₂), les coordonnées des 5 biomarqueurs sont :

Biomarqueur	PC ₁ (r)	PC ₂ (r)	cos ² (PC ₁)	cos ² (PC ₂)
MDA (Peroxydation)	+0.88	−0.20	0.774	0.040
IL-6 (Cytokine)	+0.92	−0.15	0.846	0.023
TNF-α (Cytokine)	+0.85	−0.25	0.723	0.063
Catalase (Antioxydant)	−0.80	−0.45	0.640	0.203
SOD (Antioxydant)	−0.10	+0.85	0.010	0.723

- Calculez la qualité de représentation globale $\cos^2_{1+2}$ pour la cytokine IL-6 et pour la SOD. Sont-elles bien représentées ?
- Quels biomarqueurs sont fortement corrélés positivement entre eux sur PC₁ ? Quelle est leur signification pathologique ?
- Interprétez l'opposition entre le cluster inflammatoire (MDA, IL-6, TNF-α) et la Catalase.
- Donnez une signification biologique concise pour l'axe PC₁ et pour l'axe PC₂.

✓ Solution : Exercice 2

a. Qualité de représentation ($\cos^2_{1+2}$) :

$$\text{Pour l'IL-6 : } \cos^2_{1+2} = 0.846 + 0.023 = \mathbf{0.869} \quad (86.9\%)$$

$$\text{Pour la SOD : } \cos^2_{1+2} = 0.010 + 0.723 = \mathbf{0.733} \quad (73.3\%)$$

Toutes deux sont largement supérieures à 0.50 : elles sont très fidèlement représentées dans ce premier plan factoriel.

- Corrélations positives sur PC₁** : L'IL-6 (+0.92), le MDA (+0.88) et le TNF-α (+0.85) pointent ensemble vers le côté positif de PC₁. **Signification biologique** : Il existe une association étroite entre l'orage cytokinique inflammatoire et la peroxydation lipidique des membranes cellulaires.

- Opposition Antioxydante vs Inflammatoire** : La Catalase a une coordonnée négative élevée sur PC₁ (−0.80), diamétralement opposée au MDA et à l'IL-6 (angle proche de 180°). **Signification biologique** : L'effondrement des défenses enzymatiques antioxydantes est directement corrélé à la flambée de l'inflammation tissulaire.

d. Dénomination biologique des axes factoriels :

- Axe PC₁ (53% d'inertie)** : *Axe de l'atteinte inflammatoire et du stress oxydatif* (oppose les patients très enflammés à droite aux patients protégés à gauche).
- Axe PC₂ (25% d'inertie)** : *Axe du statut enzymatique SOD* (différencie les profils de régulation de la superoxyde dismutase).

Formulaire Récapitulatif : Métriques de l'ACP Normée

Métrique ACP	Formule	Signification en Biologie
Standardisation (Z-score)	$z_{ij} = (x_{ij} - \bar{x}_j) / s_j$	Égalisation du poids de toutes les variables
Inertie totale	$\sum_{k=1}^p \lambda_k = p$	Somme des variances de toutes les variables
Proportion de variance	$\% = (\lambda_k / p) \times 100$	Poids informatif d'un axe factoriel
Règle de Kaiser	Retenir si $\lambda_k \geq 1.0$	Seuil de pertinence statistique
Coordonnée factorielle	$F_{jk} = r(X_j, PC_k)$	Corrélation de la variable avec l'axe
Qualité de représentation	$\cos^2(PC_k) = r^2(X_j, PC_k)$	Part de la variance de la variable captée par l'axe