

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : Biostatistiques Appliquées & Modélisation

Enseignante : Dr. Sarra BENMOUMOU-HOSNI (Ph.D.)

color BioNavy



Portail Interactif Web

Scannez pour les simulateurs

SUPPORT DE COURS & GUIDE PRATIQUE RÉDIGÉ (CHAPITRE 6)

Classification Ascendante Hiérarchique (CAH)

Clustering Non Supervisé, Critère de Ward & Typologie Moléculaire

1 Introduction : La Taxonomie Moléculaire du Vivant

En microbiologie, oncologie et biotechnologie, le biologiste cherche fréquemment à regrouper des échantillons en sous-types homogènes sans étiquette préalable :

- Identifier des souches bactériennes hospitalières partageant le même profil d'antibiorésistance.
- Découvrir de nouveaux sous-types moléculaires de tumeurs mammaires d'après leur transcriptome.
- Classer des isolats environnementaux selon leurs activités enzymatiques sécrétées.

La **Classification Ascendante Hiérarchique (CAH)** est un algorithme itératif non supervisé qui part des individus isolés et les agrège deux à deux de manière emboîtée jusqu'à former un groupe unique, visualisé sous la forme d'un **dendrogramme** (arbre de classification).

2 Métriques de Dissimilarité : La Matrice des Distances (D_0)

Pour quantifier la proximité phénotypique entre deux échantillons biologiques $A = (x_{A1}, \dots, x_{Ap})$ et $B = (x_{B1}, \dots, x_{Bp})$ décrits par p paramètres :

$$\text{Distance Euclidienne : } d_E(A, B) = \sqrt{\sum_{j=1}^p (x_{Aj} - x_{Bj})^2}$$

$$\text{Distance de Manhattan } (L_1) : d_M(A, B) = \sum_{j=1}^p |x_{Aj} - x_{Bj}|$$

L'algorithme calcule au départ la **matrice de dissimilarité** D_0 de dimension $n \times n$, symétrique et à diagonale nulle ($d(i, i) = 0$).

3 Stratégies de Liaison (Linkage Methods)


À chaque étape, après la fusion de deux individus, comment mesure-t-on la distance entre deux groupes d'échantillons C_1 et C_2 ?

- **Saut Minimum (Single Linkage) :** $D(C_1, C_2) = \min_{x \in C_1, y \in C_2} d(x, y)$.

Défaut majeur en biologie : Phénomène de chaînage (*chaining effect*) qui fusionne artificiellement des groupes distincts reliés par un seul point bruit transitoire.

- › **Saut Maximum (*Complete Linkage*)** : $D(C_1, C_2) = \max d(x, y)$. Forme des clusters très compacts et sphériques.
- › **Lien Moyen (*Average Linkage* / UPGMA)** : Moyenne arithmétique de toutes les distances inter-paires. Très utilisé en phylogénie moléculaire.

Figure & Analyse Visuelle : Comparaison Visuelle des 4 Stratégies de Liaison (Linkage)



Analyse des comportements géométriques d'agrégation :

- › **Single Linkage (Saut Minimum)** : Très sensible aux points aberrants et sujet au « chaînage » (formation de longs filaments reliant artificiellement des groupes distincts).
- › **Complete Linkage (Saut Maximum)** : Favorise des groupes sphériques très compacts, mais peut casser artificiellement de grands clusters naturels.
- › **Average Linkage (Lien Moyen - UPGMA)** : Compromis robuste, très populaire pour les arbres phylogénétiques de séquences d'ADN/protéines.
- › **Méthode de Ward (Variance Minimale)** : Standard en biomédecine. Produit des groupes réguliers et homogènes en minimisant la variance interne de chaque cluster.

Le Critère de Ward & Théorème de Décomposition d'Huygens

La méthode de référence absolue en biochimie clinique et en médecine translationnelle est le **Critère de Ward**. D'après le **théorème d'Huygens**, l'inertie totale du nuage de points est invariante :

$$I_{\text{totale}} = I_{\text{intra}} + I_{\text{inter}} = \text{Constante}$$

- ✓ Au départ (n classes de 1 individu) : $I_{\text{intra}} = 0$ et $I_{\text{inter}} = I_{\text{totale}}$.
- ✓ À la fin (1 seule classe) : $I_{\text{intra}} = I_{\text{totale}}$ et $I_{\text{inter}} = 0$.

À chaque étape, la fusion de deux groupes (A, B) engendre une **augmentation de l'inertie intra-classe** :


$$\Delta I(A, B) = \frac{n_A \cdot n_B}{n_A + n_B} \cdot d_E^2(g_A, g_B)$$

où g_A et g_B sont les barycentres des clusters. L'algorithme de Ward choisit systématiquement la fusion qui minimise cette perte d'homogénéité interne ($\min \Delta I$).

4 Le Dendrogramme & Choix Optimal du Nombre de Classes (k)

Le dendrogramme représente graphiquement l'arbre de classification. L'axe vertical porte la hauteur de fusion (ΔI).

Figure & Analyse Visuelle : Dendrogramme de Ward & Seuil Optimal de Coupure Horizontale



Méthodologie de coupure de l'arbre taxonomique :

- › **Hauteur des branches verticales** : La longueur d'une branche verticale est proportionnelle au coût en inertie (ΔI). Une longue branche signifie que l'on agrège deux sous-populations radicalement différentes.
- › **Ligne de coupure horizontale** : On sectionne l'arbre juste avant le saut d'inertie majeur. Le nombre de tiges verticales traversées définit le nombre de phénotypes distincts k .

✓ Synthèse & Décision Biologique : Règle de Coupe Horizontale du Dendrogramme

Pour déterminer le nombre biologique optimal de sous-groupes (k) :

1. On repère le **plus grand saut vertical** entre deux paliers de fusion successifs (perte d'inertie maximale).
2. On trace une **ligne de coupure horizontale** au niveau de ce saut majeur.
3. Le nombre de branches verticales coupées correspond exactement au nombre naturel de classes phénotypiques k .


5 La Heatmap Clustérisée Bidirectionnelle (Clustermap Omique)

En biochimie, protéomique et séquençage ARN, la restitution finale d'une CAH s'effectue quasi-systématiquement sous forme de **Clustermap** :

- › Un dendrogramme vertical regroupe les **échantillons ou patients** en colonnes selon leur similarité d'expression.
- › Un dendrogramme horizontal regroupe les **gènes ou biomarqueurs** en lignes selon leur co-régulation fonctionnelle.

- La matrice centrale est colorée en dégradé continu (ex : rouge pour surexpression, bleu pour sous-expression), mettant immédiatement en évidence les signatures moléculaires spécifiques de chaque groupe.

Figure & Analyse Visuelle : Heatmap Clustérisée Bidirectionnelle (Biomarqueurs × Échantillons)



Lecture de la signature moléculaire en double clustering :

- Les blocs de couleur homogènes mettent en évidence des **modules de biomarqueurs co-régulés**.
- La classification simultanée des patients permet d'identifier des groupes répondeurs et non-répondeurs à une thérapie ciblée sans aucun étiquetage clinique préalable.

6 Exercices d'Application & Solutions

Exercice 1 : Matrice de Distance & Première Étape de Fusion (RT-qPCR)

Le profil d'expression relative ($\Delta\Delta C_t$) de deux gènes de résistance (G_1 : pompe d'efflux, G_2 : β -lactamase) est quantifié chez 4 isolats bactériens cliniques (S_1, S_2, S_3, S_4) :

Isolat Bactérien	S_1	S_2	S_3	S_4
Gène G_1 (Efflux)	1.0	2.0	5.0	6.0
Gène G_2 (β -lactamase)	2.0	1.0	5.0	4.0

- Calculez les carrés des distances euclidiennes d_E^2 entre chaque paire d'isolats.
- Établissez la matrice des distances euclidiennes D_0 (4×4).
- Quels sont les deux premiers isolats qui fusionnent ?
- Quelle est la seconde paire d'isolats qui fusionne à la même distance ?

✓ Solution : Exercice 1

a. Calcul des distances euclidiennes au carré (d_E^2) :

$$d^2(S_1, S_2) = (2 - 1)^2 + (1 - 2)^2 = 1 + 1 = \mathbf{2.0} \implies d(S_1, S_2) = \sqrt{2} \approx \mathbf{1.414}$$

$$d^2(S_1, S_3) = (5 - 1)^2 + (5 - 2)^2 = 16 + 9 = \mathbf{25.0} \implies d(S_1, S_3) = \mathbf{5.000}$$

$$d^2(S_1, S_4) = (6 - 1)^2 + (4 - 2)^2 = 25 + 4 = \mathbf{29.0} \implies d(S_1, S_4) = \sqrt{29} \approx \mathbf{5.385}$$

$$d^2(S_2, S_3) = (5 - 2)^2 + (5 - 1)^2 = 9 + 16 = \mathbf{25.0} \implies d(S_2, S_3) = \mathbf{5.000}$$

$$d^2(S_2, S_4) = (6 - 2)^2 + (4 - 1)^2 = 16 + 9 = \mathbf{25.0} \implies d(S_2, S_4) = \mathbf{5.000}$$

$$d^2(S_3, S_4) = (6 - 5)^2 + (4 - 5)^2 = 1 + 1 = \mathbf{2.0} \implies d(S_3, S_4) = \sqrt{2} \approx \mathbf{1.414}$$

b. Matrice triangulaire inférieure des distances (D_0) :

$$D_0 = \begin{pmatrix} 0 & & & \\ \mathbf{1.414} & 0 & & \\ 5.000 & 5.000 & 0 & \\ 5.385 & 5.000 & \mathbf{1.414} & 0 \end{pmatrix}$$

c. **Première fusion** : La distance minimale dans la matrice est $d(S_1, S_2) = 1.414$. Les deux premiers isolats agrégés sont donc (S_1, S_2) .

d. **Deuxième fusion** : La seconde distance minimale est $d(S_3, S_4) = 1.414$. Le second groupe formé est donc (S_3, S_4) .

✎ Exercice 2 : Critère de Ward, Barycentres & Dendrogramme

À partir des deux clusters formés à l'Exercice 1 : $C_1 = \{S_1, S_2\}$ et $C_2 = \{S_3, S_4\}$:

- Calculez les coordonnées des barycentres g_1 du groupe C_1 et g_2 du groupe C_2 .
- Calculez la distance euclidienne au carré entre les deux barycentres : $d_E^2(g_1, g_2)$.
- Calculez l'augmentation d'inertie $\Delta I(C_1, C_2)$ lors de la fusion finale selon la formule de Ward.
- Comparez $\Delta I(C_1, C_2)$ aux premières fusions ($\Delta I = 1.0$). Où doit-on couper l'arbre et quelle est l'interprétation microbiologique finale ?

✓ Solution : Exercice 2

a. Coordonnées des barycentres :

$$g_1 = \left(\frac{1.0 + 2.0}{2}; \frac{2.0 + 1.0}{2} \right) = (\mathbf{1.5}; \mathbf{1.5})$$

$$g_2 = \left(\frac{5.0 + 6.0}{2}; \frac{5.0 + 4.0}{2} \right) = (\mathbf{5.5}; \mathbf{4.5})$$

b. Distance entre barycentres :

$$d_E^2(g_1, g_2) = (5.5 - 1.5)^2 + (4.5 - 1.5)^2 = 4.0^2 + 3.0^2 = 16.0 + 9.0 = \mathbf{25.0}$$

c. Augmentation d'inertie de Ward lors de la fusion finale ($n_1 = 2, n_2 = 2$) :

$$\Delta I(C_1, C_2) = \frac{n_1 \cdot n_2}{n_1 + n_2} \cdot d_E^2(g_1, g_2) = \frac{2 \times 2}{2 + 2} \times 25.0 = \frac{4}{4} \times 25.0 = \mathbf{25.0}$$

(Pour chaque fusion initiale d'individus isolés, $\Delta I = \frac{1 \times 1}{2} \times 2.0 = 1.0$).

- d. Coupe du dendrogramme & Décision microbiologique :** Il y a un saut d'inertie massif entre $\Delta I = 1.0$ (variabilité intra-groupe très faible) et $\Delta I = 25.0$ (disparité inter-groupe gigantesque). La ligne de coupure horizontale se place entre 1.0 et 25.0 (vers une hauteur de 10), isolant sans ambiguïté $k = 2$ **classes biologiques distinctes** :
- **Cluster 1** (S_1, S_2) : Profil sensible à expression basale des gènes de résistance ($G_1 \leq 2, G_2 \leq 2$).
 - **Cluster 2** (S_3, S_4) : Profil multi-résistant avec surexpression conjointe de la pompe d'efflux et de la β -lactamase ($G_1 \geq 5, G_2 \geq 4$).

Formulaire Récapitulatif : Algorithme de la CAH

Étape / Méthode	Formule Mathématique	Propriété en Biologie
Distance Euclidienne	$d(A, B) = \sqrt{\sum (x_{Aj} - x_{Bj})^2}$	Écart géométrique réel dans l'espace des descripteurs
Inertie intra-classe de Ward	$\Delta I(A, B) = \frac{n_A n_B}{n_A + n_B} d_E^2(g_A, g_B)$	Minimise la dispersion interne des sous-groupes
Single Linkage	$\min d(x_i, y_j)$	Risque de chaînage artificiel
Complete Linkage	$\max d(x_i, y_j)$	Favorise les clusters compacts et sphériques
Critère de coupure	Saut vertical maximal dans le dendrogramme	Définit le nombre de phénotypes majeurs (k)