

Université M'Hamed Bougara de Boumerdès (UMBB)

Faculté des Sciences — Département de Biologie

Master 2 : Biochimie Appliquée (Semestre 3)

Module : **Biostatistiques Appliquées & Plans d'Expériences**

color BioNavy

Année 2024 – 2025

 Dr. S. BENMOUMOU

Enseignante Responsable

**SÉRIE
D'EXERCICES****Travaux Dirigés : Série 05****Analyse en Composantes Principales (ACP) en Biologie** **Exercice 1 : Centrage-Réduction & Nécessité de la Standardisation**Une étude métabolomique hospitalière mesure 3 paramètres sanguins chez $N = 40$ patients :

- Glycémie (X_1) : Moyenne $\bar{x}_1 = 1.10$ g/L, écart-type $s_1 = 0.25$ g/L ($s_1^2 = 0.0625$).
- Transaminases ALAT (X_2) : Moyenne $\bar{x}_2 = 45.0$ UI/L, écart-type $s_2 = 30.0$ UI/L ($s_2^2 = 900.0$).
- Cholestérol total (X_3) : Moyenne $\bar{x}_3 = 5.20$ mmol/L, écart-type $s_3 = 0.80$ mmol/L ($s_3^2 = 0.640$).

Questions :

- Donnez la formule de transformation en variable centrée-réduite (Z -score) : $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$.
- Un patient présente : Glycémie = 1.60 g/L, ALAT = 105.0 UI/L, Cholestérol = 6.80 mmol/L. Calculez ses trois coordonnées centrées-réduites (z_{i1}, z_{i2}, z_{i3}). Quel paramètre biologique est le plus anormal chez ce patient ?
- Si l'on réalisait une ACP brute sur la matrice de covariance sans centrage-réduction, quelle variable dicterait à elle seule le premier axe factoriel ? Pourquoi cela fausserait-il totalement l'analyse biologique ?
- Déduisez-en pourquoi toute ACP en biologie/biochimie doit impérativement être une ****ACP normée**** (sur la matrice des corrélations R).

 Exercice 2 : Matrice de Corrélation, Valeurs Propres & Éboulis de KaiserDans une étude omique portant sur $p = 5$ biomarqueurs de stress oxydatif et d'inflammation (MDA, Catalase, SOD, IL-6, TNF- α), l'ACP normée fournit les 5 valeurs propres ordonnées suivantes :

$$\lambda_1 = 2.65, \quad \lambda_2 = 1.25, \quad \lambda_3 = 0.60, \quad \lambda_4 = 0.35, \quad \lambda_5 = 0.15$$

Questions :

- Quelle est la somme totale des valeurs propres $\sum_{j=1}^5 \lambda_j$? Justifiez cette valeur à partir de la trace de la matrice de corrélation R .
- Calculez pour chaque axe factoriel la proportion de variance expliquée (% Inertie = $\lambda_k/p \times 100$) ainsi que le pourcentage cumulé.

- c. Selon le critère de Kaiser ($\lambda \geq 1.0$), combien d'axes factoriels doit-on retenir ?
- d. Quel pourcentage cumulé de la variabilité biologique totale le premier plan factoriel (PC1 – PC2) permet-il de résumer ?



Exercice 3 : Interprétation du Cercle des Corrélations & Métriques

Sur le cercle des corrélations du premier plan factoriel (PC1, PC2), les coordonnées factorielles (qui représentent les corrélations linéaires $r(X_j, PC_k)$) des 5 biomarqueurs sont :

Biomarqueur	PC1 (F_1)	PC2 (F_2)	$\cos^2(\text{PC1})$	$\cos^2(\text{PC2})$	Qualité Globale ($\cos^2_{1+2}$)
MDA (Peroxydation)	+0.88	−0.20	?	?	?
IL-6 (Cytokine)	+0.92	−0.15	?	?	?
TNF- α (Cytokine)	+0.85	−0.25	?	?	?
Catalase (Antioxydant)	−0.80	−0.45	?	?	?
SOD (Antioxydant)	−0.10	+0.85	?	?	?

Questions :

- a. Complétez le tableau en calculant pour chaque variable sa qualité de représentation : $\cos^2(PC_k) = r^2(X_j, PC_k)$, ainsi que $\cos^2_{1+2} = \cos^2(PC1) + \cos^2(PC2)$.
- b. Quelle est la variable la mieux représentée sur l'axe PC1 ? Quelle est celle qui définit principalement l'axe PC2 ?
- c. Interprétez l'angle proche de 0° entre les vecteurs IL-6 et MDA : quelle est la relation biologique entre ces deux molécules ?
- d. Interprétez l'angle obtus ($\approx 180^\circ$) entre le cluster (MDA, IL-6) et la Catalase. Donnez une dénomination biologique claire pour l'axe PC1 (ex: « Axe de l'état inflammatoire et du stress oxydatif »).



Exercice 4 : Plan des Individus & Discrimination Clinique

L'ACP projette les 40 patients dans le plan factoriel (PC1, PC2). Les patients sont répartis en 3 groupes diagnostiques :

- Groupe 1 (Témoins sains, $n = 15$) : situés majoritairement dans le cadran gauche ($PC1 < -1.0$).
- Groupe 2 (Diabétiques équilibrés, $n = 15$) : situés au centre ($-0.5 < PC1 < +0.5$).
- Groupe 3 (Patients avec Stéatohépatite NASH, $n = 10$) : situés à l'extrême droite ($PC1 > +1.5$).

Questions :

- a. L'ACP est-elle une méthode supervisée (qui utilise les diagnostics pour classer) ou non supervisée ? Pourquoi l'alignement spontané des groupes le long de PC1 est-il une validation biologique remarquable ?
- b. Si un nouveau patient non étiqueté se projette avec les coordonnées ($PC1 = +2.40$, $PC2 = -0.30$), quel est son profil biologique probable ? Quels examens de confirmation préconisez-vous ?

- c. Deux patients présentent le même score $PC1 = +1.80$, mais l'un a $PC2 = +1.50$ et l'autre $PC2 = -1.20$. Quelle différence enzymatique spécifique les distingue ?



Exercice 5 : Sélection de Biomarqueurs & Élimination de la Redondance

Dans le but de concevoir une trousse de diagnostic rapide (Point-of-Care) à faible coût pour les centres de santé, l'équipe hospitalière souhaite réduire le nombre de biomarqueurs à doser de 5 à 2 ou 3 sans perdre d'information diagnostique majeure. **Questions :**

- En analysant le cercle des corrélations de l'Exercice 3, pourquoi doser simultanément IL-6 et TNF- α constitue-t-il un gaspillage analytique redondant ?
- Parmi l'IL-6 et le TNF- α , laquelle choisiriez-vous en justifiant par sa qualité de représentation $\cos^2(PC1)$?
- Proposez le panel minimal optimal de 2 ou 3 biomarqueurs qui capture à la fois l'information de l'axe PC1 et celle de l'axe PC2.